

IBI5086 – Lista 2 (1º Sem/2026)

Resolução

2026-05-06

Contents

1	Mapeamento de Genes: ANOVA com SNPs	2
1.1	Caso 1 – ANOVA 1 fator em 3 níveis (efeitos aditivo e de dominância)	2
1.1.1	Codificação dos efeitos aditivo (xa) e de dominância (xd)	4
1.1.2	Modelo com 2 g.l. – fatores aditivo e de dominância	4
1.1.3	Diagnóstico dos resíduos (Caso 1)	5
1.1.4	Comparações múltiplas de Tukey	6
1.2	Caso 2 – ANOVA Fatorial 3×3 (dois SNPs, efeitos aditivo, dominância e epistasia)	7
1.2.1	Modelo com efeitos aditivos, dominância e interações (8 g.l.)	9
2	Delineamento Fatorial 3×2: SNP $\times$ Subgrupo Populacional	12
2.1	Simulação dos dados (P1, P2, P3)	12
2.2	Análise por População	13
2.2.1	Função auxiliar para análise completa	13
2.2.2	P1 – Sem efeito de SNP, sem interação	14
2.2.3	P3 – Efeito de SNP com interação (epistasia SNP $\times$ Subgrupo)	26
2.3	Item (d) – Combinando as três populações	32
2.3.1	(d.i) – Fatorial $3 \times 2 \times 3$: SNP $\times$ Grupo $\times$ População (todos fixos)	32
2.3.2	(d.ii) – Fatorial 3×2 com População como fator aleatório (ANOVA Mista)	33
3	Regressão Logística: Y dicotomizada	34
3.1	Dicotomização de Y	34
3.2	Questão 1 (Caso 1) – Regressão Logística	35
3.3	Questão 1 (Caso 2) – Regressão Logística com dois SNPs	37
3.4	Questão 2 – Regressão Logística por População	39
3.5	Regressão Logística Combinada (3 populações)	42
3.6	Comparação ANOVA vs. Regressão Logística	44

1 Mapeamento de Genes: ANOVA com SNPs

Gerar X (binomial) e Y (normal); ajustar modelos de ANOVA.

1.1 Caso 1 – ANOVA 1 fator em 3 níveis (efeitos aditivo e de dominância)

```
set.seed(8732)
n_por_genot <- 100

# X: genótipos 0=aa, 1=Aa, 2=AA (distribuição ~binomial(2, p=0.3))
# probabilidades Hardy-Weinberg com p=0.3
p <- 0.3
freq <- c((1-p)^2, 2*p*(1-p), p^2) # aa, Aa, AA
snp <- sample(0:2, n_por_genot*3, replace=TRUE, prob=freq)

# Y: resposta com efeito aditivo (a=10) e dominância (d=5) sobre a média basal 100
# mu_aa=100, mu_Aa=115 (=100+d, com d=5 sobre midpoint), mu_AA=120 (=100+2a)
# Parametrização: a=(mu_AA-mu_aa)/2=10; d=mu_Aa-(mu_AA+mu_aa)/2=5
mu <- c(100, 115, 120)[snp + 1]
Y1 <- rnorm(length(snp), mean = mu, sd = 15)

dat1 <- data.frame(Y = Y1, SNP = factor(snp, labels = c("aa", "Aa", "AA")),
                  snp_num = snp)

# Estatísticas descritivas por genótipo
library(psych)
descri <- describeBy(dat1, group = "SNP", mat = TRUE)

tabela1 <- descri[c("Y1", "Y2", "Y3"), c("group1", "n", "mean", "sd", "median", "min", "max")]
tabela1$group1 <- c("aa", "Aa", "AA")
rownames(tabela1) <- NULL


knitr::kable(tabela1, digits = 2,
             col.names = c("genotype", "n", "mean", "sd", "median", "min", "max"),
             caption = "Estatísticas descritivas de Y por genótipo (Caso 1)")
```

Table 1: Estatísticas descritivas de Y por genótipo (Caso 1)

genotype	n	mean	sd	median	min	max
aa	148	100.47	15.25	101.29	57.16	135.29
Aa	123	113.72	14.82	112.69	76.27	160.89
AA	29	120.45	13.89	121.18	87.74	144.04


```
boxplot(Y ~ SNP, data = dat1, col = c("lightblue", "lightgreen", "lightyellow"),
        main = "Distribuição de Y por Genótipo (Caso 1)", xlab = "Genótipo", ylab = "Y")
```

Distribuição de Y por Genótipo (Caso 1)



```
# Perfil de médias
medias1 <- tapply(dat1$Y, dat1$SNP, mean)
plot(0:2, medias1, type = "b", pch = 19, col = "red",
     xaxt = "n", xlab = "Genótipo", ylab = "Média de Y",
     main = "Perfil de Médias - Caso 1")
axis(1, at = 0:2, labels = c("aa", "Aa", "AA"))
```

Perfil de Médias – Caso 1



1.1.1 Codificação dos efeitos aditivo (xa) e de dominância (xd)

```
# xa: -1 (aa), 0 (Aa), 1 (AA) + captura efeito aditivo
# xd: 0 (aa), 1 (Aa), 0 (AA) + captura desvio de dominância
dat1$xa <- dat1$snp_num - 1
dat1$xd <- ifelse(dat1$snp_num == 1, 1, 0)
```

1.1.2 Modelo com 2 g.l. – fatores aditivo e de dominância

```
fit1_ad <- lm(Y ~ xa + xd, data = dat1)
summary(fit1_ad)
```

```
##
## Call:
## lm(formula = Y ~ xa + xd, data = dat1)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -43.310  -9.935  -0.274   9.605  47.170
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   110.456      1.518  72.750 < 2e-16 ***
## xa              9.990      1.518   6.580 2.13e-10 ***
## xd              3.263      2.031   1.607  0.109
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 14.95 on 297 degrees of freedom
## Multiple R-squared:  0.2029, Adjusted R-squared:  0.1976
## F-statistic: 37.81 on 2 and 297 DF, p-value: 2.356e-15
```

```
anova(fit1_ad)
```

```
## Analysis of Variance Table
##
## Response: Y
##           Df Sum Sq Mean Sq F value    Pr(>F)
## xa          1  16330  16329.9  73.0331 6.799e-16 ***
## xd          1    577    577.3   2.5821  0.1091
## Residuals 297  66408    223.6
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Discussão: Interpretação dos coeficientes

O intercepto estimado ($\hat{\mu} = 110,46$) representa o ponto médio entre as médias dos homozigotos, $(\mu_{AA} + \mu_{aa})/2$.


O efeito aditivo (xa, $\hat{a} = 9,99$) é altamente significativo ($p < 0,001$), indicando que cada alelo A adicional eleva Y em aproximadamente 10 unidades.

O efeito de dominância (x_d , $\hat{d} = 3,26$) não é significativo ($p = 0,109$), indicando que **não** há evidência de que o heterozigoto Aa se desvia do ponto médio dos homozigotos.

O modelo explica cerca de 20% da variância total de Y ($R^2 = 0,203$).

1.1.3 Diagnóstico dos resíduos (Caso 1)

```
par(mfrow = c(2,2))
plot(fit1_ad)
```



```
par(mfrow = c(1,1))
shapiro.test(fit1_ad$residuals)
```

```
##
## Shapiro-Wilk normality test
##
## data: fit1_ad$residuals
## W = 0.99764, p-value = 0.9466
```

```
bartlett.test(Y ~ SNP, data = dat1)
```

```
##
## Bartlett test of homogeneity of variances
##
## data: Y by SNP
## Bartlett's K-squared = 0.42151, df = 2, p-value = 0.81
```

Discussão dos gráficos de diagnóstico

Residuals vs Fitted: dispersão vertical nas três colunas parece similar, e a linha vermelha está praticamente horizontal. Aleatoriedade OK.

Q-Q Residuals: pontos muito bem aderidos à diagonal. Normalidade bem satisfeita.

Sale-Location: Dispersão bem uniforme, linha vermelha praticamente horizontal, homocedasticidade bem satisfeita. As três observações rotuladas são outliers, nada alarmante.

Residuals vs Leverage: As observações do genótipo AA concentram-se à direita ($\sim 0,033$), com maior leverage que os demais genótipos — esperado dado sua menor frequência amostral sob Hardy-Weinberg ($p=0,3$, $\sim 9\%$ de AA). Ainda assim, a linha de Cook aparece colapsada na borda esquerda do gráfico, indicando que nenhuma observação exerce influência desproporcional sobre os coeficientes. O modelo é estável.


Testes de diagnóstico: O teste de Shapiro-Wilk **não rejeita** a normalidade dos resíduos ($W = 0,998$; $p = 0,947$), e o teste de Bartlett **não rejeita** a homogeneidade de variâncias entre os três genótipos ($K^2 = 0,42$; $gl = 2$; $p = 0,810$). Ambos os resultados confirmam que as suposições do modelo linear são satisfeitas, em concordância com o diagnóstico visual dos gráficos.

1.1.4 Comparações múltiplas de Tukey

```
fit1_aov <- aov(Y ~ SNP, data = dat1)
TukeyHSD(fit1_aov)

## Tukey multiple comparisons of means
## 95% family-wise confidence level
##
## Fit: aov(formula = Y ~ SNP, data = dat1)
##
## $SNP
##          diff          lwr          upr          p adj
## Aa-aa 13.252910  8.9553676 17.55045 0.0000000
## AA-aa 19.980122 12.8273273 27.13292 0.0000000
## AA-Aa  6.727211 -0.5437059 13.99813 0.0763967

par(mar=c(5,8,4,2))
plot(TukeyHSD(fit1_aov))
```



Comparações múltiplas de Tukey: O teste de Tukey HSD compara os três genótipos par a par com controle da taxa de erro familiar a 5%. Aa–aa (diff = 13,25; $p < 0,001$) e AA–aa (diff = 19,98; $p < 0,001$) são ambos significativos, confirmando que cada alelo A adicional eleva a média de Y — resultado coerente com o efeito aditivo significativo estimado no modelo anterior ($\hat{a} \approx 10$). O contraste AA–Aa (diff = 6,73; $p = 0,076$), no entanto, não atinge significância, com IC 95% que inclui o zero (−0,54; 13,99), como também é visível no gráfico.

Esse resultado é consistente com a não-significância do efeito de dominância.

1.2 Caso 2 – ANOVA Fatorial 3×3 (dois SNPs, efeitos aditivo, dominância e epistasia)

```
set.seed(8732)
n_cell <- 50 # por célula (genótipo conjunto)

# SNP1 e SNP2 gerados independentemente (HWE, p1=0.3, p2=0.4)
p1 <- 0.3; p2 <- 0.4
freq1 <- c((1-p1)^2, 2*p1*(1-p1), p1^2)
freq2 <- c((1-p2)^2, 2*p2*(1-p2), p2^2)

snp1 <- sample(0:2, n_cell*9, replace=TRUE, prob=freq1)
snp2 <- sample(0:2, n_cell*9, replace=TRUE, prob=freq2)

# Estrutura de médias com epistasia (interação a1*a2)
# mu_base + a1_efeito + a2_efeito + interacao
a1 <- 8; d1 <- 4; a2 <- 6; d2 <- 3
```

```

xa1 <- snp1 - 1      # -1, 0, 1
xd1 <- ifelse(snp1==1, 1, 0) # 0, 1, 0
xa2 <- snp2 - 1
xd2 <- ifelse(snp2==1, 1, 0)

# Modelo com efeitos e interações
mu2 <- 100 + a1*xa1 + d1*xd1 + a2*xa2 + d2*xd2 +
      3*xa1*xa2 + 1.5*xa1*xd2 + 1.5*xd1*xa2 + 1*xd1*xd2

Y2 <- rnorm(length(mu2), mean = mu2, sd = 12)

dat2 <- data.frame(
  Y = Y2,
  SNP1 = factor(snp1, labels = c("a1a1", "a1A1", "A1A1")),
  SNP2 = factor(snp2, labels = c("a2a2", "a2A2", "A2A2")),
  xa1 = xa1, xd1 = xd1, xa2 = xa2, xd2 = xd2
)

# Estatísticas descritivas
cat("Dimensões do dataset (Caso 2):", nrow(dat2), "observações\n")

## Dimensões do dataset (Caso 2): 450 observações

tapply(dat2$Y, list(dat2$SNP1, dat2$SNP2), mean) |>
  round(2) |>
  knitr::kable(caption = "Médias de Y por combinação genotípica (Caso 2)")

```

Table 2: Médias de Y por combinação genotípica (Caso 2)


	a2a2	a2A2	A2A2
a1a1	89.48	96.03	96.04
a1A1	94.37	109.66	110.44
A1A1	97.95	107.98	115.01

```

with(dat2,
  interaction.plot(SNP2, SNP1, Y, col = 1:3,
    main = "Perfil de Médias - Caso 2 (Epistasia)",
    xlab = "Genótipo SNP2", ylab = "Média Y",
    lwd = 2, pch = 19, type = "b"))

```


Perfil de Médias – Caso 2 (Epistasia)



O perfil de médias evidencia epistasia entre SNP1 e SNP2: o efeito de cada SNP sobre Y depende do genótipo do outro. Quanto mais alelos A1 o indivíduo carrega, maior o ganho em Y proporcionado pelos alelos A2 — padrão consistente com a epistasia aditiva $\times$ aditiva ($a_1 \times a_2 = 3$) simulada no modelo verdadeiro.

1.2.1 Modelo com efeitos aditivos, dominância e interações (8 g.l.)

```
# Parametrização explícita: xa1, xd1, xa2, xd2 e 4 termos de interação
fit2_completo <- lm(Y ~ xa1 + xd1 + xa2 + xd2 +
  xa1:xa2 + xa1:xd2 + xd1:xa2 + xd1:xd2,
  data = dat2)
summary(fit2_completo)
```

```
##
## Call:
## lm(formula = Y ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xa1:xd2 +
##     xd1:xa2 + xd1:xd2, data = dat2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -30.996  -8.708   0.486   8.204  36.778
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   99.6183     1.6941  58.803 < 2e-16 ***
## xa1             6.8594     1.6941   4.049 6.08e-05 ***
## xd1             2.7875     2.1860   1.275 0.202928
## xa2             5.9072     1.6941   3.487 0.000538 ***
```

```
## xd2          2.3858      2.3409      1.019 0.308666
## xa1:xa2       2.6254      1.6941      1.550 0.121918
## xa1:xd2      -0.8845      2.3409     -0.378 0.705713
## xd1:xa2       2.1274      2.1860      0.973 0.330986
## xd1:xd2       4.8708      2.9884      1.630 0.103837
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 12.67 on 441 degrees of freedom
## Multiple R-squared:  0.2792, Adjusted R-squared:  0.2662
## F-statistic: 21.36 on 8 and 441 DF,  p-value: < 2.2e-16
```

```
anova(fit2_completo)
```

```
## Analysis of Variance Table
##
## Response: Y
##          Df Sum Sq Mean Sq F value    Pr(>F)
## xa1         1  10648  10648.0  66.3807 3.867e-15 ***
## xd1         1   3617   3617.0  22.5484 2.775e-06 ***
## xa2         1   8703   8702.8  54.2543 8.732e-13 ***
## xd2         1   2554   2553.7  15.9198 7.737e-05 ***
## xa1:xa2      1    1021   1021.3    6.3670  0.01198 *
## xa1:xd2      1     31     31.3    0.1954  0.65865
## xd1:xa2      1    404    404.2    2.5201  0.11312
## xd1:xd2      1    426    426.1    2.6566  0.10384
## Residuals 441  70740    160.4
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Interpretação:

- **xa1** e **xa2**: efeitos aditivos dos SNP1 e SNP2, respectivamente.
- **xd1** e **xd2**: desvios de dominância de cada SNP.
- **xa1:xa2** ($a_1 \times a_2$): **epistasia aditiva** $\times$ **aditiva** – interação entre os efeitos aditivos.
- **xa1:xd2** ($a_1 \times d_2$), **xd1:xa2** ($d_1 \times a_2$): epistasias mistas.
- **xd1:xd2** ($d_1 \times d_2$): epistasia dominância $\times$ dominância.


O modelo explica 27,9% da variância de Y ($R^2 = 0,279$) e é globalmente significativo ($F = 21,36$; $p < 0,001$). O erro padrão residual ($\sim 12,67$) está próximo do valor verdadeiro simulado ($\sigma = 12$), indicando bom ajuste.

Efeitos principais: os efeitos aditivos de ambos os SNPs são significativos — **xa1** ($\hat{a}_1 = 6,86$; $p < 0,001$) e **xa2** ($\hat{a}_2 = 5,91$; $p < 0,001$) — indicando que cada alelo A adicional em cada loco eleva Y independentemente, próximo aos valores verdadeiros simulados ($a_1 = 8$, $a_2 = 6$). Os efeitos de dominância **xd1** e **xd2** não são significativos pelo summary ($p = 0,203$ e $p = 0,309$), porém na tabela ANOVA sequencial ambos aparecem significativos ($p < 0,001$ e $p < 0,001$) — discrepância explicada pela ordem de entrada dos termos na ANOVA Tipo I e pela correlação entre os preditores (ANOVA: **xd1** $p = 2,8 \times 10^{-6}$; **xd2** $p < 0,001$).

Epistasia: apenas a interação aditiva $\times$ aditiva **xa1:xa2** é significativa na tabela ANOVA ($F = 6,37$; $p = 0,012$), coerente com o maior coeficiente de epistasia simulado ($a_1 \times a_2 = 3$). As demais interações — **xa1:xd2**, **xd1:xa2** e **xd1:xd2** — não atingem significância, embora seus valores verdadeiros simulados fossem pequenos (1,5; 1,5 e 1,0), o que explica a dificuldade de detecção com este tamanho amostral.

Em conjunto, os resultados confirmam que o fenótipo Y é influenciado pelos efeitos aditivos de dois locos e por sua interação epistática aditiva×aditiva, padrão visualmente antecipado pelo não-paralelismo das linhas no perfil de médias.

```
par(mfrow = c(2,2)); plot(fit2_completo); par(mfrow = c(1,1))
```



```
shapiro.test(fit2_completo$residuals)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  fit2_completo$residuals
## W = 0.99572, p-value = 0.2586
```

Diagnóstico dos resíduos – Caso 2:

Residuals vs Fitted: os pontos distribuem-se em colunas verticais correspondentes às 9 combinações genóticas (células do fatorial 3×3), padrão esperado com preditores discretos. A linha vermelha é aproximadamente horizontal em 0, sem curvatura sistemática, indicando que o modelo linear é adequado.

Q-Q Residuals: excelente aderência à diagonal em toda a extensão central, com desvios pequenos nas caudas (observações 406, 285, 75). A normalidade dos resíduos é confirmada formalmente pelo teste de Shapiro-Wilk ($W = 0,996$; $p = 0,259$), que não rejeita H .

Scale-Location: a linha vermelha apresenta leve curvatura — sobe levemente no centro e cai nas extremidades — sugerindo uma discreta heterocedasticidade entre as células genotípicas. Não é grave, mas vale notar que células com genótipos menos frequentes (como A1A1_A2A2, de baixa probabilidade sob HWE) podem ter variâncias amostrais menos estáveis.

Residuals vs Leverage: os pontos se distribuem em faixas de leverage distintas, refletindo as diferentes frequências das 9 células genotípicas — células raras (como A1A1 com $p1=0,3$) têm maior leverage, chegando a $\sim 0,20$ (ponto 16). Ainda assim, a linha de Cook permanece colapsada na borda inferior do gráfico, indicando que nenhuma observação exerce influência desproporcional sobre os coeficientes.

2 Delineamento Fatorial 3×2 : SNP $\times$ Subgrupo Populacional

2.1 Simulação dos dados (P1, P2, P3)

```
set.seed(8732)
n_rep <- 30 # réplicas por célula
sigma <- 10 # desvio padrão dentro de célula (mmHg)

# Médias de pressão arterial sistólica (mmHg) por genótipo e sexo
# Subgrupo A = feminino, B = masculino (homens ~10 mmHg mais altos)
medias_pop <- list(
  P1 = matrix(c(118,118,118, 128,128,128), nrow=2, byrow=TRUE,
    dimnames=list(c("A","B"), c("aa","Aa","AA"))),
  P2 = matrix(c(113,118,128, 120,128,138), nrow=2, byrow=TRUE,
    dimnames=list(c("A","B"), c("aa","Aa","AA"))),
  P3 = matrix(c(113,118,123, 113,123,138), nrow=2, byrow=TRUE,
    dimnames=list(c("A","B"), c("aa","Aa","AA")))
)

# Gerar dados para cada população
gerar_pop <- function(mmat, n, sigma, pop_nome) {
  rows <- list()
  for (grp in rownames(mmat)) {
    for (geno in colnames(mmat)) {
      y <- rnorm(n, mean = mmat[grp, geno], sd = sigma)
      rows[[length(rows)+1]] <- data.frame(
        Y = y, Grupo = grp, Genotipo = geno,
        Geno_num = match(geno, c("aa","Aa","AA")) - 1,
        Pop = pop_nome
      )
    }
  }
  do.call(rbind, rows)
}

dat_P1 <- gerar_pop(medias_pop$P1, n_rep, sigma, "P1")
dat_P2 <- gerar_pop(medias_pop$P2, n_rep, sigma, "P2")
dat_P3 <- gerar_pop(medias_pop$P3, n_rep, sigma, "P3")
```

```
# Ordenar fatores
for (d in list(dat_P1, dat_P2, dat_P3)) {
  d$Genotipo <- factor(d$Genotipo, levels = c("aa", "Aa", "AA"))
}
dat_P1$Genotipo <- factor(dat_P1$Genotipo, levels=c("aa", "Aa", "AA"))
dat_P2$Genotipo <- factor(dat_P2$Genotipo, levels=c("aa", "Aa", "AA"))
dat_P3$Genotipo <- factor(dat_P3$Genotipo, levels=c("aa", "Aa", "AA"))
```

Contextualização (item b): Os dados simulam medições de pressão arterial sistólica (mmHg) em indivíduos de três populações (P1, P2, P3), classificados segundo o genótipo de um SNP (aa, Aa, AA) e o sexo (A = feminino, B = masculino). Adotou-se $n = 30$ réplicas por célula e $\sigma = 10$ mmHg. As três populações representam cenários distintos: **P1** sem efeito do SNP (apenas efeito de sexo, com homens ~10 mmHg acima das mulheres); **P2** com efeito aditivo do SNP e perfis paralelos entre sexos; e **P3** com interação SNP×sexo, onde o efeito do SNP é modesto em mulheres (+10 mmHg de aa→AA) mas acentuado em homens (+25 mmHg).

2.2 Análise por População

2.2.1 Função auxiliar para análise completa

```
analisa_pop <- function(dat, nome_pop) {
  cat("\n\n===== \n")
  cat(" POPULAÇÃO:", nome_pop, "\n")
  cat("===== \n\n")

  # (i) Estatísticas descritivas
  cat("--- (i) Estatísticas Descritivas --- \n")
  desc <- describeBy(dat$Y, group = list(dat$Grupo, dat$Genotipo), mat=TRUE)
  print(knitr::kable(desc[, c("group1", "group2", "n", "mean", "sd", "median")],
    digits=2, caption=paste("Descritivas -", nome_pop)))

  # (ii) Perfil de médias
  par(mfrow=c(1,2))
  with(dat,
    interaction.plot(Genotipo, Grupo, Y,
      col=c("red", "blue"), lwd=2, pch=19, type="b",
      main=paste("Perfil de Médias -", nome_pop),
      xlab="Genótipo SNP", ylab="Média Y"))

  # Boxplot
  boxplot(Y ~ Grupo:Genotipo, data=dat, col=c("lightcoral", "lightblue"),
    main=paste("Boxplot -", nome_pop),
    xlab="Grupo:Genótipo", ylab="Y", las=2, cex.axis=0.7)
  par(mfrow=c(1,1))

  # (iii) ANOVA Fatorial 3x2 - fator categórico
  cat("\n--- (iii) ANOVA Fatorial 3x2 (Genotipo categórico) --- \n")
  fit_cat <- aov(Y ~ Grupo * Genotipo, data=dat)
  print(summary(fit_cat))
```

```

cat("\nCoeficientes:\n")
print(coef(fit_cat))

# Diagnóstico resíduos
par(mfrow=c(2,2)); plot(fit_cat); par(mfrow=c(1,1))
cat("\nShapiro-Wilk (normalidade resíduos):\n")
print(shapiro.test(fit_cat$residuals))
cat("Bartlett (homocedasticidade):\n")
print(bartlett.test(Y ~ interaction(Grupo, Genotipo), data=dat))

# Tukey
cat("\nComparações múltiplas de Tukey:\n")
tk <- TukeyHSD(fit_cat)
print(tk)
plot(tk, las=1, cex.axis=0.6)

# (iv) SNP como variável quantitativa (1 g.l. - efeito linear)
cat("\n--- (iv) SNP como variável quantitativa (efeito aditivo linear) ---\n")
fit_num <- lm(Y ~ Grupo * Geno_num, data=dat)
print(summary(fit_num))
print(anova(fit_num))

invisible(list(fit_cat=fit_cat, fit_num=fit_num))
}

```



2.2.2 P1 – Sem efeito de SNP, sem interação

```





res_P1 <- analisa_pop(dat_P1, "P1")

##
##
## =====
## POPULAÇÃO: P1
## =====
##
## --- (i) Estatísticas Descritivas ---
##
##
## Table: Descritivas - P1
##
## |      |group1 |group2 |  n| mean|  sd| median|
## |:----|:-----|:-----|--:|----:|----:|-----:|
## |X1*1 |A      |aa      | 30| 15.5| 8.8| 15.5|
## |X1*2 |B      |aa      | 30| 15.5| 8.8| 15.5|
## |X1*3 |A      |Aa      | 30| 15.5| 8.8| 15.5|
## |X1*4 |B      |Aa      | 30| 15.5| 8.8| 15.5|
## |X1*5 |A      |AA      | 30| 15.5| 8.8| 15.5|
## |X1*6 |B      |AA      | 30| 15.5| 8.8| 15.5|

```



```
##
## --- (iii) ANOVA Fatorial 3x2 (Genótipo categórico) ---
##               Df Sum Sq Mean Sq F value    Pr(>F)
## Grupo         1    5941    5941  64.053 1.65e-13 ***
## Genótipo       2     51      25   0.273   0.761
## Grupo:Genótipo 2     52      26   0.281   0.755
## Residuals    174   16138      93
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Coeficientes:
##      (Intercept)          GrupoB      GenótipoAa      GenótipoAA  GrupoB:GenótipoAa  GrupoB:GenótipoAA
##      117.94040030      10.69614515     -1.27480397     -1.21137796      2.31650844      0.00000000
```




```
##
## Shapiro-Wilk (normalidade resíduos):
##
## Shapiro-Wilk normality test
##
## data: fit_cat$residuals
## W = 0.99448, p-value = 0.7439
##
## Bartlett (homocedasticidade):
##
## Bartlett test of homogeneity of variances
##
## data: Y by interaction(Grupo, Genotipo)
## Bartlett's K-squared = 10.56, df = 5, p-value = 0.06083
##
##
## Comparações múltiplas de Tukey:
## Tukey multiple comparisons of means
## 95% family-wise confidence level
##
## Fit: aov(formula = Y ~ Grupo * Genotipo, data = dat)
##
## $Grupo
##      diff      lwr      upr p adj
## B-A 11.48984 8.656334 14.32335 0
```




```
##
## $Genotipo
##      diff      lwr      upr      p adj
## Aa-aa -0.1165497 -4.273051 4.039952 0.9975806
## AA-aa -1.1790864 -5.335588 2.977415 0.7808776
## AA-Aa -1.0625367 -5.219038 3.093965 0.8179569
##
## $`Grupo:Genotipo`
##      diff      lwr      upr      p adj
## B:aa-A:aa 10.69614515  3.530404 17.861886 0.0004009
## A:Aa-A:aa -1.27480397 -8.440545  5.890937 0.9956337
## B:Aa-A:aa 11.73784963  4.572109 18.903591 0.0000700
## A:AA-A:aa -1.21137796 -8.377119  5.954363 0.9965684
## B:AA-A:aa  9.54935026  2.383609 16.715091 0.0023411
## A:Aa-B:aa -11.97094912 -19.136690 -4.805208 0.0000466
## B:Aa-B:aa  1.04170448 -6.124037  8.207445 0.9983292
## A:AA-B:aa -11.90752311 -19.073264 -4.741782 0.0000521
## B:AA-B:aa -1.14679490 -8.312536  6.018946 0.9973543
## B:Aa-A:AA 13.01265360  5.846913 20.178395 0.0000070
## A:AA-A:AA  0.06342601 -7.102315  7.229167 1.0000000
## B:AA-A:AA 10.82415422  3.658413 17.989895 0.0003258
## A:AA-B:AA -12.94922759 -20.114969 -5.783487 0.0000079
## B:AA-B:AA -2.18849938 -9.354240  4.977242 0.9508273
## B:AA-A:AA 10.76072822  3.594987 17.926469 0.0003611
```


95% family-wise confidence level



95% family-wise confidence level



95% family-wise confidence level



Differences in mean levels of Grupo:Genotipo

```
##
## --- (iv) SNP como variável quantitativa (efeito aditivo linear) ---
##
## Call:
## lm(formula = Y ~ Grupo * Geno_num, data = dat)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -23.9410  -6.6182   0.0927   6.3599  27.1516
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    117.71736     1.59897   73.621 < 2e-16 ***
## GrupoB          11.45755     2.26128    5.067 1.02e-06 ***
## Geno_num        -0.60569     1.23855   -0.489   0.625
## GrupoB:Geno_num  0.03229     1.75158    0.018   0.985
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 9.594 on 176 degrees of freedom
## Multiple R-squared:  0.2697, Adjusted R-squared:  0.2573
## F-statistic: 21.67 on 3 and 176 DF,  p-value: 5.45e-12
##
## Analysis of Variance Table
##
```

```
## Response: Y
##               Df Sum Sq Mean Sq F value    Pr(>F)
## Grupo         1  5940.7   5940.7  64.5445 1.311e-13 ***
## Geno_num       1    41.7    41.7   0.4531   0.5017
## Grupo:Geno_num 1     0.0     0.0   0.0003   0.9853
## Residuals     176 16199.2    92.0
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Interpretação P1:

Perfil de médias e boxplot: as linhas do perfil de médias oscilam levemente entre genótipos — a linha masculina sobe de aa para Aa e recua em AA, enquanto a feminina desce ligeiramente — mas essas variações refletem apenas flutuação amostral em torno das médias verdadeiras (118 mmHg em A, 128 mmHg em B para todos os genótipos). A separação vertical entre os sexos é consistente e visualmente dominante. O boxplot corrobora: as distribuições dentro de cada sexo são similares entre genótipos, com dispersão compatível com $\sigma = 10$ mmHg.

ANOVA: apenas o efeito de Grupo é significativo ($F = 64,05$; $p < 0,001$), estimando uma diferença de $\sim 10,7$ mmHg entre homens e mulheres. Os efeitos de Genótipo ($F = 0,27$; $p = 0,761$) e da interação Grupo $\times$ Genótipo ($F = 0,28$; $p = 0,755$) são não significativos, como esperado pela estrutura simulada.

Diagnóstico: normalidade (Shapiro-Wilk: $W = 0,994$; $p = 0,744$) e homocedasticidade (Bartlett: $K^2 = 10,56$; $p = 0,061$) satisfeitas. O gráfico “Constant Leverage: Residuals vs Factor Levels” — que substitui o Residuals vs Leverage em modelos `aov` com delineamento balanceado — mostra resíduos uniformemente distribuídos entre os níveis de Grupo, sem padrões preocupantes.



Tukey: o contraste B–A é significativo ($\sim 11,5$ mmHg; $p < 0,001$). Todos os contrastes entre genótipos (Aa–aa, AA–aa, AA–Aa) incluem o zero nos ICs e têm $p > 0,75$, confirmando ausência de efeito do SNP. No Tukey da interação Grupo:Genótipo, os únicos contrastes significativos são aqueles que comparam grupos de sexos opostos (ex.: B:aa–A:aa, B:Aa–A:Aa), ou seja, toda a significância se deve ao efeito de sexo, não ao SNP.

SNP quantitativo (item iv): o modelo com `Geno_num` confirma: coeficiente do SNP não significativo ($-0,61$; $p = 0,625$) e interação Grupo $\times$ Geno_num também não significativa ($p = 0,985$). O ajuste é equivalente ao modelo categórico, com $R^2 = 0,270$ explicado quase integralmente pelo efeito de sexo. `### P2 – Efeito aditivo de SNP, sem interação (perfis paralelos)`





```
res_P2 <- analisa_pop(dat_P2, "P2")
```

```
##
##
## =====
## POPULAÇÃO: P2
## =====
##
## --- (i) Estatísticas Descritivas ---
##
##
## Table: Descritivas - P2
##
## |      |group1 |group2 |  n| mean|  sd| median|
## |:----|:-----|:-----|--:|----:|----:|-----:|
## |X1*1 |A      |aa      | 30| 15.5| 8.8|   15.5|
## |X1*2 |B      |aa      | 30| 15.5| 8.8|   15.5|
```

##	X1*3	A	Aa		30	15.5	8.8	15.5
##	X1*4	B	Aa		30	15.5	8.8	15.5
##	X1*5	A	AA		30	15.5	8.8	15.5
##	X1*6	B	AA		30	15.5	8.8	15.5




##							
##	--- (iii) ANOVA Fatorial 3x2 (Genotipo categórico) ---						
##		Df	Sum Sq	Mean Sq	F value	Pr(>F)	
##	Grupo	1	3901	3901	37.84	5.13e-09 ***	
##	Genotipo	2	11044	5522	53.57	< 2e-16 ***	
##	Grupo:Genotipo	2	214	107	1.04	0.356	
##	Residuals	174	17938	103			
##	---						
##	Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1						
##							
##	Coeficientes:						
##	(Intercept)	GrupoB	GenotipoAa	GenotipoAA	GrupoB:GenotipoAa	GrupoB:Gen	
##	111.786102	7.095447	5.919372	16.319137	1.459842	5	




```
##
## Shapiro-Wilk (normalidade resíduos):
##
##  Shapiro-Wilk normality test
##
## data:  fit_cat$residuals
## W = 0.9929, p-value = 0.5306
##
## Bartlett (homocedasticidade):
##
##  Bartlett test of homogeneity of variances
##
## data:  Y by interaction(Grupo, Genotipo)
## Bartlett's K-squared = 1.8307, df = 5, p-value = 0.872
##
##
## Comparações múltiplas de Tukey:
##  Tukey multiple comparisons of means
##    95% family-wise confidence level
##
## Fit: aov(formula = Y ~ Grupo * Genotipo, data = dat)
##
## $Grupo
##      diff      lwr      upr p adj
## B-A 9.310298 6.322963 12.29763    0
```

```
##
## $Genotipo
##      diff      lwr      upr      p adj
## Aa-aa  6.649293  2.267141 11.03144 0.0012582
## AA-aa 18.911494 14.529342 23.29365 0.0000000
## AA-Aa 12.262201  7.880049 16.64435 0.0000000
##
## $`Grupo:Genotipo`
##      diff      lwr      upr      p adj
## B:aa-A:aa  7.095447 -0.4593121 14.650206 0.0790743
## A:Aa-A:aa  5.919372 -1.6353873 13.474130 0.2172305
## B:Aa-A:aa 14.474660  6.9199015 22.029419 0.0000018
## A:AA-A:aa 16.319137  8.7643783 23.873896 0.0000001
## B:AA-A:aa 28.599297 21.0445377 36.154056 0.0000000
## A:Aa-B:aa -1.176075 -8.7308341  6.378684 0.9976811
## B:Aa-B:aa  7.379214 -0.1755453 14.933972 0.0598136
## A:AA-B:aa  9.223690  1.6689315 16.778449 0.0072154
## B:AA-B:aa 21.503850 13.9490909 29.058609 0.0000000
## B:Aa-A:AA  8.555289  1.0005299 16.110048 0.0164442
## A:AA-A:AA 10.399766  2.8450067 17.954525 0.0014671
## B:AA-A:AA 22.679925 15.1251661 30.234684 0.0000000
## A:AA-B:AA  1.844477 -5.7102821  9.399236 0.9813130
## B:AA-B:AA 14.124636  6.5698773 21.679395 0.0000034
## B:AA-A:AA 12.280159  4.7254005 19.834918 0.0000818
```

95% family-wise confidence level




95% family-wise confidence level



Differences in mean levels of Genotipo

95% family-wise confidence level



Differences in mean levels of Grupo:Genotipo

```
##
## --- (iv) SNP como variável quantitativa (efeito aditivo linear) ---
##
## Call:
## lm(formula = Y ~ Grupo * Geno_num, data = dat)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -27.0801  -6.8622   0.0347   5.9448  31.2345
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    111.039     1.698  65.398 < 2e-16 ***
## GrupoB           6.718     2.401   2.798  0.00572 **
## Geno_num         8.160     1.315   6.204 3.82e-09 ***
## GrupoB:Geno_num  2.592     1.860   1.394  0.16514
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 10.19 on 176 degrees of freedom
## Multiple R-squared:  0.4481, Adjusted R-squared:  0.4387
## F-statistic: 47.64 on 3 and 176 DF, p-value: < 2.2e-16
##
## Analysis of Variance Table
##
```

```
## Response: Y
##              Df Sum Sq Mean Sq F value    Pr(>F)
## Grupo        1  3900.7   3900.7   37.5850 5.597e-09 ***
## Geno_num      1 10729.3  10729.3  103.3827 < 2.2e-16 ***
## Grupo:Geno_num 1   201.6    201.6    1.9426  0.1651
## Residuals    176 18265.8    103.8
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```


Interpretação P2: As médias crescem com o número de alelos A em ambos os subgrupos, com perfis aproximadamente paralelos. Espera-se **efeito de Genotipo significativo** (efeito aditivo do SNP) e **efeito de Grupo**, mas **sem interação significativa** (perfis paralelos indicam ausência de interação).

2.2.3 P3 – Efeito de SNP com interação (epistasia SNP × Subgrupo)


```
res_P3 <- analisa_pop(dat_P3, "P3")
```

```
##
##
## =====
## POPULAÇÃO: P3
## =====
##
## --- (i) Estatísticas Descritivas ---
##
##
## Table: Descritivas - P3
##
## |      |group1 |group2 |  n| mean|  sd| median|
## |:----|:-----|:-----|--:|----:|----:|-----:|
## |X1*1 |A      |aa      | 30| 15.5| 8.8|  15.5|
## |X1*2 |B      |aa      | 30| 15.5| 8.8|  15.5|
## |X1*3 |A      |Aa      | 30| 15.5| 8.8|  15.5|
## |X1*4 |B      |Aa      | 30| 15.5| 8.8|  15.5|
## |X1*5 |A      |AA      | 30| 15.5| 8.8|  15.5|
## |X1*6 |B      |AA      | 30| 15.5| 8.8|  15.5|
```





Perfil de Médias – P3



Boxplot – P3




```
##
## --- (iii) ANOVA Fatorial 3x2 (Genotipo categórico) ---
##               Df Sum Sq Mean Sq F value    Pr(>F)
## Grupo          1   1883    1883  16.989 5.81e-05 ***
## Genotipo        2   9088    4544  40.992 2.59e-15 ***
## Grupo:Genotipo  2   1961     980   8.845 0.00022 ***
## Residuals      174  19289     111
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Coeficientes:
##      (Intercept)          GrupoB      GenotipoAa      GenotipoAA  GrupoB:GenotipoAa  GrupoB:Geno
##      114.542742         -1.047054         2.096983         8.980921         6.479454         16
```




```
##
## Shapiro-Wilk (normalidade resíduos):
##
## Shapiro-Wilk normality test
##
## data: fit_cat$residuals
## W = 0.99501, p-value = 0.8113
##
## Bartlett (homocedasticidade):
##
## Bartlett test of homogeneity of variances
##
## data: Y by interaction(Grupo, Genotipo)
## Bartlett's K-squared = 3.6449, df = 5, p-value = 0.6016
##
##
## Comparações múltiplas de Tukey:
## Tukey multiple comparisons of means
## 95% family-wise confidence level
##
## Fit: aov(formula = Y ~ Grupo * Genotipo, data = dat)
##
## $Grupo
##      diff      lwr      upr    p adj
## B-A 6.469338 3.371553 9.567122 5.81e-05
```

```
##
## $Genotipo
##      diff      lwr      upr      p adj
## Aa-aa  5.33671  0.7925384  9.880881 0.0167176
## AA-aa 17.01578 12.4716111 21.559953 0.0000000
## AA-Aa 11.67907  7.1349015 16.223244 0.0000000
##
## $`Grupo:Genotipo`
##      diff      lwr      upr      p adj
## B:aa-A:aa -1.047054 -8.8811316  6.787023 0.9988855
## A:Aa-A:aa  2.096983 -5.7370947  9.931060 0.9719752
## B:Aa-A:aa  7.529382 -0.3046951 15.363460 0.0673023
## A:AA-A:aa  8.980921  1.1468439 16.814999 0.0145007
## B:AA-A:aa 24.003589 16.1695117 31.837666 0.0000000
## A:Aa-B:aa  3.144037 -4.6900405 10.978114 0.8566419
## B:Aa-B:aa  8.576437  0.7423592 16.410514 0.0229101
## A:AA-B:aa 10.027976  2.1938982 17.862053 0.0040226
## B:AA-B:aa 25.050643 17.2165659 32.884721 0.0000000
## B:Aa-A:AA  5.432400 -2.4016778 13.266477 0.3475257
## A:AA-A:AA  6.883939 -0.9501388 14.718016 0.1205082
## B:AA-A:AA 21.906606 14.0725290 29.740684 0.0000000
## A:AA-B:AA  1.451539 -6.3825384  9.285616 0.9947156
## B:AA-B:AA 16.474207  8.6401294 24.308284 0.0000001
## B:AA-A:AA 15.022668  7.1885904 22.856745 0.0000017
```


95% family-wise confidence level



95% family-wise confidence level



95% family-wise confidence level



Differences in mean levels of Grupo:Genotipo

```
##
## --- (iv) SNP como variável quantitativa (efeito aditivo linear) ---
##
## Call:
## lm(formula = Y ~ Grupo * Geno_num, data = dat)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -28.2883  -6.2066  -0.5178   7.5351  28.2131
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    113.745     1.764   64.482 < 2e-16 ***
## GrupoB         -1.566     2.495  -0.628  0.53111
## Geno_num        4.490     1.366   3.286  0.00122 **
## GrupoB:Geno_num  8.035     1.932   4.158 5.01e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 10.58 on 176 degrees of freedom
## Multiple R-squared:  0.3881, Adjusted R-squared:  0.3777
## F-statistic: 37.21 on 3 and 176 DF, p-value: < 2.2e-16
##
## Analysis of Variance Table
##
```

```
## Response: Y
##               Df Sum Sq Mean Sq F value    Pr(>F)
## Grupo          1  1883.4   1883.4   16.813 6.293e-05 ***
## Geno_num       1  8686.1   8686.1   77.542 1.200e-15 ***
## Grupo:Geno_num  1  1936.8   1936.8   17.290 5.006e-05 ***
## Residuals     176 19715.3    112.0
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Interpretação P3: No subgrupo A, o efeito do SNP é pequeno (75→80→85); no subgrupo B, o efeito é maior (75→85→100). As diferenças entre AA e aa são distintas nos subgrupos (A: +10; B: +25), indicando **interação Genotipo×Grupo**. O perfil de médias deve mostrar linhas não paralelas.

2.3 Item (d) – Combinando as três populações

2.3.1 (d.i) – Fatorial 3×2×3: SNP × Grupo × População (todos fixos)


```
dat_all <- rbind(dat_P1, dat_P2, dat_P3)
dat_all$Pop <- factor(dat_all$Pop)

# Modelo completo 3x2x3
fit_fixo <- aov(Y ~ Grupo * Genotipo * Pop, data = dat_all)
summary(fit_fixo)
```

```
##               Df Sum Sq Mean Sq F value    Pr(>F)
## Grupo          1  11154   11154 109.109 < 2e-16 ***
## Genotipo        2  12478    6239  61.030 < 2e-16 ***
## Pop             2    516     258   2.524 0.08111 .
## Grupo:Genotipo  2   1137     568   5.560 0.00408 **
## Grupo:Pop       2    570     285   2.790 0.06235 .
## Genotipo:Pop    4   7705    1926  18.842 1.75e-14 ***
## Grupo:Genotipo:Pop 4   1091     273   2.668 0.03168 *
## Residuals     522 53365     102
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
with(dat_all,
      interaction.plot(Genotipo, interaction(Grupo, Pop), Y,
                       main="Perfil Médias: SNP × Grupo × População",
                       xlab="Genótipo", ylab="Média Y",
                       lwd=2, type="b"))
```


Perfil Médias: SNP × Grupo × População



Modelo (d.i): $Y \sim \text{Grupo} * \text{Genotipo} * \text{Pop}$ com todos os efeitos principais (3 fatores) e todas as interações de 2ª e 3ª ordem. A interação tripla **Genotipo:Grupo:Pop** permite verificar se a interação SNP×Subgrupo difere entre populações. Tem $2+1+2+2+2+4+4 = 17$ g.l. de **tratamento** e é útil para testar heterogeneidade de efeito entre populações (relevante em estudos de metanálise genômica).

2.3.2 (d.ii) – Fatorial 3×2 com População como fator aleatório (ANOVA Mista)

```
library(lme4)

# Modelo misto: Population como efeito aleatório (intercepto aleatório por Pop)
fit_misto <- lmer(Y ~ Grupo * Genotipo + (1 | Pop), data = dat_all, REML = TRUE)
summary(fit_misto)

## Linear mixed model fit by REML. t-tests use Satterthwaite's method ['lmerModLmerTest']
## Formula: Y ~ Grupo * Genotipo + (1 | Pop)
## Data: dat_all
##
## REML criterion at convergence: 4091.2
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -2.8127 -0.6360 -0.0499  0.7049  3.2411
##
## Random effects:
## Groups Name Variance Std.Dev.
## Pop (Intercept) 0.7784 0.8823
## Residual 117.9155 10.8589
```

```
## Number of obs: 540, groups:  Pop, 3
##
## Fixed effects:
##              Estimate Std. Error      df t value Pr(>|t|)
## (Intercept)    114.756      1.253   21.165   91.596 < 2e-16 ***
## GrupoB         5.582      1.619  532.000    3.448 0.000609 ***
## GenotipoAa      2.247      1.619  532.000    1.388 0.165650
## GenotipoAA      8.030      1.619  532.000    4.960 9.48e-07 ***
## GrupoB:GenotipoAa  3.419      2.289  532.000    1.493 0.135945
## GrupoB:GenotipoAA  7.106      2.289  532.000    3.104 0.002009 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
##              (Intr) GrupoB  GntpA  GntpAA  GrB:GA
## GrupoB      -0.646
## GenotipoAa  -0.646  0.500
## GenotipoAA  -0.646  0.500  0.500
## GrpB:GntpA   0.457 -0.707 -0.707 -0.354
## GrpB:GntpAA  0.457 -0.707 -0.354 -0.707  0.500
```

```
# Teste dos efeitos fixos
library(lmerTest)
fit_misto2 <- lmer(Y ~ Grupo * Genotipo + (1 | Pop), data = dat_all, REML = FALSE)
anova(fit_misto2)
```

```
## Type III Analysis of Variance Table with Satterthwaite's method
##              Sum Sq Mean Sq NumDF DenDF F value  Pr(>F)
## Grupo        11154.4  11154.4      1    537 95.4854 < 2e-16 ***
## Genotipo      12478.4   6239.2      2    537 53.4097 < 2e-16 ***
## Grupo:Genotipo  1136.8    568.4      2    537  4.8657 0.00805 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Modelo (d.ii): $Y \sim \text{Grupo} * \text{Genotipo} + (1|\text{Pop})$. População é um **efeito aleatório** (ex.: amostras de populações tiradas ao acaso de um universo maior de populações). O intercepto aleatório por Pop captura variabilidade entre populações, e os efeitos fixos de Grupo e Genotipo são estimados controlando essa fonte de variação. As inferências se generalizam a outras populações (não apenas às 3 observadas).

3 Regressão Logística: Y dicotomizada

3.1 Dicotomização de Y

```
# Ponto de corte: mediana global de cada dataset
corte1 <- median(dat1$Y)
corte2 <- median(dat2$Y)
corte_all <- median(dat_all$Y)
```

```

dat1$Ybin <- as.factor(ifelse(dat1$Y > corte1, 1, 0))
dat2$Ybin <- as.factor(ifelse(dat2$Y > corte2, 1, 0))
dat_all$Ybin <- as.factor(ifelse(dat_all$Y > corte_all, 1, 0))

cat("Ponto de corte Q1:", corte1, " | Distribuição:\n"); print(table(dat1$Ybin))

```

```
## Ponto de corte Q1: 107.934 | Distribuição:
```

```
##
##  0  1
## 150 150
```

```
cat("Ponto de corte Q2:", corte2, " | Distribuição:\n"); print(table(dat2$Ybin))
```

```
## Ponto de corte Q2: 99.43729 | Distribuição:
```

```
##
##  0  1
## 225 225
```

3.2 Questão 1 (Caso 1) – Regressão Logística

```

# Modelo logístico com efeitos aditivo e de dominância
fitr11_ad <- glm(Ybin ~ xa + xd, family=binomial(link="logit"), data=dat1)
summary(fitr11_ad)

```

```

##
## Call:
## glm(formula = Ybin ~ xa + xd, family = binomial(link = "logit"),
##      data = dat1)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   0.4367     0.2845   1.535   0.125
## xa            1.3959     0.2845   4.907 9.26e-07 ***
## xd            0.3306     0.3442   0.960   0.337
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 415.89  on 299  degrees of freedom
## Residual deviance: 351.61  on 297  degrees of freedom
## AIC: 357.61
##
## Number of Fisher Scoring iterations: 4

```

```
cat("\nOR estimados (exp(coef)):\n")
```

```
##  
## OR estimados (exp(coef)):
```

```
print(exp(coef(fitr11_ad)))
```

```
## (Intercept)          xa          xd  
##      1.547533      4.038685      1.391793
```

```
cat("\nIC para OR:\n")
```

```
##  
## IC para OR:
```

```
print(exp(confint(fitr11_ad)))
```

```
##              2.5 %   97.5 %  
## (Intercept) 0.9293790 2.915662  
## xa          2.4288894 7.613690  
## xd          0.6731698 2.655131
```

```
# Probabilidades preditas e tabela de classificação  
pred1r <- predict(fitr11_ad, type="response")  
class1r <- ifelse(pred1r >= 0.5, 1, 0)  
cat("Tabela de classificação:\n")
```

```
## Tabela de classificação:
```

```
print(table(Predito=class1r, Observado=dat1$Ybin))
```


```
##      Observado  
## Predito    0    1  
##      0 107  41  
##      1  43 109
```

```
cat("Acurácia:", round(mean(class1r == dat1$Ybin), 3), "\n")
```

```
## Acurácia: 0.72
```

```
plot(0:2, tapply(as.numeric(dat1$Ybin)-1, dat1$snp_num, mean),  
      type="b", pch=19, col="blue", xaxt="n",  
      xlab="Genótipo", ylab="P(Y=1 | Genótipo)",  
      main="Prob. estimadas vs. observadas - Regressão Logística (Q1-C1)")  
axis(1, at=0:2, labels=c("aa", "Aa", "AA"))  
lines(0:2, tapply(pred1r, dat1$snp_num, mean), col="red", lty=2, pch=15, type="b")  
legend("topleft", c("Observado", "Predito"), col=c("blue", "red"), lty=c(1,2), bty="n")
```

Prob. estimadas vs. observadas – Regressão Logística (Q1–C1)



Comparação ANOVA × Logística (Caso 1):

O efeito aditivo (xa) permanece altamente significativo em ambos os modelos. O coeficiente logístico representa a **log-razão de chances** de Y=1 por unidade de aumento em xa. O OR associado ao efeito aditivo indica a chance relativa de fenótipo elevado a cada alelo A adicional.

3.3 Questão 1 (Caso 2) – Regressão Logística com dois SNPs

```
fitrl2 <- glm(Ybin ~ xa1 + xd1 + xa2 + xd2 +
              xa1:xa2 + xa1:xd2 + xd1:xa2 + xd1:xd2,
              family=binomial(link="logit"), data=dat2)
summary(fitrl2)
```

```
##
## Call:
## glm(formula = Ybin ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xa1:xd2 +
##      xd1:xa2 + xd1:xd2, family = binomial(link = "logit"), data = dat2)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   3.322    162.718   0.020   0.984
## xa1           4.370    162.718   0.027   0.979
## xd1          -2.888    162.719  -0.018   0.986
## xa2           4.192    162.718   0.026   0.979
## xd2          -3.100    162.719  -0.019   0.985
## xa1:xa2        3.682    162.718   0.023   0.982
## xa1:xd2       -3.899    162.719  -0.024   0.981
```

```
## xd1:xa2      -2.867    162.719  -0.018    0.986
## xd1:xd2       3.925    162.719   0.024    0.981
##
## (Dispersion parameter for binomial family taken to be 1)
##
## Null deviance: 623.83  on 449  degrees of freedom
## Residual deviance: 515.58  on 441  degrees of freedom
## AIC: 533.58
##
## Number of Fisher Scoring iterations: 14
```

```
cat("\nOR estimados:\n")
```

```
##
## OR estimados:
```

```
print(round(exp(coef(fitr12)), 3))
```

```
## (Intercept)      xa1      xd1      xa2      xd2  xa1:xa2  xa1:xd2  xd1:xa2
##      27.706      79.061      0.056     66.147     0.045     39.738      0.020      0.057
```

```
cat("\nIC para OR:\n")
```

```
##
## IC para OR:
```

```
print(round(exp(confint(fitr12)), 3))
```

```
##              2.5 %      97.5 %
## (Intercept) 0.000000e+00      NA
## xa1         0.000000e+00      NA
## xd1         0.000000e+00 0.000000e+00
## xa2         0.000000e+00      NA
## xd2         0.000000e+00 3.000000e-03
## xa1:xa2     0.000000e+00      NA
## xa1:xd2     0.000000e+00 0.000000e+00
## xd1:xa2     0.000000e+00 0.000000e+00
## xd1:xd2     1.042443e+30 1.011669e+31
```

```
pred2r <- predict(fitr12, type="response")
class2r <- ifelse(pred2r >= 0.5, 1, 0)
cat("Tabela de classificação:\n")
```

```
## Tabela de classificação:
```

```
print(table(Predito=class2r, Observado=dat2$Ybin))
```

```
##      Observado
## Predito    0    1
##      0 191  98
##      1  34 127
```

```
cat("Acurácia:", round(mean(class2r == dat2$Ybin), 3), "\n")
```

```
## Acurácia: 0.707
```

3.4 Questão 2 – Regressão Logística por População

```
logistica_pop <- function(dat, nome) {
  cat("\n\n===== \n")
  cat(" POPULAÇÃO:", nome, "\n===== \n")

  # Codificação aditiva/dominância para SNP
  dat$xa_snp <- dat$Geno_num - 1
  dat$xd_snp <- ifelse(dat$Geno_num==1, 1, 0)
  dat$Grupo_bin <- ifelse(dat$Grupo=="A", 0, 1)

  # Dicotomizar Y
  corte_local <- median(dat$Y)
  dat$Ybin <- as.factor(ifelse(dat$Y > corte_local, 1, 0))

  fit_logit <- glm(Ybin ~ Grupo_bin * (xa_snp + xd_snp),
                  family=binomial(link="logit"), data=dat)
  cat("\nModelo logístico - fator categórico:\n")
  print(summary(fit_logit))
  cat("\nOR estimados:\n")
  print(round(exp(coef(fit_logit)), 3))

  # Prob preditas
  pred_r <- predict(fit_logit, type="response")
  class_r <- ifelse(pred_r >= 0.5, 1, 0)
  cat("\nAcurácia:", round(mean(class_r == dat$Ybin), 3), "\n")

  # Comparação com ANOVA para o mesmo dado
  cat("\n[ANOVA correspondente - para comparação]\n")
  fit_anova <- lm(Y ~ Grupo * Genotipo, data=dat)
  cat("ANOVA p-valor Genotipo:", anova(fit_anova)["Genotipo", "Pr(>F)"], "\n")
  cat("Logístico p-valor xa: ", summary(fit_logit)$coef["xa_snp", "Pr(>|z|)"], "\n")

  invisible(fit_logit)
}

logistica_pop(dat_P1, "P1")
```

```
##
##
## =====
## POPULAÇÃO: P1
## =====
##
```

```
## Modelo logístico - fator categórico:
##
## Call:
## glm(formula = Ybin ~ Grupo_bin * (xa_snp + xd_snp), family = binomial(link = "logit"),
##      data = dat)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -0.9664    0.2966  -3.258  0.00112 **
## Grupo_bin      1.5928    0.4030   3.953  7.72e-05 ***
## xa_snp        -0.4199    0.2966  -1.416  0.15688
## xd_snp         0.2733    0.4878   0.560  0.57535
## Grupo_bin:xa_snp 0.6408    0.4030   1.590  0.11178
## Grupo_bin:xd_snp 0.4866    0.7216   0.674  0.50006
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 249.53  on 179  degrees of freedom
## Residual deviance: 214.70  on 174  degrees of freedom
## AIC: 226.7
##
## Number of Fisher Scoring iterations: 4
##
##
## OR estimados:
##      (Intercept)      Grupo_bin      xa_snp      xd_snp Grupo_bin:xa_snp Grupo_bin:xd_snp
##      0.380          4.918          0.657          1.314          1.898          1.62
##
## Acurácia: 0.7
##
## [ANOVA correspondente - para comparação]
## ANOVA p-valor Genotipo: 0.7613525
## Logístico p-valor xa: 0.1568771
```

```
logistica_pop(dat_P2, "P2")
```

```
##
##
## =====
## POPULAÇÃO: P2
## =====
##
## Modelo logístico - fator categórico:
##
## Call:
## glm(formula = Ybin ~ Grupo_bin * (xa_snp + xd_snp), family = binomial(link = "logit"),
##      data = dat)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -0.5893    0.3311  -1.780  0.075075 .
## Grupo_bin      1.9264    0.6370   3.024  0.002492 **
```



```
## xa_snp          1.2825      0.3311   3.874 0.000107 ***
## xd_snp          -0.1038      0.5095  -0.204 0.838543
## Grupo_bin:xa_snp  0.7477      0.6370   1.174 0.240433
## Grupo_bin:xd_snp -0.9650      0.8316  -1.160 0.245859
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
## Null deviance: 249.53 on 179 degrees of freedom
## Residual deviance: 187.96 on 174 degrees of freedom
## AIC: 199.96
##
## Number of Fisher Scoring iterations: 6
##
## OR estimados:
##      (Intercept)      Grupo_bin      xa_snp      xd_snp Grupo_bin:xa_snp Grupo_bin:xd_snp
##      0.555          6.865          3.606          0.901          2.112          0.38
##
## Acurácia: 0.733
##
## [ANOVA correspondente - para comparação]
## ANOVA p-valor Genotipo: 7.457217e-19
## Logístico p-valor xa: 0.0001072462
```

```
logistica_pop(dat_P3, "P3")
```

```
##
##
## =====
## POPULAÇÃO: P3
## =====
##
## Modelo logístico - fator categórico:
##
## Call:
## glm(formula = Ybin ~ Grupo_bin * (xa_snp + xd_snp), family = binomial(link = "logit"),
##      data = dat)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -0.3215    0.2872  -1.120  0.2629
## Grupo_bin      1.1352    0.5089   2.231  0.0257 *
## xa_snp         0.8681    0.2872   3.023  0.0025 **
## xd_snp        -0.2250    0.4754  -0.473  0.6360
## Grupo_bin:xa_snp  0.9573    0.5089   1.881  0.0600 .
## Grupo_bin:xd_snp -0.3204    0.7337  -0.437  0.6623
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
## Null deviance: 249.53 on 179 degrees of freedom
```

```
## Residual deviance: 202.00 on 174 degrees of freedom
## AIC: 214
##
## Number of Fisher Scoring iterations: 5
##
## OR estimados:
##      (Intercept)      Grupo_bin      xa_snp      xd_snp Grupo_bin:xa_snp Grupo_bin:xd_snp
##           0.725           3.112           2.382           0.798           2.605           0.72
##
## Acurácia: 0.711
##
## [ANOVA correspondente - para comparação]
## ANOVA p-valor Genotipo: 2.589809e-15
## Logístico p-valor xa: 0.002504658
```

3.5 Regressão Logística Combinada (3 populações)

```
dat_all$xa_snp <- dat_all$Geno_num - 1
dat_all$xd_snp <- ifelse(dat_all$Geno_num==1, 1, 0)
dat_all$Grupo_bin <- ifelse(dat_all$Grupo=="A", 0, 1)

# Efeito fixo de Pop
fitrl_all_fixo <- glm(Ybin ~ Grupo_bin * (xa_snp + xd_snp) + Pop,
                     family=binomial(link="logit"), data=dat_all)
summary(fitrl_all_fixo)
```

```
##
## Call:
## glm(formula = Ybin ~ Grupo_bin * (xa_snp + xd_snp) + Pop, family = binomial(link = "logit"),
##      data = dat_all)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -4.813e-01  2.108e-01  -2.283   0.0224 *
## Grupo_bin     1.435e+00  2.508e-01   5.721 1.06e-08 ***
## xa_snp        5.567e-01  1.643e-01   3.390   0.0007 ***
## xd_snp       -1.581e-01  2.817e-01  -0.561   0.5746
## PopP2        -9.037e-17  2.341e-01   0.000   1.0000
## PopP3       -4.992e-01  2.370e-01  -2.107   0.0351 *
## Grupo_bin:xa_snp  5.488e-01  2.505e-01   2.191   0.0284 *
## Grupo_bin:xd_snp  1.762e-01  4.094e-01   0.430   0.6670
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 748.60 on 539 degrees of freedom
## Residual deviance: 632.88 on 532 degrees of freedom
```

```
## AIC: 648.88
##
## Number of Fisher Scoring iterations: 4
```

```
cat("\nOR estimados:\n")
```

```
##
## OR estimados:
```

```
print(round(exp(coef(fitrl_all_fixo)), 3))
```

##	(Intercept)	Grupo_bin	xa_snp	xd_snp	PopP2	PopP
##	0.618	4.198	1.745	0.854	1.000	0.60

```
# Modelo misto logístico (Pop aleatório)
library(lme4)
fitrl_all_misto <- glmer(Ybin ~ Grupo_bin * (xa_snp + xd_snp) + (1|Pop),
                        family=binomial(link="logit"), data=dat_all)
summary(fitrl_all_misto)
```

```
## Generalized linear mixed model fit by maximum likelihood (Laplace Approximation) ['glmerMod']
## Family: binomial ( logit )
## Formula: Ybin ~ Grupo_bin * (xa_snp + xd_snp) + (1 | Pop)
## Data: dat_all
##
##      AIC      BIC    logLik -2*log(L)  df.resid
##    651.9    682.0   -319.0    637.9      533
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -2.66973 -0.78676 -0.06594  0.72754  1.97451
##
## Random effects:
##  Groups Name      Variance Std.Dev.
##  Pop      (Intercept) 0.02713  0.1647
## Number of obs: 540, groups: Pop, 3
##
## Fixed effects:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -0.6432    0.1894  -3.396  0.000685 ***
## Grupo_bin      1.4262    0.2500   5.704  1.17e-08 ***
## xa_snp         0.5536    0.1638   3.380  0.000726 ***
## xd_snp        -0.1569    0.2810  -0.558  0.576651
## Grupo_bin:xa_snp 0.5452    0.2498   2.183  0.029070 *
## Grupo_bin:xd_snp 0.1739    0.4083   0.426  0.670167
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
##              (Intr) Grp_bn xa_snp xd_snp Grp_bn:x_s
## Grupo_bin   -0.567
## xa_snp      -0.142  0.109
```

```
## xd_snp      -0.503  0.381  0.095
## Grp_bn:x_sn  0.092  0.133 -0.655 -0.063
## Grp_bn:xd_s  0.346 -0.611 -0.065 -0.688 -0.081
```

3.6 Comparação ANOVA vs. Regressão Logística

```
# ANOVA Q1C1
pval_anova_q1 <- anova(lm(Y ~ xa + xd, data=dat1))["xa","Pr(>F)"]
pval_logit_q1 <- summary(fitrl1_ad)$coef["xa","Pr(>|z|)"]
pval_anova_P2 <- anova(res_P2$fit_cat)["Genotipo","Pr(>F)"]
pval_anova_P3 <- anova(res_P3$fit_cat)["Grupo:Genotipo","Pr(>F)"]

# Logístico P2
d2tmp <- dat_P2
d2tmp$xa <- d2tmp$Geno_num - 1
d2tmp$xd <- ifelse(d2tmp$Geno_num==1, 1, 0)
d2tmp$Gb <- ifelse(d2tmp$Grupo=="A", 0, 1)
d2tmp$Ybin2 <- as.factor(ifelse(d2tmp$Y > median(d2tmp$Y), 1, 0))
pval_logit_P2 <- tryCatch(
  summary(glm(Ybin2 ~ Gb*(xa+xd), family=binomial, data=d2tmp))$coef["xa","Pr(>|z|)"],
  error = function(e) NA)

# Logístico P3
d3tmp <- dat_P3
d3tmp$xa <- d3tmp$Geno_num - 1
d3tmp$xd <- ifelse(d3tmp$Geno_num==1, 1, 0)
d3tmp$Gb <- ifelse(d3tmp$Grupo=="A", 0, 1)
d3tmp$Ybin3 <- as.factor(ifelse(d3tmp$Y > median(d3tmp$Y), 1, 0))
fit_logit_p3 <- tryCatch(
  glm(Ybin3 ~ Gb*(xa+xd), family=binomial, data=d3tmp),
  error = function(e) NULL)
pval_logit_P3 <- if(!is.null(fit_logit_p3)) {
  cf <- summary(fit_logit_p3)$coef
  if ("Gb:xa" %in% rownames(cf)) cf["Gb:xa","Pr(>|z|)"] else NA
} else NA

comp <- data.frame(
  Modelo = c("ANOVA xa (Q1-C1)","Logístico xa (Q1-C1)",
    "ANOVA SNP (P2)","Logístico xa (P2)",
    "ANOVA SNP×Grupo (P3)","Logístico xa×Grupo (P3)"),
  P_valor = round(c(pval_anova_q1, pval_logit_q1,
    pval_anova_P2, pval_logit_P2,
    pval_anova_P3, pval_logit_P3), 4)
)
knitr::kable(comp, caption="Comparação de p-valores: ANOVA vs. Regressão Logística")
```

Table 3: Comparação de p-valores: ANOVA vs. Regressão Logística

Modelo	P_valor
ANOVA xa (Q1-C1)	0e+00
Logístico xa (Q1-C1)	0e+00
ANOVA SNP (P2)	0e+00
Logístico xa (P2)	1e-04
ANOVA SNP $\times$ Grupo (P3)	2e-04
Logístico xa $\times$ Grupo (P3)	6e-02

Impacto da categorização:

A dicotomização da variável resposta **reduz o poder estatístico** do teste, pois descarta informação contínua de Y. Em geral, os p-valores tendem a ser maiores na regressão logística (menos poder) em comparação à ANOVA sobre Y contínua. Contudo, quando o fenótipo de interesse é genuinamente binário (ex.: doença/ausência), a regressão logística é o modelo **correto**, e os **Odds Ratios** têm interpretação clínica direta. O efeito aditivo do SNP (coef. xa) é detectado em ambos os modelos quando suficientemente forte, mas a magnitude da perda de poder depende do ponto de corte adotado e da distribuição subjacente de Y.