

IBI5086 – Lista 2 (1º Sem/2026)

Grupo 4: Amanda Gonçalves, Carlos Lima, Daniel Nogueira, Guilherme Zonzin, Lucas Ito, Victoria Mel

2026-05-18

Contents

1	Mapeamento de Genes: ANOVA com SNPs	1
1.1	Caso 1 – ANOVA 1 fator em 3 níveis (efeitos aditivo e de dominância)	1
1.1.1	Codificação dos efeitos aditivo (xa) e de dominância (xd)	4
1.1.2	Modelo com 2 g.l. – fatores aditivo e de dominância	4
1.1.3	Diagnóstico dos resíduos (Caso 1)	5
1.1.4	Comparações múltiplas de Tukey	6
1.2	Caso 2 – ANOVA Fatorial 3×3 (dois SNPs, efeitos aditivo, dominância e epistasia)	7
1.2.1	Modelo com efeitos aditivos, dominância e interações (8 g.l.)	9
2	Delineamento Fatorial 3×2: SNP $\times$ Subgrupo Populacional	13
2.1	Simulação dos dados (P1, P2, P3) (item a)	13
2.2	Análise por População	14
2.2.1	Função auxiliar para análise completa	14
2.2.2	P1 – Sem efeito de SNP, sem interação	15
2.2.3	P2 – Efeito aditivo de SNP, sem interação (perfis paralelos)	21
2.2.4	P3 – Efeito de SNP com interação (epistasia SNP $\times$ Subgrupo)	27
2.3	Item (d) – Combinando as três populações	34
2.3.1	(d.i) – Fatorial $3 \times 2 \times 3$: SNP $\times$ Grupo $\times$ População (todos fixos)	34
2.3.2	(d.ii) – Fatorial 3×2 com População como fator aleatório (ANOVA Mista)	36
3	Regressão Logística: Y dicotomizada	38
3.1	Dicotomização de Y	38
3.2	Questão 1 (Caso 1) – Regressão Logística	39
3.3	Questão 1 (Caso 2) – Regressão Logística com dois SNPs	42
3.4	Questão 2 – Regressão Logística por População	47
3.5	Regressão Logística Combinada (3 populações)	55
3.6	Comparação ANOVA vs. Regressão Logística	58

1 Mapeamento de Genes: ANOVA com SNPs

Gerar X (binomial) e Y (normal); ajustar modelos de ANOVA.

1.1 Caso 1 – ANOVA 1 fator em 3 níveis (efeitos aditivo e de dominância)

```
set.seed(8732)
n_por_genot <- 100
```

```

# X: genótipos 0=aa, 1=Aa, 2=AA (distribuição ~binomial(2, p=0.3))
# probabilidades Hardy-Weinberg com p=0.3
p <- 0.3
freq <- c((1-p)^2, 2*p*(1-p), p^2) # aa, Aa, AA
snp <- sample(0:2, n_por_genot*3, replace=TRUE, prob=freq)

# Y: resposta com efeito aditivo (a=10) e dominância (d=5) sobre a média basal 100
# mu_aa=100, mu_Aa=115 (=100+d, com d=5 sobre midpoint), mu_AA=120 (=100+2a)
# Parametrização: a=(mu_AA-mu_aa)/2=10; d=mu_Aa-(mu_AA+mu_aa)/2=5
mu <- c(100, 115, 120)[snp + 1]
Y1 <- rnorm(length(snp), mean = mu, sd = 5)

dat1 <- data.frame(Y = Y1, SNP = factor(snp, labels = c("aa","Aa","AA")),
                  snp_num = snp)

# Estatísticas descritivas por genótipo
library(psych)
descr1 <- describeBy(dat1, group = "SNP", mat = TRUE)

tabela1 <- descr1[c("Y1", "Y2", "Y3"), c("group1","n","mean","sd","median","min","max")]
tabela1$group1 <- c("aa", "Aa", "AA")
rownames(tabela1) <- NULL

knitr::kable(tabela1, digits = 2,
             col.names = c("genotype","n","mean","sd","median","min","max"),
             caption = "Estatísticas descritivas de Y por genótipo (Caso 1)")

```

Table 1: Estatísticas descritivas de Y por genótipo (Caso 1)


genotype	n	mean	sd	median	min	max
aa	148	100.16	5.08	100.43	85.72	111.76
Aa	123	114.57	4.94	114.23	102.09	130.30
AA	29	120.15	4.63	120.39	109.25	128.01

```

boxplot(Y ~ SNP, data = dat1, col = c("lightblue","lightgreen","lightyellow"),
        main = "Distribuição de Y por Genótipo (Caso 1)", xlab = "Genótipo", ylab = "Y")


```

Distribuição de Y por Genótipo (Caso 1)



```
# Perfil de médias
medias1 <- tapply(dat1$Y, dat1$SNP, mean)
plot(0:2, medias1, type = "b", pch = 19, col = "red",
     xaxt = "n", xlab = "Genótipo", ylab = "Média de Y",
     main = "Perfil de Médias - Caso 1")
axis(1, at = 0:2, labels = c("aa", "Aa", "AA"))
```

Perfil de Médias – Caso 1



1.1.1 Codificação dos efeitos aditivo (xa) e de dominância (xd)

```
# xa: -1 (aa), 0 (Aa), 1 (AA) → captura efeito aditivo
# xd: 0 (aa), 1 (Aa), 0 (AA) → captura desvio de dominância
dat1$xa <- dat1$snp_num - 1
dat1$xd <- ifelse(dat1$snp_num == 1, 1, 0)
```

1.1.2 Modelo com 2 g.l. – fatores aditivo e de dominância

```
fit1_ad <- lm(Y ~ xa + xd, data = dat1)
summary(fit1_ad)

##
## Call:
## lm(formula = Y ~ xa + xd, data = dat1)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -14.4366  -3.3116  -0.0913   3.2016  15.7234
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  110.1521     0.5061  217.649 < 2e-16 ***
## xa           9.9967     0.5061  19.752 < 2e-16 ***
## xd           4.4209     0.6768   6.532 2.82e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.984 on 297 degrees of freedom
## Multiple R-squared:  0.7171, Adjusted R-squared:  0.7152
## F-statistic: 376.4 on 2 and 297 DF,  p-value: < 2.2e-16

anova(fit1_ad)

## Analysis of Variance Table
##
## Response: Y
##           Df Sum Sq Mean Sq F value    Pr(>F)
## xa         1 17642.1 17642.1  710.116 < 2.2e-16 ***
## xd         1  1059.9  1059.9   42.663 2.817e-10 ***
## Residuals 297  7378.6    24.8
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Discussão: Interpretação dos coeficientes

O intercepto estimado ($\hat{\mu} = 110,15$) representa o ponto médio entre as médias dos homozigotos, $(\mu_{AA} + \mu_{aa})/2$.


O efeito aditivo (xa, $\hat{a} = 9,99$) é altamente significativo ($p < 0,001$), indicando que cada alelo A adicional eleva Y em aproximadamente 10 unidades.

O efeito de dominância (xd, $\hat{d} = 4,42$) é significativo ($p < 0,001$) e positivo, indicando que o heterozigoto acrescenta em torno de 4,42 unidades à média de Y.

O modelo explica cerca de 72% da variância total de Y ($R^2 = 0,717$).

1.1.3 Diagnóstico dos resíduos (Caso 1)

```
par(mfrow = c(2,2))
plot(fit1_ad)
```



```
par(mfrow = c(1,1))

shapiro.test(fit1_ad$residuals)

##
##  Shapiro-Wilk normality test
##
## data:  fit1_ad$residuals
## W = 0.99764, p-value = 0.9466

bartlett.test(Y ~ SNP, data = dat1)

##
##  Bartlett test of homogeneity of variances
##
## data:  Y by SNP
## Bartlett's K-squared = 0.42151, df = 2, p-value = 0.81
```

Discussão dos gráficos de diagnóstico

Residuals vs Fitted: dispersão vertical nas três colunas parece similar, e a linha vermelha está praticamente horizontal. Aleatoriedade OK.

Q-Q Residuals: pontos muito bem aderidos à diagonal. Normalidade bem satisfeita.

Sale-Location: Dispersão bem uniforme, linha vermelha praticamente horizontal, homocedasticidade bem satisfeita. As três observações rotuladas são outliers, nada alarmante.

Residuals vs Leverage: As observações do genótipo AA concentram-se à direita ($\sim 0,033$), com maior leverage que os demais genótipos — esperado dado sua menor frequência amostral sob Hardy-Weinberg ($p=0,3$, $\sim 9\%$ de AA). Ainda assim, a linha de Cook aparece colapsada na borda esquerda do gráfico, indicando que nenhuma observação exerce influência desproporcional sobre os coeficientes. O modelo é estável.

Testes de diagnóstico: O teste de Shapiro-Wilk **não rejeita** a normalidade dos resíduos ($W = 0,998$; $p = 0,947$), e o teste de Bartlett **não rejeita** a homogeneidade de variâncias entre os três genótipos ($K^2 = 0,42$; $gl = 2$; $p = 0,810$). Ambos os resultados confirmam que as suposições do modelo linear são satisfeitas, em concordância com o diagnóstico visual dos gráficos.


1.1.4 Comparações múltiplas de Tukey

```
fit1_aov <- aov(Y ~ SNP, data = dat1)
TukeyHSD(fit1_aov)

##    Tukey multiple comparisons of means
##      95% family-wise confidence level
##
## Fit: aov(formula = Y ~ SNP, data = dat1)
##
## $SNP
##           diff           lwr          upr p adj
## Aa-aa 14.417637 12.985123 15.850151 0e+00
## AA-aa 19.993374 17.609109 22.377639 0e+00
## AA-Aa  5.575737  3.152098  7.999376 4e-07

par(mar=c(5,8,4,2))
plot(TukeyHSD(fit1_aov))
```

95% family-wise confidence level



Comparações múltiplas de Tukey: O teste de Tukey HSD compara os três genótipos par a par com controle da taxa de erro familiar a 5%. Aa-aa (diff = 14,42; $p < 0,001$), AA-aa (diff = 19,99; $p < 0,001$) e AA-Aa (diff = 5,58; $p < 0,001$) são todos significativos, confirmando que cada alelo A adicional eleva a média de Y (~ 10) e que o heterozigoto sofre influência positiva do fator de dominância (~ 5).

1.2 Caso 2 – ANOVA Fatorial 3×3 (dois SNPs, efeitos aditivo, dominância e epistasia)

```
set.seed(8732)
n_cell <- 100 # por célula (genótipo conjunto)

# SNP1 e SNP2 gerados independentemente (HWE, p1=0.3, p2=0.4)
p1 <- 0.3; p2 <- 0.4
freq1 <- c((1-p1)^2, 2*p1*(1-p1), p1^2)
freq2 <- c((1-p2)^2, 2*p2*(1-p2), p2^2)

snp1 <- sample(0:2, n_cell*9, replace=TRUE, prob=freq1)
snp2 <- sample(0:2, n_cell*9, replace=TRUE, prob=freq2)

# Estrutura de médias com epistasia (interação a1*a2)
# mu_base + a1_efeito + a2_efeito + interacao
a1 <- 8; d1 <- 4; a2 <- 6; d2 <- 3

xa1 <- snp1 - 1 # -1, 0, 1
xd1 <- ifelse(snp1==1, 1, 0) # 0, 1, 0
xa2 <- snp2 - 1
xd2 <- ifelse(snp2==1, 1, 0)
```

```

# Modelo com efeitos e interações
mu2 <- 100 + a1*xa1 + d1*xd1 + a2*xa2 + d2*xd2 +
      3*xa1*xa2 + 1.5*xa1*xd2 + 1.5*xd1*xa2 + 1*xd1*xd2

Y2 <- rnorm(length(mu2), mean = mu2, sd = 12)

dat2 <- data.frame(
  Y = Y2,
  SNP1 = factor(snp1, labels = c("a1a1", "a1A1", "A1A1")),
  SNP2 = factor(snp2, labels = c("a2a2", "a2A2", "A2A2")),
  xa1 = xa1, xd1 = xd1, xa2 = xa2, xd2 = xd2
)

# Estatísticas descritivas
cat("Dimensões do dataset (Caso 2):", nrow(dat2), "observações\n")

## Dimensões do dataset (Caso 2): 900 observações
tapply(dat2$Y, list(dat2$SNP1, dat2$SNP2), mean) |>
  round(2) |>
  knitr::kable(caption = "Médias de Y por combinação genotípica (Caso 2)")

```

Table 2: Médias de Y por combinação genotípica (Caso 2)


	a2a2	a2A2	A2A2
a1a1	89.06	93.35	94.94
a1A1	97.11	109.38	113.98
A1A1	102.20	111.63	115.31

```

with(dat2,
  interaction.plot(SNP2, SNP1, Y, col = 1:3,
    main = "Perfil de Médias - Caso 2 (Epistasia)",
    xlab = "Genótipo SNP2", ylab = "Média Y",
    lwd = 2, pch = 19, type = "b"))

```


Perfil de Médias – Caso 2 (Epistasia)



O perfil de médias evidencia epistasia entre SNP1 e SNP2: o efeito de cada SNP sobre Y depende do genótipo do outro. Quanto mais alelos A1 o indivíduo carrega, maior o ganho em Y proporcionado pelos alelos A2.

1.2.1 Modelo com efeitos aditivos, dominância e interações (8 g.l.)

```
# Parametrização explícita: xa1, xd1, xa2, xd2 e 4 termos de interação
fit2_completo <- lm(Y ~ xa1 + xd1 + xa2 + xd2 +
                    xa1:xa2 + xa1:xd2 + xd1:xa2 + xd1:xd2,
                    data = dat2)
summary(fit2_completo)
```

```
##
## Call:
## lm(formula = Y ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xa1:xd2 +
##     xd1:xa2 + xd1:xd2, data = dat2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -40.274  -8.232  -0.041   7.851  36.568
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  100.3781    0.9026  111.214 < 2e-16 ***
## xa1           8.3782    0.9026   9.283 < 2e-16 ***
## xd1           5.1671    1.2673   4.077 4.97e-05 ***
## xa2           4.7509    0.9026   5.264 1.77e-07 ***
## xd2           2.1117    1.3771   1.533 0.12552
## xa1:xa2       1.8061    0.9026   2.001 0.04568 *
## xa1:xd2       0.7633    1.3771   0.554 0.57955
## xd1:xa2       3.6857    1.2673   2.908 0.00372 **
```

```
## xd1:xd2      1.7276      1.8710      0.923      0.35608
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 11.65 on 891 degrees of freedom
## Multiple R-squared:  0.3604, Adjusted R-squared:  0.3547
## F-statistic: 62.76 on 8 and 891 DF,  p-value: < 2.2e-16
```

```
anova(fit2_completo)
```

```
## Analysis of Variance Table
##
## Response: Y
##           Df Sum Sq Mean Sq  F value    Pr(>F)
## xa1         1  42983   42983 316.6776 < 2.2e-16 ***
## xd1         1   3509    3509  25.8516 4.495e-07 ***
## xa2         1  16343   16343 120.4054 < 2.2e-16 ***
## xd2         1   1409    1409  10.3809 0.001319 **
## xa1:xa2      1   2194    2194  16.1635 6.302e-05 ***
## xa1:xd2      1    284     284   2.0929 0.148337
## xd1:xa2      1   1313    1313   9.6731 0.001929 **
## xd1:xd2      1    116     116   0.8526 0.356076
## Residuals 891 120937    136
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Como houve discrepância entre os resultados da regressão linear e da ANOVA do modelo completo, foi ajustado um modelo reduzido contendo apenas os termos significativos na ANOVA.

```
fit2_reduzido <- lm(Y ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xd1:xa2, data = dat2)
summary(fit2_reduzido)
```

```
##
## Call:
## lm(formula = Y ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xd1:xa2, data = dat2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -40.681  -8.154  -0.101   8.047  36.959
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 100.1734     0.7717 129.806 < 2e-16 ***
## xa1           8.7385     0.6813  12.826 < 2e-16 ***
## xd1           6.0316     0.9303   6.484 1.48e-10 ***
## xa2           4.6699     0.9007   5.185 2.67e-07 ***
## xd2           2.5019     0.8016   3.121 0.00186 **
## xa1:xa2       1.8991     0.8989   2.113 0.03491 *
## xd1:xa2       4.0195     1.2435   3.233 0.00127 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 11.65 on 893 degrees of freedom
## Multiple R-squared:  0.3589, Adjusted R-squared:  0.3546
## F-statistic: 83.31 on 6 and 893 DF,  p-value: < 2.2e-16
```

```
anova(fit2_reduzido)
```

```
## Analysis of Variance Table
##
## Response: Y
##          Df Sum Sq Mean Sq F value    Pr(>F)
## xa1         1  42983    42983 316.618 < 2.2e-16 ***
## xd1         1   3509     3509  25.847 4.504e-07 ***
## xa2         1  16343    16343 120.383 < 2.2e-16 ***
## xd2         1   1409     1409  10.379 0.001321 **
## xa1:xa2      1   2194     2194  16.160 6.311e-05 ***
## xd1:xa2      1   1419     1419  10.449 0.001272 **
## Residuals 893 121231      136
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
anova(fit2_reduzido, fit2_completo)
```

```
## Analysis of Variance Table
##
## Model 1: Y ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xd1:xa2
## Model 2: Y ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xa1:xd2 + xd1:xa2 + xd1:xd2
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      893 121231
## 2      891 120937  2    294.15 1.0836 0.3388
```

Os modelos foram comparados por ANOVA para modelos aninhados, e como não houve diferença significativa entre eles ($p = 0,3388$), optou-se pelo modelo reduzido.

Interpretação:

- **xa1** e **xa2**: efeitos aditivos dos SNP1 e SNP2, respectivamente.
- **xd1** e **xd2**: desvios de dominância de cada SNP.
- **xa1:xa2** ($a_1 \times a_2$): **epistasia aditiva** $\times$ **aditiva** – interação entre os efeitos aditivos.
- **xa1:xd2** ($a_1 \times d_2$), **xd1:xa2** ($d_1 \times a_2$): epistasias mistas.
- **xd1:xd2** ($d_1 \times d_2$): epistasia dominância $\times$ dominância.


O modelo explica ~35,9% da variância de Y ($R^2 = 0,359$) e é globalmente significativo ($F = 83,31$; $p < 0,001$). O erro padrão residual (~11,65) está próximo do valor verdadeiro simulado ($\sigma = 12$), indicando bom ajuste.

Efeitos principais: os efeitos aditivos de ambos os SNPs são significativos — **xa1** ($\hat{a}_1 = 8,74$; $p < 0,001$) e **xa2** ($\hat{a}_2 = 4,67$; $p < 0,001$) — indicando que cada alelo A adicional em cada loco eleva Y independentemente. Os efeitos de dominância **xd1** e **xd2** também são significativos pelo summary ($p < 0,001$ e $p < 0,01$). Entretanto, como foi detectada epistasia aditiva $\times$ aditiva e dominância $\times$ aditiva entre os alelos, a interpretação isolada dos efeitos principais pode não ser adequada. Nota: É interessante notar que os coeficientes recuperados para **xa1**, **xa2**, **xd1** e **xd2** foram próximos dos reais usados na geração: ($a_1 = 8$; $d_1 = 4$; $a_2 = 6$; $d_2 = 3$).

Epistasia: as interações aditiva $\times$ aditiva **xa1:xa2** e dominância $\times$ aditiva **xd1:xa2** são significativas na tabela ANOVA (**xa1:xa2** -> $F = 16,16$; $p < 0,001$ | **xd1:xa2** -> $F = 10,45$; $p < 0,01$). As demais interações não atingem significância, embora o valor verdadeiro simulado das interações **xd1:xa2** e **xa1:xd2** fossem idênticos (1.5x). A diferença em significância é reflexo da variação amostral e não um erro.

Em conjunto, os resultados confirmam que o fenótipo Y é influenciado pelos efeitos aditivos de dois locos e por sua interação epistática, padrão visualmente antecipado pelo não-paralelismo das linhas no perfil de médias.

```
par(mfrow = c(2,2)); plot(fit2_completo); par(mfrow = c(1,1))
```



```
shapiro.test(fit2_completo$residuals)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  fit2_completo$residuals
## W = 0.99908, p-value = 0.9438
```

Diagnóstico dos resíduos – Caso 2:

Residuals vs Fitted: os pontos distribuem-se em colunas verticais correspondentes às 9 combinações genotípicas (células do fatorial 3×3), padrão esperado com preditores discretos. A linha vermelha é aproximadamente horizontal em 0, sem curvatura sistemática, indicando que o modelo linear é adequado.

Q-Q Residuals: excelente aderência à diagonal em toda a extensão central, com desvios pequenos nas caudas. A normalidade dos resíduos é confirmada formalmente pelo teste de Shapiro-Wilk ($W = 0,999$; $p = 0,944$), que não rejeita H_0 .

Scale-Location: a linha vermelha é praticamente horizontal e a distribuição dos resíduos aparenta ser uniforme.

Residuals vs Leverage: os pontos se distribuem em faixas de leverage distintas, refletindo as diferentes frequências das 9 células genotípicas — células raras (como A1A1 com $p_1=0,3$) têm maior leverage. Ainda assim, a linha de Cook permanece colapsada na borda inferior do gráfico, indicando que nenhuma observação exerce influência desproporcional sobre os coeficientes.

2 Delineamento Fatorial 3×2 : SNP $\times$ Subgrupo Populacional

2.1 Simulação dos dados (P1, P2, P3) (item a)

```
set.seed(8732)
n_rep <- 30 # réplicas
sigma <- 8 # desvio padrão

# Médias fornecidas na lista
medias_pop <- list(
  P1 = matrix(c(80,80,80, 90,90,90), nrow=2, byrow=TRUE,
    dimnames=list(c("A","B"), c("aa","Aa","AA"))),
  P2 = matrix(c(75,80,90, 80,86,97), nrow=2, byrow=TRUE,
    dimnames=list(c("A","B"), c("aa","Aa","AA"))),
  P3 = matrix(c(75,80,85, 75,85,100), nrow=2, byrow=TRUE,
    dimnames=list(c("A","B"), c("aa","Aa","AA")))
)

# Gerar dados para cada população
gerar_pop <- function(mmat, n, sigma, pop_nome) {
  rows <- list()
  for (grp in rownames(mmat)) {
    for (geno in colnames(mmat)) {
      y <- rnorm(n, mean = mmat[grp, geno], sd = sigma)
      rows[[length(rows)+1]] <- data.frame(
        Y = y, Grupo = grp, Genotipo = geno,
        Geno_num = match(geno, c("aa","Aa","AA")) - 1,
        Pop = pop_nome
      )
    }
  }
  do.call(rbind, rows)
}

dat_P1 <- gerar_pop(medias_pop$P1, n_rep, sigma, "P1")
dat_P2 <- gerar_pop(medias_pop$P2, n_rep, sigma, "P2")
dat_P3 <- gerar_pop(medias_pop$P3, n_rep, sigma, "P3")

# Ordenar fatores
dat_P1$Genotipo <- factor(dat_P1$Genotipo, levels=c("aa","Aa","AA"))
dat_P2$Genotipo <- factor(dat_P2$Genotipo, levels=c("aa","Aa","AA"))
dat_P3$Genotipo <- factor(dat_P3$Genotipo, levels=c("aa","Aa","AA"))
```

Contextualização (item b): Os dados representam medições de pressão arterial diastólica em repouso (mmHg) em indivíduos de três populações distintas (P1, P2, P3), classificados segundo o genótipo de um SNP (aa, Aa, AA) e a origem geográfica (A e B). Adotou-se $n = 30$ réplicas por co-ordenada (Grupo $\times$ Genótipo) $\sigma = 8$ mmHg. As três populações representam cenários distintos: **P1** sem efeito do SNP (apenas diferença entre subgrupos: $B \approx 10$ mmHg acima de A); **P2** com efeito do SNP e perfis paralelos entre subgrupos; e **P3** com interação SNP $\times$ subgrupo, onde o efeito do SNP é modesto em A (+10 mmHg de aa $\rightarrow$ AA) mas acentuado em B (+25 mmHg), sugerindo que fatores populacionais do subgrupo B potencializam o efeito do SNP sobre

a pressão diastólica.

2.2 Análise por População

2.2.1 Função auxiliar para análise completa

```
analisa_pop <- function(dat, nome_pop) {  
  cat("\n\n===== \n")  
  cat(" POPULAÇÃO:", nome_pop, "\n")  
  cat("===== \n\n")  
  
  # (i) Estatísticas descritivas  
  cat("--- (i) Estatísticas Descritivas --- \n")  
  desc <- describeBy(dat, group = list(dat$Grupo, dat$Genotipo), mat=TRUE)  
  print(knitr::kable(desc[grepl("^Y", rownames(desc)),  
                        c("group1", "group2", "n", "mean", "sd", "median")],  
        digits=2, caption=paste("Descritivas -", nome_pop)))  
  
  # (ii) Perfil de médias  
  par(mfrow=c(1,2))  
  with(dat,  
        interaction.plot(Genotipo, Grupo, Y,  
                          col=c("red", "blue"), lwd=2, pch=19, type="b",  
                          main=paste("Perfil de Médias -", nome_pop),  
                          xlab="Genótipo SNP", ylab="Média Y"))  
  
  # Boxplot  
  boxplot(Y ~ Grupo:Genotipo, data=dat, col=c("lightcoral", "lightblue"),  
          main=paste("Boxplot -", nome_pop),  
          xlab="Grupo:Genótipo", ylab="Y", las=2, cex.axis=0.7)  
  par(mfrow=c(1,1))  
  
  # (iii) ANOVA Fatorial 3$times$2 - fator categórico  
  cat("\n--- (iii) ANOVA Fatorial 3x2 (Genotipo categórico) --- \n")  
  fit_cat <- aov(Y ~ Grupo * Genotipo, data=dat)  
  print(summary(fit_cat))  
  cat("\nCoeficientes: \n")  
  print(coef(fit_cat))  
  
  # Diagnóstico resíduos  
  par(mfrow=c(2,2)); plot(fit_cat); par(mfrow=c(1,1))  
  cat("\nShapiro-Wilk (normalidade resíduos): \n")  
  print(shapiro.test(fit_cat$residuals))  
  cat("\nBartlett (homocedasticidade): \n")  
  print(bartlett.test(Y ~ interaction(Grupo, Genotipo), data=dat))  
  
  # Tukey  
  cat("\nComparações múltiplas de Tukey: \n")  
  tk <- TukeyHSD(fit_cat)  
  print(tk)  
  plot(tk, las=1, cex.axis=0.6)
```

```

# (iv) SNP como variável quantitativa (1 g.l. - efeito linear)
cat("\n--- (iv) SNP como variável quantitativa (efeito aditivo linear) ---\n")
fit_num <- lm(Y ~ Grupo * Geno_num, data=dat)
print(summary(fit_num))
print(anova(fit_num))

cat("\nComparação R²: categórico =", round(summary(lm(Y ~ Grupo * Genotipo, data=dat))$r.squared, 3),
    "| quantitativo =", round(summary(fit_num)$r.squared, 3), "\n")

invisible(list(fit_cat=fit_cat, fit_num=fit_num))
}

```



2.2.2 P1 – Sem efeito de SNP, sem interação

```





res_P1 <- analisa_pop(dat_P1, "P1")

##
##
## =====
## POPULAÇÃO: P1
## =====
##
## --- (i) Estatísticas Descritivas ---
##
##
## Table: Descritivas - P1
##
## | |group1 |group2 | n| mean| sd| median|
## |:-:|:-----|:-----|--:|-----:|-----:|-----:|
## |Y1 |A      |aa      | 30| 79.95| 7.92| 79.10|
## |Y2 |B      |aa      | 30| 90.51| 9.23| 90.51|
## |Y3 |A      |Aa      | 30| 78.93| 9.11| 79.71|
## |Y4 |B      |Aa      | 30| 91.34| 6.16| 90.93|
## |Y5 |A      |AA      | 30| 78.98| 5.76| 78.81|
## |Y6 |B      |AA      | 30| 89.59| 7.35| 90.83|

```




```
##
## --- (iii) ANOVA Fatorial 3x2 (Genotipo categórico) ---
##               Df Sum Sq Mean Sq F value Pr(>F)
## Grupo         1   5637    5637  94.959 <2e-16 ***
## Genotipo       2     32      16   0.273  0.761
## Grupo:Genotipo 2     33      17   0.281  0.755
## Residuals     174  10328      59
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Coeficientes:
##      (Intercept)          GrupoB      GenotipoAa      GenotipoAA  GrupoB:GenotipoAa  GrupoB:Gen
##      79.95232024      10.55691612     -1.01984317     -0.96910237      1.85320676      0.0
```


```
##
## Shapiro-Wilk (normalidade resíduos):
##
## Shapiro-Wilk normality test
##
## data: fit_cat$residuals
## W = 0.99448, p-value = 0.7439
##
## Bartlett (homocedasticidade):
##
## Bartlett test of homogeneity of variances
##
## data: Y by interaction(Grupo, Genotipo)
## Bartlett's K-squared = 10.56, df = 5, p-value = 0.06083
##
##
## Comparações múltiplas de Tukey:
## Tukey multiple comparisons of means
## 95% family-wise confidence level
##
## Fit: aov(formula = Y ~ Grupo * Genotipo, data = dat)
##
## $Grupo
##      diff      lwr      upr p adj
## B-A 11.19187 8.925067 13.45868    0
```

```
##
## $Genotipo
##           diff           lwr           upr           p adj
## Aa-aa -0.09323979 -3.418441  3.231961  0.9975806
## AA-aa -0.94326914 -4.268470  2.381932  0.7808776
## AA-Aa -0.85002935 -4.175230  2.475172  0.8179569
##
## $`Grupo:Genotipo`
##           diff           lwr           upr           p adj
## B:aa-A:aa  10.55691612   4.824323  16.289509  0.0000050
## A:Aa-A:aa  -1.01984317  -6.752436   4.712750  0.9956337
## B:Aa-A:aa  11.39027971   5.657687  17.122873  0.0000007
## A:AA-A:aa  -0.96910237  -6.701695   4.763490  0.9965684
## B:AA-A:aa   9.63948021   3.906887  15.372073  0.0000406
## A:Aa-B:aa -11.57675930 -17.309352  -5.844166  0.0000004
## B:Aa-B:aa   0.83336358  -4.899229   6.565956  0.9983292
## A:AA-B:aa -11.52601849 -17.258611  -5.793426  0.0000005
## B:AA-B:aa  -0.91743592  -6.650029   4.815157  0.9973543
## B:Aa-A:AA  12.41012288   6.677530  18.142716  0.0000000
## A:AA-A:AA   0.05074081  -5.681852   5.783334  1.0000000
## B:AA-A:AA  10.65932338   4.926731  16.391916  0.0000039
## A:AA-B:AA -12.35938207 -18.091975  -6.626789  0.0000001
## B:AA-B:AA  -1.75079950  -7.483392   3.981793  0.9508273
## B:AA-A:AA  10.60858257   4.875990  16.341175  0.0000044
```


95% family-wise confidence level



95% family-wise confidence level



95% family-wise confidence level



Differences in mean levels of Grupo:Genotipo

```
##
## --- (iv) SNP como variável quantitativa (efeito aditivo linear) ---
##
## Call:
## lm(formula = Y ~ Grupo * Geno_num, data = dat)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -19.1528  -5.2945   0.0742   5.0879  21.7213
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   79.77389    1.27917  62.364 < 2e-16 ***
## GrupoB        11.16604    1.80902   6.172 4.51e-09 ***
## Geno_num      -0.48455    0.99084  -0.489   0.625
## GrupoB:Geno_num 0.02583    1.40126   0.018   0.985
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 7.675 on 176 degrees of freedom
## Multiple R-squared:  0.3533, Adjusted R-squared:  0.3423
## F-statistic: 32.05 on 3 and 176 DF, p-value: < 2.2e-16
##
## Analysis of Variance Table
##
```

```
## Response: Y
##               Df   Sum Sq Mean Sq F value Pr(>F)
## Grupo         1  5636.6   5636.6  95.6879 <2e-16 ***
## Geno_num       1    26.7    26.7   0.4531  0.5017
## Grupo:Geno_num 1     0.0     0.0   0.0003  0.9853
## Residuals     176 10367.5    58.9
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Comparação R²: categórico = 0.356 | quantitativo = 0.353
```

Interpretação P1:

Perfil de médias e boxplot: as linhas do perfil de médias oscilam levemente entre genótipos — a linha do subgrupo B sobe de aa para Aa e recua em AA, enquanto a do subgrupo A desce ligeiramente — mas essas variações refletem apenas flutuação amostral, hipótese fortalecida pelos testes seguintes. A separação vertical entre subgrupos é consistente e visualmente dominante. O boxplot corrobora: as distribuições dentro de cada subgrupo são similares entre genótipos.

ANOVA: apenas o efeito de Grupo é significativo ($F = 94,96$; $p < 0,001$). Os efeitos de Genótipo ($F = 0,27$; $p = 0,761$) e da interação Grupo×Genótipo ($F = 0,28$; $p = 0,755$) não são significativos.

Diagnóstico: normalidade (Shapiro-Wilk: $W = 0,994$; $p = 0,744$) e homocedasticidade (Bartlett: $K^2 = 10,56$; $p = 0,061$) satisfeitas. O gráfico “Constant Leverage” mostra resíduos uniformemente distribuídos entre os níveis de Grupo, sem padrões preocupantes.

Tukey: o contraste B-A é significativo ($\sim 11,2$ mmHg; $p < 0,001$). Todos os contrastes entre genótipos (Aa-aa, AA-aa, AA-Aa) incluem o zero nos ICs e têm $p > 0,75$, confirmando ausência de efeito do SNP sobre a pressão diastólica. No Tukey da interação Grupo:Genótipo, os únicos contrastes significativos são aqueles que comparam subgrupos opostos (ex.: B:aa-A:aa, B:Aa-A:Aa), confirmando que toda a significância se deve ao efeito de subgrupo, não ao SNP.


SNP quantitativo (item iv): o modelo com `Geno_num` confirma: coeficiente do SNP não significativo ($-0,48$; $p = 0,625$) e interação Grupo×Geno_num também não significativa ($p = 0,985$). O ajuste é praticamente equivalente ao modelo categórico ($R^2 = \text{categórico } 0.356 \mid \text{quantitativo } 0.353$), com a variância explicada quase integralmente pelo efeito de subgrupo populacional.

2.2.3 P2 – Efeito aditivo de SNP, sem interação (perfis paralelos)





```
res_P2 <- analisa_pop(dat_P2, "P2")

##
##
## =====
## POPULAÇÃO: P2
## =====
##
## --- (i) Estatísticas Descritivas ---
##
##
## Table: Descritivas - P2
##
## |   |group1 |group2 |  n| mean|   sd| median|
## |---|:-----|:-----|--|:-----|:-----|:-----|
## |Y1 |A      |aa      | 30| 74.03| 9.13| 74.11|
## |Y2 |B      |aa      | 30| 79.11| 7.25| 78.43|
## |Y3 |A      |Aa      | 30| 79.76| 8.37| 79.23|
```

##	Y4	B	Aa		30	84.61	7.90	83.63
##	Y5	A	AA		30	90.08	7.68	89.23
##	Y6	B	AA		30	98.91	8.27	101.49




```
##
## --- (iii) ANOVA Fatorial 3x2 (Genotipo categórico) ---
##
##          Df Sum Sq Mean Sq F value    Pr(>F)
## Grupo      1   1757    1757  26.627 6.68e-07 ***
## Genotipo    2  10091    5046  76.474 < 2e-16 ***
## Grupo:Genotipo 2    150     75   1.134   0.324
## Residuals 174  11480     66
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Coeficientes:
##      (Intercept)          GrupoB      GenotipoAa      GenotipoAA GrupoB:GenotipoAa GrupoB:Gen
##      74.0288813         5.0763575         5.7354973        16.0553098        -0.2321264         3.7
```




```
##
## Shapiro-Wilk (normalidade resíduos):
##
## Shapiro-Wilk normality test
##
## data: fit_cat$residuals
## W = 0.9929, p-value = 0.5306
##
## Bartlett (homocedasticidade):
##
## Bartlett test of homogeneity of variances
##
## data: Y by interaction(Grupo, Genotipo)
## Bartlett's K-squared = 1.8307, df = 5, p-value = 0.872
##
##
## Comparações múltiplas de Tukey:
## Tukey multiple comparisons of means
## 95% family-wise confidence level
##
## Fit: aov(formula = Y ~ Grupo * Genotipo, data = dat)
##
## $Grupo
##      diff      lwr      upr p adj
## B-A 6.248239 3.85837 8.638107 7e-07
```

```
##
## $Genotipo
##      diff      lwr      upr      p adj
## Aa-aa  5.619434  2.113712  9.125156  0.0006069
## AA-aa 17.929195 14.423473 21.434916 0.0000000
## AA-Aa 12.309761  8.804039 15.815482 0.0000000
##
## $`Grupo:Genotipo`
##      diff      lwr      upr      p adj
## B:aa-A:aa  5.0763575 -0.9674497 11.120165 0.1549331
## A:Aa-A:aa  5.7354973 -0.3083098 11.779304 0.0736213
## B:Aa-A:aa 10.5797283  4.5359212 16.623535 0.0000167
## A:AA-A:aa 16.0553098 10.0115027 22.099117 0.0000000
## B:AA-A:aa 24.8794373 18.8356302 30.923244 0.0000000
## A:Aa-B:aa  0.6591398 -5.3846673  6.702947 0.9995854
## B:Aa-B:aa  5.5033709 -0.5404363 11.547178 0.0969478
## A:AA-B:aa 10.9789523  4.9351452 17.022759 0.0000070
## B:AA-B:aa 19.8030798 13.7592727 25.846887 0.0000000
## B:Aa-A:AA  4.8442311 -1.1995761 10.888038 0.1957295
## A:AA-A:AA 10.3198125  4.2760054 16.363620 0.0000291
## B:AA-A:AA 19.1439400 13.1001329 25.187747 0.0000000
## A:AA-B:AA  5.4755815 -0.5682257 11.519389 0.1001007
## B:AA-B:AA 14.2997090  8.2559018 20.343516 0.0000000
## B:AA-A:AA  8.8241275  2.7803204 14.867935 0.0005826
```


95% family-wise confidence level



95% family-wise confidence level



95% family-wise confidence level



Differences in mean levels of Grupo:Genotipo

```
##
## --- (iv) SNP como variável quantitativa (efeito aditivo linear) ---
##
## Call:
## lm(formula = Y ~ Grupo * Geno_num, data = dat)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -21.0974  -5.5636   0.1684   4.8664  25.1543
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    73.265     1.375   53.299 < 2e-16 ***
## GrupoB          4.374     1.944    2.250  0.0257 *
## Geno_num        8.028     1.065    7.539 2.41e-12 ***
## GrupoB:Geno_num  1.874     1.506    1.244  0.2150
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 8.248 on 176 degrees of freedom
## Multiple R-squared:  0.4901, Adjusted R-squared:  0.4814
## F-statistic: 56.38 on 3 and 176 DF, p-value: < 2.2e-16
##
## Analysis of Variance Table
##
```

```
## Response: Y
##               Df Sum Sq Mean Sq F value    Pr(>F)
## Grupo         1  1756.8   1756.8   25.8265 9.479e-07 ***
## Geno_num      1  9643.7   9643.7  141.7691 < 2.2e-16 ***
## Grupo:Geno_num 1   105.3    105.3    1.5486   0.215
## Residuals    176 11972.2    68.0
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Comparação R2: categórico = 0.511 | quantitativo = 0.49
```

Interpretação P2:

Perfil de médias e boxplot: as linhas do perfil de médias variam de forma ascendente entre os genótipos. As linhas dos subgrupos são aproximadamente paralelas, indicando independência do efeito do SNP em relação ao subgrupo. O boxplot corrobora: as distribuições dentro de cada subgrupo mostram aumento progressivo da mediana e da média de Y de aa para AA.

ANOVA: são significativos tanto o efeito de Grupo ($F = 26,63$; $p < 0,001$) quanto do Genótipo ($F = 76,47$; $p < 0,001$). Já interação Grupo $\times$ Genótipo é não significativa ($F = 1,134$; $p = 0,324$).

Diagnóstico: normalidade (Shapiro-Wilk: $W = 0,993$; $p = 0,531$) e homocedasticidade (Bartlett: $K^2 = 1,831$; $p = 0,872$) satisfeitas. O gráfico “Constant Leverage” mostra resíduos bem distribuídos.

Tukey: o contraste B-A é significativo ($\sim 6,2$ mmHg; $p < 0,001$), indicando diferença entre subgrupos. Todos os contrastes entre genótipos são significativos (Aa-aa: $+5,6$ mmHg, $p < 0,001$; AA-aa: $+17,9$ mmHg, $p < 0,001$; AA-Aa: $+12,3$ mmHg, $p < 0,001$), confirmando o efeito do SNP sobre a pressão diastólica. No Tukey da interação Grupo:Genótipo, os contrastes dentro do mesmo subgrupo entre genótipos distintos são em sua maioria significativos (ex.: A:AA-A:aa, B:AA-B:aa), enquanto contrastes entre subgrupos dentro do mesmo genótipo tendem a não atingir significância isoladamente (ex.: B:aa-A:aa: $p = 0,155$; B:Aa-A:Aa: $p = 0,196$), sugerindo que o efeito de subgrupo é menos pronunciado do que o efeito do SNP nesta população. A ausência de interação significativa na ANOVA é corroborada: o padrão de diferenças entre genótipos é consistente entre os subgrupos A e B.

SNP quantitativo (item iv): o modelo com `Geno_num` detecta efeito do SNP altamente significativo ($p < 0,001$). O efeito de Grupo permanece significativo ($p = 0,026$) e a interação Grupo $\times$ Geno_num não é significativa ($p = 0,215$), reforçando a ausência de interação já observada no modelo categórico. O R^2 é ligeiramente inferior ao do modelo categórico (0,490 vs. 0,511), diferença pequena que reflete a perda de um G.L. causada ao assumir linearidade do efeito de SNP, que assumindo os valores [0, 1, 2] seria necessariamente aditivo, ignorando possíveis efeitos adicionais, como dominância ou recessividade. Em casos como este, que o heterozigoto não está exatamente no ponto médio entre aa e AA, há perda de informação. O uso do SNP quantitativo é, então, ideal somente para casos em que o efeito aditivo é muito mais significativo que quaisquer outros.


2.2.4 P3 – Efeito de SNP com interação (epistasia SNP $\times$ Subgrupo)

```
res_P3 <- analisa_pop(dat_P3, "P3")
```


```
##
##
## =====
## POPULAÇÃO: P3
## =====
##
```

```
## --- (i) Estatísticas Descritivas ---
##
##
## Table: Descritivas - P3
##
## |   |group1 |group2 |  n|   mean|   sd| median|
## |---|:-----|:-----|---|:-----|:-----|:-----|
## |Y1 |A      |aa      | 30|  76.23|  7.10|  75.47|
## |Y2 |B      |aa      | 30|  75.40|  8.69|  74.82|
## |Y3 |A      |Aa      | 30|  78.91|  7.77|  78.46|
## |Y4 |B      |Aa      | 30|  84.26|  7.96|  84.10|
## |Y5 |A      |AA      | 30|  85.42|  9.07|  84.44|
## |Y6 |B      |AA      | 30| 100.44|  9.68| 101.09|
```

Perfil de Médias – P3







Boxplot – P3



```
##
## --- (iii) ANOVA Fatorial 3x2 (Genotipo categórico) ---
##
##           Df Sum Sq Mean Sq F value    Pr(>F)
## Grupo      1   1906    1906    26.87 5.99e-07 ***
## Genotipo    2   9096    4548    64.10 < 2e-16 ***
## Grupo:Genotipo 2   1916     958    13.50 3.54e-06 ***
## Residuals 174 12345       71
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Coeficientes:
##      (Intercept)      GrupoB      GenotipoAa      GenotipoAA  GrupoB:GenotipoAa  GrupoB:GenotipoAA
```


76.2341934 -0.8376434 2.6775862 9.1847370 6.1835631 15.8




```
##
## Shapiro-Wilk (normalidade resíduos):
##
## Shapiro-Wilk normality test
##
## data: fit_cat$residuals
## W = 0.99501, p-value = 0.8113
##
## Bartlett (homocedasticidade):
##
## Bartlett test of homogeneity of variances
##
## data: Y by interaction(Grupo, Genotipo)
## Bartlett's K-squared = 3.6449, df = 5, p-value = 0.6016
##
##
## Comparações múltiplas de Tukey:
## Tukey multiple comparisons of means
## 95% family-wise confidence level
##
## Fit: aov(formula = Y ~ Grupo * Genotipo, data = dat)
##
## $Grupo
##      diff      lwr      upr p adj
```

```
## B-A 6.508804 4.030576 8.987031 6e-07
##
## $Genotipo
##      diff      lwr      upr      p adj
## Aa-aa  5.769368  2.134031  9.404705 0.0006967
## AA-aa 17.112626 13.477289 20.747963 0.0000000
## AA-Aa 11.343258  7.707921 14.978595 0.0000000
##
## $`Grupo:Genotipo`
##      diff      lwr      upr      p adj
## B:aa-A:aa -0.8376434 -7.1049053  5.429619 0.9988855
## A:Aa-A:aa  2.6775862 -3.5896757  8.944848 0.8210097
## B:Aa-A:aa  8.0235058  1.7562439 14.290768 0.0040153
## A:AA-A:aa  9.1847370  2.9174751 15.451999 0.0005474
## B:AA-A:aa 24.2028712 17.9356094 30.470133 0.0000000
## A:Aa-B:aa  3.5152295 -2.7520324  9.782491 0.5889066
## B:Aa-B:aa  8.8611492  2.5938873 15.128411 0.0009766
## A:AA-B:aa 10.0223804  3.7551185 16.289642 0.0001131
## B:AA-B:aa 25.0405146 18.7732527 31.307777 0.0000000
## B:Aa-A:AA  5.3459197 -0.9213422 11.613182 0.1426013
## A:AA-A:AA  6.5071509  0.2398890 12.774413 0.0368267
## B:AA-A:AA 21.5252851 15.2580232 27.792547 0.0000000
## A:AA-B:AA  1.1612312 -5.1060307  7.428493 0.9947156
## B:AA-B:AA 16.1793654  9.9121035 22.446627 0.0000000
## B:AA-A:AA 15.0181342  8.7508723 21.285396 0.0000000
```


95% family-wise confidence level



95% family-wise confidence level



95% family-wise confidence level



Differences in mean levels of Grupo:Genotipo

```
##
## --- (iv) SNP como variável quantitativa (efeito aditivo linear) ---
##
## Call:
## lm(formula = Y ~ Grupo * Geno_num, data = dat)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -22.6306  -5.0435  -0.5809   6.1423  22.7371
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    75.596     1.415  53.425 < 2e-16 ***
## GrupoB         -1.419     2.001  -0.709   0.479
## Geno_num        4.592     1.096   4.190 4.41e-05 ***
## GrupoB:Geno_num  7.928     1.550   5.115 8.16e-07 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 8.49 on 176 degrees of freedom
## Multiple R-squared:  0.4978, Adjusted R-squared:  0.4893
## F-statistic: 58.16 on 3 and 176 DF, p-value: < 2.2e-16
##
## Analysis of Variance Table
##
```



```
## Response: Y
##               Df Sum Sq Mean Sq F value    Pr(>F)
## Grupo          1  1906.4   1906.4   26.449 7.161e-07 ***
## Geno_num        1   8785.3   8785.3  121.883 < 2.2e-16 ***
## Grupo:Geno_num  1   1885.5   1885.5   26.159 8.158e-07 ***
## Residuals      176 12686.0     72.1
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Comparação R2: categórico = 0.511 | quantitativo = 0.498
```

Interpretação P3:

Perfil de médias e boxplot: as linhas do perfil de médias crescem afastando-se, indicando que dessa vez, não podemos assumir independência do efeito do SNP em relação ao subgrupo. O boxplot mostra “shifts” maiores entre genótipos no subgrupo B, evidenciando a interação: o efeito do SNP é mais acentuado em B do que em A.

ANOVA: são significativos ambos o efeito de Grupo ($F = 26,87$; $p < 0,001$) e de Genótipo ($F = 64,10$; $p < 0,001$). E também é significativa a interação Grupo×Genótipo ($F = 13,50$; $p < 0,001$).

Diagnóstico: normalidade (Shapiro-Wilk: $W = 0,995$; $p = 0,811$) e homocedasticidade (Bartlett: $K^2 = 3,645$; $p = 0,602$) satisfeitas. O gráfico “Constant Leverage” mostra resíduos bem distribuídos. Já o “Scale-Location” apresenta uma leve inclinação ascendente, sugerindo que a variabilidade dos resíduos tende a aumentar com os valores ajustados. Ainda assim, o teste de Bartlett não rejeita a homocedasticidade, então o padrão observado no gráfico não é estatisticamente relevante com este tamanho amostral.

Tukey: o contraste B-A é significativo ($\sim 6,5$ mmHg; $p < 0,001$), indicando diferença entre subgrupos. Todos os contrastes entre genótipos são significativos (Aa-aa: $+5,8$ mmHg, $p < 0,001$; AA-aa: $+17,1$ mmHg, $p < 0,001$; AA-Aa: $+11,3$ mmHg, $p < 0,001$), confirmando o efeito do SNP sobre a pressão diastólica. No Tukey da interação Grupo:Genótipo, o padrão de contrastes revela claramente a interação SNP×subgrupo: dentro do subgrupo A, o efeito do SNP é moderado (A:AA-A:aa: $+9,2$ mmHg; $p < 0,001$), enquanto no subgrupo B é muito mais acentuado (B:AA-B:aa: $+25,0$ mmHg; $p < 0,001$). Contrastes entre subgrupos dentro do mesmo genótipo mostram que A e B são indistinguíveis em aa (B:aa-A:aa: $p = 0,999$) mas divergem fortemente em AA (B:AA-A:AA: $+15,0$ mmHg; $p < 0,001$), confirmando que a diferença entre subgrupos depende do genótipo — assinatura inequívoca de interação. Estes resultados corroboram a interação significativa observada na ANOVA e o não-paralelismo das linhas no perfil de médias.

SNP quantitativo (item iv): o modelo com `Geno_num` assume e detecta efeito aditivo linear significativo no subgrupo A ($\hat{\beta} = 4,59$ mmHg por alelo A; $p < 0,001$) e uma interação Grupo×Geno_num altamente significativa ($\hat{\beta} = 7,93$; $p < 0,001$), indicando que o efeito do SNP é maior por alelo A no subgrupo B do que em A — resultado coerente com a interação detectada no modelo categórico. O efeito principal de Grupo não é significativo ($p = 0,479$). Isso pode ser justificado pois quando há interação, o efeito de Grupo depende do genótipo, não podendo ser interpretado isoladamente. O R^2 é ligeiramente inferior ao do modelo categórico (0,498 vs. 0,511), diferença pequena que reflete a restrição de G.L. causada pela adoção da linearidade. A conclusão é a mesma: há interação SNP×grupo significativa, com o efeito do SNP sendo muito mais pronunciado no grupo B.

2.3 Item (d) – Combinando as três populações

A análise conjunta permite avaliar se os efeitos do SNP e do subgrupo são consistentes entre populações ou se há heterogeneidade, questão central em estudos de genética de populações.

2.3.1 (d.i) – Fatorial 3 x 2 x 3 : SNP × Grupo × População (todos fixos)

```
dat_all <- rbind(dat_P1, dat_P2, dat_P3)
dat_all$Pop <- factor(dat_all$Pop) # Transformo população em var. categórica

# Estatísticas descritivas do dataset combinado
desc_all <- describeBy(dat_all$Y,
                        group = list(dat_all$Pop, dat_all$Grupo, dat_all$Genotipo),
                        mat = TRUE)

tabela_all <- desc_all[, c("group1", "group2", "group3", "n", "mean", "sd", "median", "min", "max")]
rownames(tabela_all) <- NULL


knitr::kable(tabela_all, digits = 2,
             col.names = c("População", "Grupo", "Genótipo", "n", "Média", "DP", "Mediana", "Mín", "Máx"),
             caption = "Estatísticas descritivas de Y por População, Grupo e Genótipo")
```

Table 3: Estatísticas descritivas de Y por População, Grupo e Genótipo

População	Grupo	Genótipo	n	Média	DP	Mediana	Mín	Máx
P1	A	aa	30	79.95	7.92	79.10	66.62	94.18
P2	A	aa	30	74.03	9.13	74.11	54.91	92.07
P3	A	aa	30	76.23	7.10	75.47	60.13	93.82
P1	B	aa	30	90.51	9.23	90.51	75.07	107.78
P2	B	aa	30	79.11	7.25	78.43	63.70	91.86
P3	B	aa	30	75.40	8.69	74.82	55.89	95.17
P1	A	Aa	30	78.93	9.11	79.71	60.14	94.87
P2	A	Aa	30	79.76	8.37	79.23	65.14	98.32
P3	A	Aa	30	78.91	7.77	78.46	60.86	94.20
P1	B	Aa	30	91.34	6.16	90.93	78.77	112.20
P2	B	Aa	30	84.61	7.90	83.63	73.61	103.71
P3	B	Aa	30	84.26	7.96	84.10	66.69	99.87
P1	A	AA	30	78.98	5.76	78.81	66.94	93.31
P2	A	AA	30	90.08	7.68	89.23	79.32	114.47
P3	A	AA	30	85.42	9.07	84.44	62.15	101.10
P1	B	AA	30	89.59	7.35	90.83	72.80	104.50
P2	B	AA	30	98.91	8.27	101.49	76.34	114.68
P3	B	AA	30	100.44	9.68	101.09	81.02	121.95

```
# Perfil de médias
with(dat_all,
     interaction.plot(Genotipo, interaction(Gruo,Pop), Y,
                     main="Perfil Médias: SNP x Grupo x População",
                     xlab="Genótipo", ylab="Média Y",
                     lwd=2, type="b"))
```

Perfil Médias: SNP x Grupo x População



Modelo completo 3x2x3

```
fit_fixo <- aov(Y ~ Grupo * Genótipo * Pop, data = dat_all)
summary(fit_fixo)
```

```
##              Df Sum Sq Mean Sq F value    Pr(>F)
## Grupo          1   8603    8603 131.492 < 2e-16 ***
## Genótipo        2  12069    6034  92.227 < 2e-16 ***
## Pop             2    195      97   1.490 0.226376
## Grupo:Genótipo  2    979     490   7.485 0.000624 ***
## Grupo:Pop       2    697     348   5.323 0.005145 **
## Genótipo:Pop    4   7151    1788  27.324 < 2e-16 ***
## Grupo:Genótipo:Pop 4   1120     280   4.278 0.002049 **
## Residuals      522  34153      65
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Coeficientes do modelo

```
fit_fixo$coef
```

```
##              (Intercept)              GrupoB              GenótipoAa              GenótipoAA
##              79.95232024              10.55691612              -1.01984317              -0.96910237
##              GrupoB:GenótipoAA              GrupoB:PopP2              GrupoB:PopP3              GenótipoAa:PopP2
##              0.05166645              -5.48055866              -11.39455950              6.75534045
## GrupoB:GenótipoAa:PopP2 GrupoB:GenótipoAA:PopP2 GrupoB:GenótipoAa:PopP3 GrupoB:GenótipoAA:PopP3
##              -2.08533317              3.69610359              4.33035631              15.80411113
```

Modelo (d.i) — População como fator fixo: $Y \sim \text{Grupo} * \text{Genótipo} * \text{Pop}$ inclui todos os efeitos principais e interações de 2ª e 3ª ordem (17 g.l. de tratamento). Grupo ($F = 131,5$; $p < 0,001$) e Genótipo ($F = 92,2$; $p < 0,001$) são significativos, mas Pop isoladamente não ($F = 1,49$; $p = 0,226$). A interação tripla Grupo×Genótipo×Pop é significativa ($F = 4,28$; $p = 0,002$), confirmando que o padrão de interação SNP×subgrupo é heterogêneo entre populações — como visível no gráfico, onde as inclinações diferem marcadamente entre P1, P2 e P3.

2.3.2 (d.ii) – Fatorial 3 x 2 com População como fator aleatório (ANOVA Mista)

```
library(lme4)

# Modelo misto: Population como efeito aleatório (intercepto aleatório por Pop)
fit_misto <- lmer(Y ~ Grupo * Genotipo * (1 | Pop), data = dat_all)
summary(fit_misto)

## Linear mixed model fit by REML. t-tests use Satterthwaite's method ['lmerModLmerTest']
## Formula: Y ~ Grupo * Genotipo * (1 | Pop)
## Data: dat_all
##
## REML criterion at convergence: 3889.8
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -2.8484 -0.6599 -0.0410  0.6774  3.2897
##
## Random effects:
## Groups Name Variance Std.Dev.
## Pop (Intercept) 0.09122 0.302
## Residual 81.05413 9.003
## Number of obs: 540, groups: Pop, 3
##
## Fixed effects:
## Estimate Std. Error df t value Pr(>|t|)
## (Intercept) 76.7385 0.9649 49.9573 79.531 < 2e-16 ***
## GrupoB 4.9319 1.3421 532.0000 3.675 0.000262 ***
## GenotipoAa 2.4644 1.3421 532.0000 1.836 0.066878 .
## GenotipoAA 8.0903 1.3421 532.0000 6.028 3.1e-09 ***
## GrupoB:GenotipoAa 2.6015 1.8980 532.0000 1.371 0.171053
## GrupoB:GenotipoAA 6.5517 1.8980 532.0000 3.452 0.000601 ***
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
## (Intr) GrupoB GntpA GntpAA GrB:GA
## GrupoB -0.695
## GenotipoAa -0.695 0.500
## GenotipoAA -0.695 0.500 0.500
## GrpB:GntpA 0.492 -0.707 -0.707 -0.354
## GrpB:GntpAA 0.492 -0.707 -0.354 -0.707 0.500

# Coeficientes do modelo
print(coef(fit_misto))

## $Pop
## (Intercept) GrupoB GenotipoAa GenotipoAA GrupoB:GenotipoAa GrupoB:GenotipoAA
## P1 76.84579 4.931877 2.464413 8.090315 2.601548 6.551738
## P2 76.76683 4.931877 2.464413 8.090315 2.601548 6.551738
## P3 76.60277 4.931877 2.464413 8.090315 2.601548 6.551738
##
## attr(,"class")
## [1] "coef.mer"
```

```
# IC dos efeitos fixos
confint(fit_misto, method="Wald")

##                2.5 %    97.5 %
## .sig01           NA      NA
## .sigma           NA      NA
## (Intercept)    74.8473185 78.629611
## GrupoB         2.3014306 7.562323
## GenotipoAa     -0.1660327 5.094860
## GenotipoAA      5.4598687 10.720761
## GrupoB:GenotipoAa -1.1184648 6.321560
## GrupoB:GenotipoAA  2.8317255 10.271751

# IC profile
confint(fit_misto)

##                2.5 %    97.5 %
## .sig01          0.0000000 1.692875
## .sigma          8.4475286 9.518151
## (Intercept)    74.8848240 78.592106
## GrupoB         2.3104325 7.553321
## GenotipoAa     -0.1570308 5.085858
## GenotipoAA      5.4688706 10.711759
## GrupoB:GenotipoAa -1.1057342 6.308830
## GrupoB:GenotipoAA  2.8444560 10.259020

# IC bootstrap
confint(fit_misto, method="boot", nsim=1000)

##                2.5 %    97.5 %
## .sig01          0.0000000 1.273450
## .sigma          8.4489750 9.610272
## (Intercept)    74.9202306 78.620777
## GrupoB         2.1563800 7.565635
## GenotipoAa     -0.2005394 5.003334
## GenotipoAA      5.5990832 10.919747
## GrupoB:GenotipoAa -1.2031479 6.192034
## GrupoB:GenotipoAA  2.6301816 10.408517
```

Modelo (d.ii) — População como fator aleatório: $Y \sim \text{Grupo} * \text{Genotipo} * (1|\text{Pop})$

a população como efeito aleatório não se mostrou importante para o conjunto de dados. A variância praticamente nula (0,091) em relação ao resíduo (81,054) indica que a heterogeneidade entre populações é pequena comparada à variação dentro das populações. Os efeitos fixos de **GrupoB** e **GenotipoAA** permanecem altamente significativos ($p < 0,001$), assim como a interação **GrupoB:GenotipoAA**. Então, embora no modelo d.i a interação de População como efeito fixo com os demais fatores fosse importante, ao considerá-la aleatória, o efeito de grupo e genótipo se sobressaem. Nesse caso então, uma generalização dos efeitos de Grupo e Genótipo para além das três populações observadas é plausível e sustentada pelos dados: a estabilidade dos efeitos fixos entre populações sugere que a associação do SNP e do fator de grupo com a pressão diastólica não é específica de população. Contudo, essa conclusão deve ser interpretada com cautela, pois com apenas três populações o modelo aleatório não possui poder suficiente para estimar com precisão a variabilidade interpopulacional no universo amostral. Os intervalos de confiança para o desvio-padrão do efeito aleatório (.sig01) incluem zero em ambos os métodos avaliados (profile e bootstrap). Portanto, a ausência de variância interpopulacional detectável pode refletir tanto homogeneidade real entre populações quanto limitação de poder amostral.

3 Regressão Logística: Y dicotomizada

3.1 Dicotomização de Y

```
# Ponto de corte: mediana global de cada dataset
corte1 <- median(dat1$Y)
corte2 <- median(dat2$Y)
corte_all <- median(dat_all$Y)

dat1$Ybin <- as.factor(ifelse(dat1$Y > corte1, 1, 0))
dat2$Ybin <- as.factor(ifelse(dat2$Y > corte2, 1, 0))
dat_all$Ybin <- as.factor(ifelse(dat_all$Y > corte_all, 1, 0))

cat("Ponto de corte Q1:", corte1, " | Distribuição:\n"); print(table(dat1$Ybin))

## Ponto de corte Q1: 108.5428 | Distribuição:
##
##      0      1
## 150 150

tab1 <- table(factor(dat1$Ybin, labels = c("baixo", "alto")), dat1$SNP)
tab1 <- rbind(tab1, "total" = colSums(tab1))
tab1


##           aa  Aa AA
## baixo 137   13   0
## alto   11  110  29
## total 148  123  29

cat("Ponto de corte Q2:", corte2, " | Distribuição:\n"); print(table(dat2$Ybin))

## Ponto de corte Q2: 99.32791 | Distribuição:
##
##      0      1
## 450 450

plot <- ggplot2::ggplot(dat2, ggplot2::aes(x = SNP1, fill = SNP2)) +
  ggplot2::geom_bar(position = ggplot2::position_dodge()) +
  ggplot2::facet_wrap(~ Ybin) +
  ggplot2::scale_fill_brewer(type = "qual", palette = "Set2", name = "SNP2") +
  ggplot2::labs(
    title = "Contingência - Q2 (SNP1 x SNP2 x Resposta)",
    x = "Genótipo SNP1",
    y = "Contagem"
  ) +
  ggplot2::theme_minimal()

print(plot)
```



Dicotomização de Y: A mediana é adotada como ponto de corte, resultando em distribuição perfeitamente balanceada: 150 observações em cada classe para Q1 (corte = 107,93) e 225 para Q2 (corte = 99,44). Essa escolha maximiza o poder do teste logístico, mas é arbitrária — um corte clinicamente motivado seria igualmente válido e potencialmente mais interpretável.

3.2 Questão 1 (Caso 1) – Regressão Logística

```
# Modelo logístico
fitrl1_ad <- glm(as.factor(Ybin) ~ xa + xd, family=binomial(link="logit"), data=dat1)
summary(fitrl1_ad)
```

```
##
## Call:
## glm(formula = as.factor(Ybin) ~ xa + xd, family = binomial(link = "logit"),
##      data = dat1)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    8.022     605.612   0.013   0.989
## xa             10.544     605.612   0.017   0.986
## xd             -5.886     605.612  -0.010   0.992
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 415.89  on 299  degrees of freedom
## Residual deviance: 161.35  on 297  degrees of freedom
## AIC: 167.35
##
## Number of Fisher Scoring iterations: 17
```

```

cat("\nOR estimado (exp(coef)):\n")

##
## OR estimado (exp(coef)):
print(exp(coef(fitr11_ad)))

## (Intercept)          xa          xd
## 3.047240e+03 3.795198e+04 2.776788e-03

cat("\nIC para OR:\n")

##
## IC para OR:
print(exp(confint(fitr11_ad)))

##          2.5 %          97.5 %
## (Intercept) 1.339586e-17          NA
## xa          2.516933e-09 4.004769e+80
## xd          NA 1.777731e+12

# Probabilidades preditas e tabela de classificação
pred1r <- predict(fitr11_ad, type="response")
class1r <- ifelse(pred1r >= 0.5, 1, 0)
cat("Tabela de classificação:\n")

```

```

## Tabela de classificação:
print(table(Predito=class1r, Observado=dat1$Ybin))

##      Observado
## Predito    0    1
##      0 137   11
##      1   13 139

cat("Acurácia:", round(mean(class1r == dat1$Ybin), 3), "\n")

## Acurácia: 0.92

```

Regressão Logística – Q1 Caso 1: O estabelecimento do valor corte para dicotomização de Y na mediana dos dados causou um fenômeno de separação completa dos grupos devido à ausência de observações “baixas” para o genótipo AA. Isso fez o modelo de regressão logística não recuperar adequadamente os coeficientes para os efeitos aditivo e de dominância, que tiveram a significância ignorada. Decidimos então voltar atrás e definir arbitrariamente um valor de corte que não deixasse valores nulos na tabela de contingência “altos *versus* baixos.”

```

corte1 <- 111
dat1$Ybin <- as.factor(ifelse(dat1$Y > corte1, 1, 0))

cat("Ponto de corte Q1:", corte1, " | Distribuição:\n"); print(table(dat1$Ybin))

## Ponto de corte Q1: 111 | Distribuição:
##
##      0    1
## 173 127

tab1 <- table(factor(dat1$Ybin, labels = c("baixo", "alto")), dat1$SNP)
tab1 <- rbind(tab1, "total" = colSums(tab1))

```



```

tab1

##          aa  Aa AA
## baixo 144  27  2
## alto   4  96 27
## total 148 123 29

fitrl1_ad <- glm(as.factor(Ybin) ~ xa + xd, family=binomial(link="logit"), data=dat1)
summary(fitr11_ad)

##
## Call:
## glm(formula = as.factor(Ybin) ~ xa + xd, family = binomial(link = "logit"),
##      data = dat1)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -0.4904      0.4455  -1.101  0.27101
## xa              3.0931      0.4455   6.943 3.85e-12 ***
## xd              1.7589      0.4959   3.547 0.00039 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 408.81  on 299  degrees of freedom
## Residual deviance: 180.80  on 297  degrees of freedom
## AIC: 186.8
##
## Number of Fisher Scoring iterations: 6

cat("\nOR estimado (exp(coef)):\n")

##
## OR estimado (exp(coef)):
print(exp(coef(fitr11_ad)))

## (Intercept)          xa          xd
##  0.6123724 22.0454077  5.8061979

cat("\nIC para OR:\n")

##
## IC para OR:
print(exp(confint(fitr11_ad)))

##              2.5 %    97.5 %
## (Intercept)  0.2636769  1.673448
## xa          10.2133711 61.911080
## xd           1.9757020 14.980133

predlr <- predict(fitr11_ad, type="response")
classlr <- ifelse(predlr >= 0.5, 1, 0)
cat("Tabela de classificação:\n")

## Tabela de classificação:

```

```
print(table(Predito=class1r, Observado=dat1$Ybin))

##      Observado
## Predito    0    1
##      0 144    4
##      1   29 123

cat("Acurácia:", round(mean(class1r == dat1$Ybin), 3), "\n")

## Acurácia: 0.89
```

Regressão Logística – Q1 Caso 1 (com corte arbitrário): Dessa vez, conseguimos evitar a separação total dos grupos, possibilitando que o modelo recuperasse adequadamente os coeficientes, resultando em $\log(\frac{p}{1-p}) = -0.4904 + 3.0931 \times x_a + 1.7589 \times x_d$, com significância para ambos ($p_{x_a} = 3.85 \times 10^{-12}$; $p_{x_d} = 0.00039$).

3.3 Questão 1 (Caso 2) – Regressão Logística com dois SNPs

```
fitrl2 <- glm(Ybin ~ xa1 + xd1 + xa2 + xd2 +
             xa1:xa2 + xa1:xd2 + xd1:xa2 + xd1:xd2,
             family=binomial(link="logit"), data=dat2)
summary(fitrl2)

##
## Call:
## glm(formula = Ybin ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xa1:xd2 +
##      xd1:xa2 + xd1:xd2, family = binomial(link = "logit"), data = dat2)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  0.42831    0.28327   1.512  0.13052
## xa1          1.35709    0.28327   4.791 1.66e-06 ***
## xd1          0.43266    0.35125   1.232  0.21804
## xa2          0.86441    0.28327   3.052  0.00228 **
## xd2          0.22832    0.39495   0.578  0.56319
## xa1:xa2      0.48568    0.28327   1.715  0.08643 .
## xa1:xd2      0.09649    0.39495   0.244  0.80700
## xd1:xa2      0.18416    0.35125   0.524  0.60007
## xd1:xd2      0.27470    0.48585   0.565  0.57181
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 1247.7  on 899  degrees of freedom
## Residual deviance: 1002.6  on 891  degrees of freedom
## AIC: 1020.6
##
## Number of Fisher Scoring iterations: 5

cat("\nOR estimados:\n")

##
## OR estimados:
```

```

print(round(exp(coef(fitr12)), 3))

## (Intercept)      xa1      xd1      xa2      xd2    xa1:xa2    xa1:xd2    xd1:xa2
##      1.535      3.885      1.541      2.374      1.256      1.625      1.101      1.202

cat("\nIC para OR:\n")

##
## IC para OR:
print(round(exp(confint(fitr12)), 3))

##           2.5 % 97.5 %
## (Intercept) 0.961  3.247
## xa1         2.433  8.221
## xd1         0.675  2.949
## xa2         1.483  5.021
## xd2         0.524  2.740
## xa1:xa2     1.015  3.438
## xa1:xd2     0.459  2.402
## xd1:xa2     0.527  2.302
## xd1:xd2     0.506  3.623

pred2r <- predict(fitr12, type="response")
class2r <- ifelse(pred2r >= 0.5, 1, 0)
cat("Tabela de classificação:\n")

## Tabela de classificação:
print(table(Predito=class2r, Observado=dat2$Ybin))

##      Observado
## Predito    0    1
##      0 392 190
##      1  58 260

cat("Acurácia:", round(mean(class2r == dat2$Ybin), 3), "\n")

## Acurácia: 0.724

```

Regressão Logística – Q1 Caso 2: O estabelecimento do valor corte para dicotomização de Y na mediana dos dados causou uma separação muito desbalanceada entre os grupos **resposta** e **não resposta**, que acreditamos ter atrapalhado a eficácia do teste. No teste preditivo usando o modelo, foi obtida uma acurácia baixa (72,4%), o que atesta a limitação do método. Decidimos então, tentar novamente com um corte manual.

```

corte2 <- 105
dat2$Ybin <- as.factor(ifelse(dat2$Y > corte2, 1, 0))

cat("Ponto de corte Q2:", corte2, " | Distribuição:\n"); print(table(dat2$Ybin))

## Ponto de corte Q2: 105 | Distribuição:

##
##      0    1
## 574 326

plot <- ggplot2::ggplot(dat2, ggplot2::aes(x = SNP1, fill = SNP2)) +
  ggplot2::geom_bar(position = ggplot2::position_dodge()) +
  ggplot2::facet_wrap(~ Ybin) +


```

```

ggplot2::scale_fill_brewer(type = "qual", palette = "Set2", name = "SNP2") +
ggplot2::labs(
  title = "Contingência - Q2 (SNP1 x SNP2 x Resposta)",
  x = "Genótipo SNP1",
  y = "Contagem"
) +
ggplot2::theme_minimal()

print(plot)

```



```

fitrl2 <- glm(Ybin ~ xa1 + xd1 + xa2 + xd2 +
              xa1:xa2 + xa1:xd2 + xd1:xa2 + xd1:xd2,
              family=binomial(link="logit"), data=dat2)
summary(fitrl2)

```

```

##
## Call:
## glm(formula = Ybin ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xa1:xd2 +
##       xd1:xa2 + xd1:xd2, family = binomial(link = "logit"), data = dat2)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -0.752799   0.180996  -4.159 3.19e-05 ***
## xa1          1.084446   0.180996   5.992 2.08e-09 ***
## xd1          0.853044   0.252301   3.381 0.000722 ***
## xa2          0.511880   0.180996   2.828 0.004682 **
## xd2          0.408230   0.267112   1.528 0.126437
## xa1:xa2      0.255085   0.180996   1.409 0.158735
## xa1:xd2     -0.005907   0.267112  -0.022 0.982355
## xd1:xa2      0.529973   0.252301   2.101 0.035680 *
## xd1:xd2      0.285214   0.360793   0.791 0.429223

```

```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 1178.43  on 899  degrees of freedom
## Residual deviance:  936.85  on 891  degrees of freedom
## AIC: 954.85
##
## Number of Fisher Scoring iterations: 4
cat("\nOR estimados:\n")

##
## OR estimados:
print(round(exp(coef(fitrl2)), 3))

## (Intercept)          xa1          xd1          xa2          xd2          xa1:xa2          xa1:xd2          xd1:xa2
##      0.471          2.958          2.347          1.668          1.504          1.291          0.994          1.699
cat("\nIC para OR:\n")

##
## IC para OR:
print(round(exp(confint(fitrl2)), 3))

##              2.5 % 97.5 %
## (Intercept) 0.331  0.676
## xa1         2.088  4.264
## xd1         1.432  3.864
## xa2         1.178  2.405
## xd2         0.893  2.554
## xa1:xa2     0.912  1.862
## xa1:xd2     0.589  1.686
## xd1:xa2     1.036  2.794
## xd1:xd2     0.653  2.694

pred2r <- predict(fitrl2, type="response")
class2r <- ifelse(pred2r >= 0.5, 1, 0)
cat("Tabela de classificação:\n")

## Tabela de classificação:
print(table(Predito=class2r, Observado=dat2$Ybin))

##      Observado
## Predito    0    1
##      0 489 121
##      1  85 205
cat("Acurácia:", round(mean(class2r == dat2$Ybin), 3), "\n")

## Acurácia: 0.771
```

Regressão Logística – Q1 Caso 2 (corte manual): Foi desafiador definir um valor de corte que gerasse uma separação mais equilibrada entre os grupos, mas com o corte em 105, conseguimos ao menos evitar grupos zerados ou com representações excessivamente baixas. Apesar disso, notamos que o modelo logístico apresentou perda de significância em relação à ANOVA para o

efeito de dominância do SNP2 e para a interação **xa1:xa2**. Esse cenário, inclusive, mostrou-se facilmente influenciado pelos vários valores de corte que experimentamos. Hora era detectada significância de alguns efeitos, hora de outros. O teste preditivo melhorou um pouco em relação à definição do corte na mediana (de 72,4% para 77,1%), mas ainda assim ficou aquém do ideal, reforçando a limitação. Podemos ver que houve impacto significativo na adoção da categorização da resposta Y. Tornou-se mais desafiador por conta, acreditamos, das grandes separação e dispersão existentes nos dados. Entretanto, já que no ANOVA nós trabalhamos com um modelo reduzido, decidimos experimentar a mesma abordagem aqui, removendo efeitos que antes não haviam sido dados como significativos, a fim de focar nos efeitos de interesse.

```
fitrl2_reduzido <- glm(Ybin ~ xa1 + xd1 + xa2 + xd2 +
                      xa1:xa2 + xd1:xa2,
                      family=binomial(link="logit"), data=dat2)
summary(fitrl2_reduzido)

##
## Call:
## glm(formula = Ybin ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xd1:xa2,
##      family = binomial(link = "logit"), data = dat2)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -0.8195     0.1564  -5.239 1.62e-07 ***
## xa1           1.0909     0.1333   8.186 2.69e-16 ***
## xd1           0.9992     0.1800   5.552 2.82e-08 ***
## xa2           0.5015     0.1808   2.774 0.00553 **
## xd2           0.5443     0.1674   3.252 0.00115 **
## xa1:xa2       0.2544     0.1803   1.411 0.15830
## xd1:xa2       0.5753     0.2487   2.313 0.02071 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 1178.43  on 899  degrees of freedom
## Residual deviance:  937.56  on 893  degrees of freedom
## AIC: 951.56
##
## Number of Fisher Scoring iterations: 4

cat("\nOR estimados:\n")

##
## OR estimados:
print(round(exp(coef(fitrl2_reduzido)), 3))

## (Intercept)      xa1      xd1      xa2      xd2      xa1:xa2      xd1:xa2
##          0.441    2.977    2.716    1.651    1.723    1.290    1.778

cat("\nIC para OR:\n")

##
## IC para OR:
print(round(exp(confint(fitrl2_reduzido)), 3))

##          2.5 % 97.5 %
```

```
## (Intercept) 0.324 0.600
## xa1         2.302 3.888
## xd1         1.908 3.868
## xa2         1.165 2.374
## xd2         1.241 2.395
## xa1:xa2     0.911 1.853
## xd1:xa2     1.091 2.899

pred2r <- predict(fitrl2_reduzido, type="response")
class2r <- ifelse(pred2r >= 0.5, 1, 0)
cat("Tabela de classificação:\n")

## Tabela de classificação:

print(table(Predito=class2r, Observado=dat2$Ybin))

##      Observado
## Predito    0    1
##      0 489 121
##      1   85 205

cat("Acurácia:", round(mean(class2r == dat2$Ybin), 3), "\n")

## Acurácia: 0.771

anova(fitrl2_reduzido, fitrl2)

## Analysis of Deviance Table
##
## Model 1: Ybin ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xd1:xa2
## Model 2: Ybin ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xa1:xd2 + xd1:xa2 +
##      xd1:xd2
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1         893      937.56
## 2         891      936.85  2   0.71429   0.6997
```

Regressão Logística – Q1 Caso 2 (modelo reduzido): Agora, com um modelo reduzido, baseado naquele que utilizamos no ANOVA, conseguimos recuperar a significância para o efeito de dominância do SNP2, mas não o efeito da interação **xa1:xa2**. A acurácia preditiva permaneceu igual (77,1%), corroborando o resultado da ANOVA comparando o modelo reduzido ao logístico original ($p = 0.6997$). Acreditamos então, depois de tantas tentativas, que a regressão logística para esse caso é inadequada por gerar perda de informação.

3.4 Questão 2 – Regressão Logística por População

```
logistica_pop <- function(dat, nome) {
  cat("\n\n===== \n")
  cat(" POPULAÇÃO:", nome, "\n===== \n")

  # Dicotomizar Y
  corte_local <- 90 # escolhemos um corte fixo aqui por conhecermos a natureza biológica dos dados (ass
  dat$Ybin <- as.factor(ifelse(dat$Y > corte_local, 1, 0))

  # Visualizando contingência dos dados dicotomizados
  plot <- ggplot2::ggplot(dat, ggplot2::aes(x = Grupo, fill = Genotipo)) +
    ggplot2::geom_bar(position = ggplot2::position_dodge()) +
```

```

ggplot2::facet_wrap(
  ~ Ybin,
  labeller = ggplot2::labeller(Ybin = c("0" = "normal", "1" = "hipertenso"))
) +
ggplot2::scale_fill_brewer(type = "qual", palette = "Set2", name = "Genótipo") +
ggplot2::labs(
  title = paste0("Contingência - População: ", nome),
  x = "Grupo",
  y = "Contagem"
) +
ggplot2::theme_minimal()

print(plot)

# Fit do modelo logístico
fit_logit <- glm(Ybin ~ Grupo * Genotipo,
  family=binomial(link="logit"), data=dat)
cat("\nModelo logístico - fator categórico:\n")
print(summary(fit_logit))
cat("\nOR estimados:\n")
print(round(exp(coef(fit_logit)), 3))

# Prob preditas
pred_r <- predict(fit_logit, type="response")
class_r <- ifelse(pred_r >= 0.5, 1, 0)
cat("\nAcurácia:", round(mean(class_r == dat$Ybin), 3), "\n")

# Fit do modelo logístico com Genótipo quantitativo
fit_logit <- glm(Ybin ~ Grupo * Geno_num,
  family=binomial(link="logit"), data=dat)
cat("\nModelo logístico - genótipo quantitativo:\n")
print(summary(fit_logit))
cat("\nOR estimados:\n")
print(round(exp(coef(fit_logit)), 3))

# Prob preditas
pred_r <- predict(fit_logit, type="response")
class_r <- ifelse(pred_r >= 0.5, 1, 0)
cat("\nAcurácia:", round(mean(class_r == dat$Ybin), 3), "\n")


invisible(fit_logit)
}

logistica_pop(dat_P1, "P1")

##
##
## =====
## POPULAÇÃO: P1
## =====

```


Contingência – População: P1



```
##
## Modelo logístico - fator categórico:
##
## Call:
## glm(formula = Ybin ~ Grupo * Genotipo, family = binomial(link = "logit"),
##      data = dat)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -2.1972     0.6086  -3.610 0.000306 ***
## GrupoB           2.4655     0.7114   3.466 0.000529 ***
## GenotipoAa      -0.4418     0.9519  -0.464 0.642529
## GenotipoAA      -1.1701     1.1853  -0.987 0.323554
## GrupoB:GenotipoAa  0.8667     1.0917   0.794 0.427250
## GrupoB:GenotipoAA  1.0353     1.2940   0.800 0.423661
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##    Null deviance: 227.73  on 179  degrees of freedom
## Residual deviance: 163.67  on 174  degrees of freedom
## AIC: 175.67
##
## Number of Fisher Scoring iterations: 6
##
##
## OR estimados:
##              (Intercept)          GrupoB          GenotipoAa          GenotipoAA
##                   0.111          11.769           0.643           0.310
##              GrupoB:GenotipoAa  GrupoB:GenotipoAA
##                   2.379
```


```

## Acurácia: 0.761
##
## Modelo logístico - genótipo quantitativo:
##
## Call:
## glm(formula = Ybin ~ Grupo * Geno_num, family = binomial(link = "logit"),
##      data = dat)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -2.1680     0.5708  -3.798 0.000146 ***
## GrupoB         2.5965     0.6647   3.906 9.37e-05 ***
## Geno_num      -0.5599     0.5531  -1.012 0.311401
## GrupoB:Geno_num  0.4910     0.6122   0.802 0.422555
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 227.73  on 179  degrees of freedom
## Residual deviance: 164.83  on 176  degrees of freedom
## AIC: 172.83
##
## Number of Fisher Scoring iterations: 5
##
##
## OR estimados:
##      (Intercept)      GrupoB      Geno_num GrupoB:Geno_num
##           0.114         13.417         0.571         1.634
##
## Acurácia: 0.761
logistica_pop(dat_P2, "P2")

##
##
## =====
##  POPULAÇÃO: P2
##  =====

```

Contingência – População: P2



```
##
## Modelo logístico - fator categórico:
##
## Call:
## glm(formula = Ybin ~ Grupo * Genotipo, family = binomial(link = "logit"),
##     data = dat)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -2.639e+00  7.319e-01  -3.606 0.000311 ***
## GrupoB       -2.387e-14  1.035e+00   0.000 1.000000
## GenotipoAa    -1.622e-14  1.035e+00   0.000 1.000000
## GenotipoAA     2.093e+00  8.242e-01   2.539 0.011119 *
## GrupoB:GenotipoAa  1.253e+00  1.347e+00   0.930 0.352491
## GrupoB:GenotipoAA  2.156e+00  1.206e+00   1.787 0.073875 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
## Null deviance: 208.77  on 179  degrees of freedom
## Residual deviance: 140.57  on 174  degrees of freedom
## AIC: 152.57
##
## Number of Fisher Scoring iterations: 5
##
##
## OR estimados:
##              (Intercept)              GrupoB              GenotipoAa              GenotipoAA
##              0.071              1.000              1.000              8.105
##              GrupoB:GenotipoAa  GrupoB:GenotipoAA
##              3.500
```


```

## Acurácia: 0.844
##
## Modelo logístico - genótipo quantitativo:
##
## Call:
## glm(formula = Ybin ~ Grupo * Geno_num, family = binomial(link = "logit"),
##      data = dat)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -3.2340     0.7409  -4.365 1.27e-05 ***
## GrupoB        -0.1561     1.0155  -0.154  0.87785
## Geno_num       1.2807     0.4492   2.851  0.00436 **
## GrupoB:Geno_num 1.1052     0.6521   1.695  0.09011 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 208.77  on 179  degrees of freedom
## Residual deviance: 144.15  on 176  degrees of freedom
## AIC: 152.15
##
## Number of Fisher Scoring iterations: 5
##
##
## OR estimados:
##      (Intercept)      GrupoB      Geno_num GrupoB:Geno_num
##          0.039         0.855         3.599         3.020
##
## Acurácia: 0.844
logistica_pop(dat_P3, "P3")

##
##
## =====
##  POPULAÇÃO: P3
##  =====

```

Contingência – População: P3



```
##
## Modelo logístico - fator categórico:
##
## Call:
## glm(formula = Ybin ~ Grupo * Genotipo, family = binomial(link = "logit"),
##      data = dat)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -2.6391    0.7319  -3.606 0.000311 ***
## GrupoB         -0.7282    1.2531  -0.581 0.561132
## GenotipoAa      0.4418    0.9519   0.464 0.642529
## GenotipoAA     2.2336    0.8213   2.719 0.006539 **
## GrupoB:GenotipoAa 1.9139    1.4529   1.317 0.187759
## GrupoB:GenotipoAA 3.0055    1.4133   2.127 0.033460 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##    Null deviance: 216.42  on 179  degrees of freedom
## Residual deviance: 141.71  on 174  degrees of freedom
## AIC: 153.71
##
## Number of Fisher Scoring iterations: 6
##
##
## OR estimados:
##              (Intercept)          GrupoB          GenotipoAa          GenotipoAA
##              0.071          0.483          1.556          9.333
##              GrupoB:GenotipoAa  GrupoB:GenotipoAA
##              6.779
```

```
## Acurácia: 0.833
##
## Modelo logístico - genótipo quantitativo:
##
## Call:
## glm(formula = Ybin ~ Grupo * Geno_num, family = binomial(link = "logit"),
##      data = dat)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -3.0644    0.6907  -4.437 9.13e-06 ***
## GrupoB        -0.5955    1.0150  -0.587  0.55737
## Geno_num       1.2830    0.4241   3.025  0.00248 **
## GrupoB:Geno_num 1.4481    0.6782   2.135  0.03276 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 216.42  on 179  degrees of freedom
## Residual deviance: 142.72  on 176  degrees of freedom
## AIC: 150.72
##
## Number of Fisher Scoring iterations: 5
##
##
## OR estimados:
##      (Intercept)      GrupoB      Geno_num GrupoB:Geno_num
##           0.047           0.551           3.608           4.255
##
## Acurácia: 0.833
```

Regressão Logística por população: P1: assim como no teste original feito com ANOVA, temos que o efeito do **Genotipo** não é significativo, mas sim somente o efeito de **Grupo** ($p < 0,001$). Apesar da acurácia do teste preditivo não ter sido tão alta (76,1%), a regressão logística trouxe a mesma significância que ANOVA, levando à mesma conclusão. O mesmo resultado de significâncias foi obtido tanto com SNP considerado categórico como quando numérico.

P2: nesta população, ao trabalhar com Y dicotomizado com corte em 90mmHg, não foi detectado efeito significativo de **Grupo**, apenas de **Genotipo** (com genótipo categórico, especificamente o AA). Ao examinar o perfil dos dados, isso faz sentido, pois para ambos os grupos, os genótipos aa e Aa encontram-se contidos abaixo de 90mmHg. Apenas o genótipo AA possui observações acima do *threshold* estabelecido, sendo uma pequena porção do grupo A e a maioria esmagadora de B. O mesmo resultado de significâncias foi obtido tanto com SNP considerado categórico como quando numérico. A diferença deste teste em relação à ANOVA não é uma limitação da metodologia em si, mas consequência da mudança da natureza do estudo, uma vez que não mais estudamos o efeito das variáveis sobre o valor Y em si, mas sim a sua influência no “shift” de uma condição clínica.

P3: com Y dicotomizado e SNP categórico, o efeito de grupo foi não-significativo ($p = 0.56$), e genótipo foi significativo apenas para AA. Isso pode ser explicado, mais uma vez, pelo perfil dos próprios dados. O mesmo cenário observado em P2, em que aa e Aa ficaram concentrados no grupo **normal**, pode ser observado aqui. Já a interação **GrupoB:GenotipoAA** teve significância, devido à importância do genótipo para o efeito de grupo. No perfil de médias, vemos que AA:A está abaixo de 90mmHg, diferente de AA:B. O mesmo resultado foi obtido com genótipo

quantitativo: significância para Genotipo e para GrupoB:Geno_num. Mais uma vez, a diferença se dá pela mudança de foco do estudo em si.


3.5 Regressão Logística Combinada (3 populações)

```
# Contingência
contagem <- as.data.frame(table(dat_all$Grupo,
                                dat_all$Pop,
                                dat_all$Genotipo,
                                dat_all$Ybin))
names(contagem) <- c("Grupo", "Pop", "Genotipo", "Ybin", "Freq")
contagem$Grupo <- factor(contagem$Grupo, levels = c("A", "B"))
contagem$Pop <- factor(contagem$Pop, levels = c("P1", "P2", "P3"))
contagem$Genotipo <- factor(contagem$Genotipo, levels = c("aa", "Aa", "AA"))
contagem$Ybin <- factor(contagem$Ybin, levels = c("0", "1"))

plot <- ggplot2::ggplot(contagem,
                        ggplot2::aes(x = Grupo,
                                      y = Pop,
                                      fill = Genotipo,
                                      size = Freq)) +
  ggplot2::geom_point(position = ggplot2::position_dodge(width = 0.8),
                     shape = 21,
                     color = "black",
                     alpha = 0.8) +
  ggplot2::facet_wrap(
    ~ Ybin,
    labeller = ggplot2::labeller(
      Ybin = c("0" = "normal", "1" = "hipertenso")
    )
  ) +
  ggplot2::scale_fill_brewer(type = "qual", palette = "Set2", name = "Genótipo") +
  ggplot2::scale_size_area(max_size = 16, guide = ggplot2::guide_legend(title = "Contagem")) +
  ggplot2::labs(
    title = "Contingência de Y dicotomizada para as 3 populações",
    x = "Grupo",
    y = "População"
  ) +
  ggplot2::theme_minimal()

print(plot)
```

Contingência de Y dicotomizada para as 3 populações



```
# Efeito fixo de Pop
fitrl_all_fixo <- glm(Ybin ~ Grupo * Genotipo * Pop,
                     family=binomial(link="logit"), data=dat_all)
summary(fitrl_all_fixo)
```

```
##
## Call:
## glm(formula = Ybin ~ Grupo * Genotipo * Pop, family = binomial(link = "logit"),
##      data = dat_all)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -0.4055     0.3727  -1.088  0.27661
## GrupoB         1.4171     0.5562   2.548  0.01084 *
## GenotipoAa     -0.2877     0.5375  -0.535  0.59248
## GenotipoAA     -0.9808     0.5893  -1.665  0.09601 .
## PopP2         -1.4663     0.6537  -2.243  0.02489 *
## PopP3         -1.4663     0.6537  -2.243  0.02489 *
## GrupoB:GenotipoAa  1.4733     0.9109   1.617  0.10578
## GrupoB:GenotipoAA  1.1588     0.8391   1.381  0.16725
## GrupoB:PopP2     -0.5569     0.8765  -0.635  0.52522
## GrupoB:PopP3     -0.9316     0.8979  -1.038  0.29948
## GenotipoAa:PopP2  1.3122     0.8580   1.529  0.12616
## GenotipoAA:PopP2  5.0499     1.0030   5.035  4.79e-07 ***
## GenotipoAa:PopP3  0.9699     0.8739   1.110  0.26706
## GenotipoAA:PopP3  3.1209     0.8783   3.553  0.00038 ***
## GrupoB:GenotipoAa:PopP2 -1.4862     1.2573  -1.182  0.23716
## GrupoB:GenotipoAA:PopP2 -0.8489     1.6019  -0.530  0.59614
## GrupoB:GenotipoAa:PopP3 -0.6357     1.2833  -0.495  0.62034
## GrupoB:GenotipoAA:PopP3  0.7265     1.3683   0.531  0.59547
## ---
```



```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
## Null deviance: 748.60  on 539  degrees of freedom
## Residual deviance: 543.75  on 522  degrees of freedom
## AIC: 579.75
##
## Number of Fisher Scoring iterations: 5
cat("\nOR estimados:\n")

##
## OR estimados:
print(round(exp(coef(fitrl_all_fixo)), 3))

##              (Intercept)              GrupoB              GenotipoAa              GenotipoAA
##              0.667              4.125              0.750              0.375
## GrupoB:GenotipoAA      GrupoB:PopP2      GrupoB:PopP3      GenotipoAa:PopP2
##              3.186              0.573              0.394              3.714
## GrupoB:GenotipoAa:PopP2 GrupoB:GenotipoAA:PopP2 GrupoB:GenotipoAa:PopP3 GrupoB:GenotipoAA:PopP3
##              0.226              0.428              0.530              2.068

# Modelo misto logístico (Pop aleatório)
library(lme4)
fitrl_all_misto <- glmer(Ybin ~ Grupo * Genotipo * (1|Pop),
                        family=binomial(link="logit"), data=dat_all)
summary(fitrl_all_misto)

## Generalized linear mixed model fit by maximum likelihood (Laplace Approximation) ['glmerMod']
## Family: binomial ( logit )
## Formula: Ybin ~ Grupo * Genotipo * (1 | Pop)
## Data: dat_all
##
##      AIC      BIC    logLik -2*log(L)  df.resid
##    640.9    670.9   -313.4    626.9      533
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -3.08683 -0.74029 -0.07955  0.81553  2.07018
##
## Random effects:
## Groups Name      Variance Std.Dev.
## Pop      (Intercept) 0.03731  0.1932
## Number of obs: 540, groups: Pop, 3
##
## Fixed effects:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -1.2631    0.2780  -4.544 5.52e-06 ***
## GrupoB           0.8538    0.3338   2.558  0.0105 *
## GenotipoAa       0.3544    0.3452   1.027  0.3046
## GenotipoAA       1.4882    0.3321   4.481 7.43e-06 ***
## GrupoB:GenotipoAa  0.6549    0.4635   1.413  0.1577
## GrupoB:GenotipoAA  1.0150    0.5194   1.954  0.0507 .
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
##              (Intr) GrupoB GntpA GntpAA GrB:GA
## GrupoB      -0.698
## GenotipoAa  -0.674  0.561
## GenotipoAA  -0.703  0.584  0.564
## GrupB:GntpA  0.501 -0.719 -0.745 -0.419
## GrpB:GntpAA  0.447 -0.642 -0.361 -0.638  0.463
confint(fitrl_all_misto)
```

```
##              2.5 %      97.5 %
## .sig01        0.00000000 0.7400220
## (Intercept)   -1.85427796 -0.7118414
## GrupoB        0.20815405  1.5214510
## GenotipoAa    -0.31925591  1.0397236
## GenotipoAA     0.85028101  2.1561738
## GrupoB:GenotipoAa -0.25506039  1.5652368
## GrupoB:GenotipoAA  0.01118295  2.0566793
```

Regressão Logística combinada: No modelo logístico considerando as três variáveis fixas, tivemos como significativas somente GrupoB, Pop2, Pop3, GenotipoAA:Pop2 e GenotipoAA:Pop3; ou seja, reconheceu-se tanto do efeito de grupo quanto da população como relevantes para a hipertensão, assim o efeito combinado de População e do genótipo homozigoto dominante. Isso é um resultado bem diferente do observado na questão 2.d com ANOVA, mas examinando os perfis de médias dos dados, é possível ver que cada um dos efeitos detectados faz sentido. As únicas caselas que se concentram acima do *threshold* são do Grupo B e Populações 2 e 3, e a grupo B /times P1 tem média em torno de 90mmHg, distribuindo-se uniformemente entre os desfechos clínicos da variável dicotomizada. O efeito do genótipo AA sozinho realmente não leva as médias acima de 90mmHg, mas com Pop = P2 ou P3 e Grupo B, o salto é expressivo. Vemos aqui outro bom exemplo de como a dicotomização da variável estudada muda de acordo com o objetivo do estudo em si. No modelo com Pop como variável aleatória, foram considerados significativos o GrupoB e GenotipoAA. Mas a interação GrupoB:GenotipoAA não foi mais significativa ($p = 0,051$), o que se explica principalmente pela perda de poder estatístico decorrente da dicotomização de Y. A inclusão do efeito aleatório contribui marginalmente para essa redução, mas não é o fator principal — diferentemente do que ocorreria se houvesse grande variância interpopulacional a ser acomodada. Quanto à importância da Pop aleatória sobre Y dicotomizada, assim como no modelo contínuo, a variância do efeito aleatório de População foi muito baixa (0,037), e o intervalo de confiança para seu desvio-padrão inclui zero (IC 95%: [0,000 ; 0,740]), indicando que as populações são homogêneas em relação ao desfecho binário após controle de Grupo e Genótipo.

3.6 Comparação ANOVA vs. Regressão Logística

```
library(knitr)

# helpers
fmt <- function(x) ifelse(is.na(x), "-",
                          ifelse(x < 0.001, "< 0.001",
                                  formatC(x, digits = 3, format = "f")))

get_pv_aov <- function(fit_aov, term) {
  s <- summary(fit_aov)[[1]]
```

```

rownames(s) <- trimws(rownames(s))
if (term %in% rownames(s)) s[term, "Pr(>F)"] else NA
}

get_pv_glm <- function(fit_glm, term) {
  cf <- summary(fit_glm)$coef
  if (term %in% rownames(cf)) cf[term, "Pr(>|z|)"] else NA
}

get_pv_lm <- function(fit_lm, term) {
  cf <- summary(fit_lm)$coef
  if (term %in% rownames(cf)) cf[term, "Pr(>|t|)"] else NA
}

# Q1 Caso 1
fit_lm_q1c1 <- lm(Y ~ xa + xd, data = dat1)
anova_q1c1 <- anova(fit_lm_q1c1)

pv_anova_q1_xa <- anova_q1c1["xa", "Pr(>F)"]
pv_anova_q1_xd <- anova_q1c1["xd", "Pr(>F)"]
pv_logit_q1_xa <- get_pv_glm(fitrl1_ad, "xa")
pv_logit_q1_xd <- get_pv_glm(fitrl1_ad, "xd")

# Q1 Caso 2 (modelos reduzidos)
anova_q1c2 <- anova(fit2_reduzido)
logit_q1c2 <- summary(fitrl2_reduzido)$coef

get_a2 <- function(term) {
  if (term %in% rownames(anova_q1c2)) anova_q1c2[term, "Pr(>F)"] else NA
}
get_l2 <- function(term) {
  if (term %in% rownames(logit_q1c2)) logit_q1c2[term, "Pr(>|z|)"] else NA
}

# Q2 por população (corte = 90 mmHg)
make_logit_pop <- function(dat) {
  dat$Ybin <- as.factor(ifelse(dat$Y > 90, 1, 0))
  glm(Ybin ~ Grupo * Genotipo, family = binomial(link = "logit"), data = dat)
}

fit_logit_P1 <- make_logit_pop(dat_P1)
fit_logit_P2 <- make_logit_pop(dat_P2)
fit_logit_P3 <- make_logit_pop(dat_P3)

# P1
pv_aov_P1_grp <- get_pv_aov(res_P1$fit_cat, "Grupo")
pv_aov_P1_geno <- get_pv_aov(res_P1$fit_cat, "Genotipo")
pv_aov_P1_int <- get_pv_aov(res_P1$fit_cat, "Grupo:Genotipo")
pv_glm_P1_grp <- get_pv_glm(fit_logit_P1, "GrupoB")
pv_glm_P1_geno <- get_pv_glm(fit_logit_P1, "GenotipoAA")
pv_glm_P1_int <- get_pv_glm(fit_logit_P1, "GrupoB:GenotipoAA")

# P2

```

```

pv_aov_P2_grp <- get_pv_aov(res_P2$fit_cat, "Grupo")
pv_aov_P2_geno <- get_pv_aov(res_P2$fit_cat, "Genotipo")
pv_aov_P2_int <- get_pv_aov(res_P2$fit_cat, "Grupo:Genotipo")
pv_glm_P2_grp <- get_pv_glm(fit_logit_P2, "GrupoB")
pv_glm_P2_geno <- get_pv_glm(fit_logit_P2, "GenotipoAA")
pv_glm_P2_int <- get_pv_glm(fit_logit_P2, "GrupoB:GenotipoAA")

# P3
pv_aov_P3_grp <- get_pv_aov(res_P3$fit_cat, "Grupo")
pv_aov_P3_geno <- get_pv_aov(res_P3$fit_cat, "Genotipo")
pv_aov_P3_int <- get_pv_aov(res_P3$fit_cat, "Grupo:Genotipo")
pv_glm_P3_grp <- get_pv_glm(fit_logit_P3, "GrupoB")
pv_glm_P3_geno <- get_pv_glm(fit_logit_P3, "GenotipoAA")
pv_glm_P3_int <- get_pv_glm(fit_logit_P3, "GrupoB:GenotipoAA")

# Q2 Combinado - Pop FIXO
pv_aov_fix_grp <- get_pv_aov(fit_fixo, "Grupo")
pv_aov_fix_geno <- get_pv_aov(fit_fixo, "Genotipo")
pv_aov_fix_int <- get_pv_aov(fit_fixo, "Grupo:Genotipo")
pv_glm_fix_grp <- get_pv_glm(fitrl_all_fixo, "GrupoB")
pv_glm_fix_geno <- get_pv_glm(fitrl_all_fixo, "GenotipoAA")
pv_glm_fix_int <- get_pv_glm(fitrl_all_fixo, "GrupoB:GenotipoAA")

# Q2 Combinado - Pop ALEATÓRIO
lmer_cf <- as.data.frame(summary(fit_misto)$coef)
glmer_cf <- as.data.frame(summary(fitrl_all_misto)$coef)
pcol_lmer <- grep("Pr", colnames(lmer_cf), value = TRUE)[1]
pcol_glmer <- grep("Pr", colnames(glmer_cf), value = TRUE)[1]

get_pv_mx <- function(cf, row, pcol) {
  if (row %in% rownames(cf) && !is.na(pcol)) cf[row, pcol] else NA
}

pv_lmer_grp <- get_pv_mx(lmer_cf, "GrupoB", pcol_lmer)
pv_lmer_geno <- get_pv_mx(lmer_cf, "GenotipoAA", pcol_lmer)
pv_lmer_int <- get_pv_mx(lmer_cf, "GrupoB:GenotipoAA", pcol_lmer)
pv_glmer_grp <- get_pv_mx(glmer_cf, "GrupoB", pcol_glmer)
pv_glmer_geno <- get_pv_mx(glmer_cf, "GenotipoAA", pcol_glmer)
pv_glmer_int <- get_pv_mx(glmer_cf, "GrupoB:GenotipoAA", pcol_glmer)

# Montar tabela
comp <- data.frame(
  `Questão` = c(
    rep("Q1 - Caso 1", 2),
    rep("Q1 - Caso 2", 6),
    rep("Q2 - P1", 3),
    rep("Q2 - P2", 3),
    rep("Q2 - P3", 3),
    rep("Q2 - Combinado (Pop fixo)", 3),
    rep("Q2 - Combinado (Pop aleatório)", 3)
  ),
  `Efeito` = c(
    "xa (aditivo)", "xd (dominância)",

```

```

"xa1", "xd1", "xa2", "xd2",
"xa1:xa2 (epistasia a×a)", "xd1:xa2 (epistasia d×a)",
"Grupo", "Genótipo (AA)", "Grupo:Genótipo (AA)",
"Grupo", "Genótipo (AA)", "Grupo:Genótipo (AA)",
"Grupo", "Genótipo (AA)", "Grupo:Genótipo (AA)",
"Grupo", "Genótipo (AA)", "Grupo:Genótipo (AA)",
"GrupoB", "GenótipoAA", "GrupoB:GenótipoAA"
),
`p ANOVA / lmer` = fmt(c(
pv_anova_q1_xa,    pv_anova_q1_xd,
get_a2("xa1"),    get_a2("xd1"),
get_a2("xa2"),    get_a2("xd2"),
get_a2("xa1:xa2"), get_a2("xd1:xa2"),
pv_aov_P1_grp, pv_aov_P1_geno, pv_aov_P1_int,
pv_aov_P2_grp, pv_aov_P2_geno, pv_aov_P2_int,
pv_aov_P3_grp, pv_aov_P3_geno, pv_aov_P3_int,
pv_aov_fix_grp, pv_aov_fix_geno, pv_aov_fix_int,
pv_lmer_grp,    pv_lmer_geno,    pv_lmer_int
)),
`p Logístico / glmer` = fmt(c(
pv_logit_q1_xa,    pv_logit_q1_xd,
get_l2("xa1"),    get_l2("xd1"),
get_l2("xa2"),    get_l2("xd2"),
get_l2("xa1:xa2"), get_l2("xd1:xa2"),
pv_glm_P1_grp, pv_glm_P1_geno, pv_glm_P1_int,
pv_glm_P2_grp, pv_glm_P2_geno, pv_glm_P2_int,
pv_glm_P3_grp, pv_glm_P3_geno, pv_glm_P3_int,
pv_glm_fix_grp, pv_glm_fix_geno, pv_glm_fix_int,
pv_glmer_grp,    pv_glmer_geno,    pv_glmer_int
)),
check.names = FALSE
)

knitr::kable(comp,
  caption = paste("Comparação de p-valores: ANOVA/lmer vs. Regressão Logística/glmer.",
    "Q1C1: corte Y=111; Q1C2: corte Y=105 (modelos reduzidos);",
    "Q2 por pop: corte Y=90 mmHg; Q2 combinado: corte=mediana global."),
  align = c("l", "l", "r", "r"))

```

Table 4: Comparação de p-valores: ANOVA/lmer vs. Regressão Logística/glmer. Q1C1: corte Y=111; Q1C2: corte Y=105 (modelos reduzidos); Q2 por pop: corte Y=90 mmHg; Q2 combinado: corte=mediana global.

Questão	Efeito	p ANOVA / lmer	p Logístico / glmer
Q1 – Caso 1	xa (aditivo)	< 0.001	< 0.001
Q1 – Caso 1	xd (dominância)	< 0.001	< 0.001
Q1 – Caso 2	xa1	< 0.001	< 0.001
Q1 – Caso 2	xd1	< 0.001	< 0.001
Q1 – Caso 2	xa2	< 0.001	0.006
Q1 – Caso 2	xd2	0.001	0.001
Q1 – Caso 2	xa1:xa2 (epistasia a×a)	< 0.001	0.158
Q1 – Caso 2	xd1:xa2 (epistasia d×a)	0.001	0.021

Questão	Efeito	p ANOVA / lmer	p Logístico / glmer
Q2 – P1	Grupo	< 0.001	< 0.001
Q2 – P1	Genótipo (AA)	0.761	0.324
Q2 – P1	Grupo:Genótipo (AA)	0.755	0.424
Q2 – P2	Grupo	< 0.001	1.000
Q2 – P2	Genótipo (AA)	< 0.001	0.011
Q2 – P2	Grupo:Genótipo (AA)	0.324	0.074
Q2 – P3	Grupo	< 0.001	0.561
Q2 – P3	Genótipo (AA)	< 0.001	0.007
Q2 – P3	Grupo:Genótipo (AA)	< 0.001	0.033
Q2 – Combinado (Pop fixo)	Grupo	< 0.001	0.011
Q2 – Combinado (Pop fixo)	Genótipo (AA)	< 0.001	0.096
Q2 – Combinado (Pop fixo)	Grupo:Genótipo (AA)	< 0.001	0.167
Q2 – Combinado (Pop aleatório)	GrupoB	< 0.001	0.011
Q2 – Combinado (Pop aleatório)	GenotipoAA	< 0.001	< 0.001
Q2 – Combinado (Pop aleatório)	GrupoB:GenotipoAA	< 0.001	0.051

Impacto da dicotomização: Sim, há impacto da categorização nos resultados de significância. Ao longo da questão 3, percebemos que as mudanças observadas nos resultados de significância entre os testes de ANOVA e regressão logística são principalmente consequência da mudança da natureza do estudo, uma vez que não mais estudamos o efeito das variáveis sobre o valor Y em si, mas sim a sua influência sobre a alocação dos indivíduos em condições clínicas distintas. As interpretações a cada caso diferem entre os modelos. Na ANOVA, os coeficientes representam diferenças médias na resposta quantitativa, enquanto na regressão logística representam mudanças no *log-odds* e *odds ratios* associados à probabilidade do fenótipo dicotomizado. A categorização da variável resposta reduz a quantidade de informação disponível, pois diferentes valores contínuos passam a pertencer à mesma categoria binária. Em geral, isso pode reduzir o poder estatístico da análise. Contudo, mais que uma limitação, a dicotomização é uma mudança de foco do estudo e uma ferramenta útil para responder a perguntas clínicas específicas, como a identificação de fatores de risco para uma condição. A escolha do ponto de corte é crucial e pode influenciar significativamente os resultados, sendo importante ter consciência da relevância biológica da dicotomização adotada nesse processo.