

IBI5086 – Lista 2 (1º Sem/2026)

Grupo 4: Amanda Gonçalves, Carlos Lima, Daniel Nogueira, Guilherme Zonzin, Lucas Ito, Victoria Mel

2026-05-14

Contents

1	Mapeamento de Genes: ANOVA com SNPs	1
1.1	Caso 1 – ANOVA 1 fator em 3 níveis (efeitos aditivo e de dominância)	1
1.1.1	Codificação dos efeitos aditivo (xa) e de dominância (xd)	4
1.1.2	Modelo com 2 g.l. – fatores aditivo e de dominância	4
1.1.3	Diagnóstico dos resíduos (Caso 1)	5
1.1.4	Comparações múltiplas de Tukey	6
1.2	Caso 2 – ANOVA Fatorial 3×3 (dois SNPs, efeitos aditivo, dominância e epistasia)	7
1.2.1	Modelo com efeitos aditivos, dominância e interações (8 g.l.)	9
2	Delineamento Fatorial 3×2: SNP $\times$ Subgrupo Populacional	13
2.1	Simulação dos dados (P1, P2, P3) (item a)	13
2.2	Análise por População	14
2.2.1	Função auxiliar para análise completa	14
2.2.2	P1 – Sem efeito de SNP, sem interação	15
2.2.3	P2 – Efeito aditivo de SNP, sem interação (perfis paralelos)	21
2.2.4	P3 – Efeito de SNP com interação (epistasia SNP $\times$ Subgrupo)	27
2.3	Item (d) – Combinando as três populações	35
2.3.1	(d.i) – Fatorial $3 \times 2 \times 3$: SNP $\times$ Grupo $\times$ População (todos fixos)	35
2.3.2	(d.ii) – Fatorial 3×2 com População como fator aleatório (ANOVA Mista)	37
3	Regressão Logística: Y dicotomizada	38
3.1	Dicotomização de Y	38
3.2	Questão 1 (Caso 1) – Regressão Logística	39
3.3	Questão 1 (Caso 2) – Regressão Logística com dois SNPs	42
3.4	Questão 2 – Regressão Logística por População	43
3.5	Regressão Logística Combinada (3 populações)	47
3.6	Comparação ANOVA vs. Regressão Logística	48

1 Mapeamento de Genes: ANOVA com SNPs

Gerar X (binomial) e Y (normal); ajustar modelos de ANOVA.

1.1 Caso 1 – ANOVA 1 fator em 3 níveis (efeitos aditivo e de dominância)

```
set.seed(8732)
n_por_genot <- 100
```

```

# X: genótipos 0=aa, 1=Aa, 2=AA (distribuição ~binomial(2, p=0.3))
# probabilidades Hardy-Weinberg com p=0.3
p <- 0.3
freq <- c((1-p)^2, 2*p*(1-p), p^2) # aa, Aa, AA
snp <- sample(0:2, n_por_genot*3, replace=TRUE, prob=freq)

# Y: resposta com efeito aditivo (a=10) e dominância (d=5) sobre a média basal 100
# mu_aa=100, mu_Aa=115 (=100+d, com d=5 sobre midpoint), mu_AA=120 (=100+2a)
# Parametrização: a=(mu_AA-mu_aa)/2=10; d=mu_Aa-(mu_AA+mu_aa)/2=5
mu <- c(100, 115, 120)[snp + 1]
Y1 <- rnorm(length(snp), mean = mu, sd = 5)

dat1 <- data.frame(Y = Y1, SNP = factor(snp, labels = c("aa","Aa","AA")),
                  snp_num = snp)

# Estatísticas descritivas por genótipo
library(psych)
descr1 <- describeBy(dat1, group = "SNP", mat = TRUE)

tabela1 <- descr1[c("Y1", "Y2", "Y3"), c("group1","n","mean","sd","median","min","max")]
tabela1$group1 <- c("aa", "Aa", "AA")
rownames(tabela1) <- NULL

knitr::kable(tabela1, digits = 2,
             col.names = c("genotype","n","mean","sd","median","min","max"),
             caption = "Estatísticas descritivas de Y por genótipo (Caso 1)")

```

Table 1: Estatísticas descritivas de Y por genótipo (Caso 1)


genotype	n	mean	sd	median	min	max
aa	148	100.16	5.08	100.43	85.72	111.76
Aa	123	114.57	4.94	114.23	102.09	130.30
AA	29	120.15	4.63	120.39	109.25	128.01

```

boxplot(Y ~ SNP, data = dat1, col = c("lightblue","lightgreen","lightyellow"),
        main = "Distribuição de Y por Genótipo (Caso 1)", xlab = "Genótipo", ylab = "Y")


```

Distribuição de Y por Genótipo (Caso 1)



```
# Perfil de médias
medias1 <- tapply(dat1$Y, dat1$SNP, mean)
plot(0:2, medias1, type = "b", pch = 19, col = "red",
     xaxt = "n", xlab = "Genótipo", ylab = "Média de Y",
     main = "Perfil de Médias - Caso 1")
axis(1, at = 0:2, labels = c("aa", "Aa", "AA"))
```

Perfil de Médias – Caso 1



1.1.1 Codificação dos efeitos aditivo (xa) e de dominância (xd)

```
# xa: -1 (aa), 0 (Aa), 1 (AA) → captura efeito aditivo
# xd: 0 (aa), 1 (Aa), 0 (AA) → captura desvio de dominância
dat1$xa <- dat1$snp_num - 1
dat1$xd <- ifelse(dat1$snp_num == 1, 1, 0)
```

1.1.2 Modelo com 2 g.l. – fatores aditivo e de dominância

```
fit1_ad <- lm(Y ~ xa + xd, data = dat1)
summary(fit1_ad)
```

```
##
## Call:
## lm(formula = Y ~ xa + xd, data = dat1)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -14.4366  -3.3116  -0.0913   3.2016  15.7234
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  110.1521     0.5061  217.649 < 2e-16 ***
## xa           9.9967     0.5061   19.752 < 2e-16 ***
## xd           4.4209     0.6768    6.532 2.82e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.984 on 297 degrees of freedom
## Multiple R-squared:  0.7171, Adjusted R-squared:  0.7152
## F-statistic: 376.4 on 2 and 297 DF,  p-value: < 2.2e-16

anova(fit1_ad)
```

```
## Analysis of Variance Table
##
## Response: Y
##          Df Sum Sq Mean Sq F value    Pr(>F)
## xa         1 17642.1  17642.1  710.116 < 2.2e-16 ***
## xd         1  1059.9   1059.9   42.663 2.817e-10 ***
## Residuals 297  7378.6     24.8
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Discussão: Interpretação dos coeficientes

O intercepto estimado ($\hat{\mu} = 110,15$) representa o ponto médio entre as médias dos homozigotos, $(\mu_{AA} + \mu_{aa})/2$.


O efeito aditivo (xa, $\hat{a} = 9,99$) é altamente significativo ($p < 0,001$), indicando que cada alelo A adicional eleva Y em aproximadamente 10 unidades.

O efeito de dominância (xd, $\hat{d} = 4,42$) é significativo ($p < 0,001$) e positivo, indicando que o heterozigoto acrescenta em torno de 4,42 unidades à média de Y.

O modelo explica cerca de 72% da variância total de Y ($R^2 = 0,717$).

1.1.3 Diagnóstico dos resíduos (Caso 1)

```
par(mfrow = c(2,2))
plot(fit1_ad)
```



```
par(mfrow = c(1,1))
```

```
shapiro.test(fit1_ad$residuals)
```

```
##
## Shapiro-Wilk normality test
##
## data: fit1_ad$residuals
## W = 0.99764, p-value = 0.9466
```

```
bartlett.test(Y ~ SNP, data = dat1)
```

```
##
## Bartlett test of homogeneity of variances
##
## data: Y by SNP
## Bartlett's K-squared = 0.42151, df = 2, p-value = 0.81
```

Discussão dos gráficos de diagnóstico

Residuals vs Fitted: dispersão vertical nas três colunas parece similar, e a linha vermelha está praticamente horizontal. Aleatoriedade OK.

Q-Q Residuals: pontos muito bem aderidos à diagonal. Normalidade bem satisfeita.

Sale-Location: Dispersão bem uniforme, linha vermelha praticamente horizontal, homocedasticidade bem satisfeita. As três observações rotuladas são outliers, nada alarmante.

Residuals vs Leverage: As observações do genótipo AA concentram-se à direita ($\sim 0,033$), com maior leverage que os demais genótipos — esperado dado sua menor frequência amostral sob Hardy-Weinberg ($p=0,3$, $\sim 9\%$ de AA). Ainda assim, a linha de Cook aparece colapsada na borda esquerda do gráfico, indicando que nenhuma observação exerce influência desproporcional sobre os coeficientes. O modelo é estável.

Testes de diagnóstico: O teste de Shapiro-Wilk **não rejeita** a normalidade dos resíduos ($W = 0,998$; $p = 0,947$), e o teste de Bartlett **não rejeita** a homogeneidade de variâncias entre os três genótipos ($K^2 = 0,42$; $gl = 2$; $p = 0,810$). Ambos os resultados confirmam que as suposições do modelo linear são satisfeitas, em concordância com o diagnóstico visual dos gráficos.


1.1.4 Comparações múltiplas de Tukey

```
fit1_aov <- aov(Y ~ SNP, data = dat1)
TukeyHSD(fit1_aov)

##    Tukey multiple comparisons of means
##      95% family-wise confidence level
##
## Fit: aov(formula = Y ~ SNP, data = dat1)
##
## $SNP
##           diff           lwr          upr p adj
## Aa-aa 14.417637 12.985123 15.850151 0e+00
## AA-aa 19.993374 17.609109 22.377639 0e+00
## AA-Aa  5.575737  3.152098  7.999376 4e-07

par(mar=c(5,8,4,2))
plot(TukeyHSD(fit1_aov))
```

95% family-wise confidence level



Comparações múltiplas de Tukey: O teste de Tukey HSD compara os três genótipos par a par com controle da taxa de erro familiar a 5%. Aa-aa (diff = 14,42; $p < 0,001$), AA-aa (diff = 19,99; $p < 0,001$) e AA-Aa (diff = 5,58; $p < 0,001$) são todos significativos, confirmando que cada alelo A adicional eleva a média de Y (~10) e que o heterozigoto sofre influência positiva do fator de dominância (~5).

1.2 Caso 2 – ANOVA Fatorial 3×3 (dois SNPs, efeitos aditivo, dominância e epistasia)

```
set.seed(8732)
n_cell <- 100 # por célula (genótipo conjunto)

# SNP1 e SNP2 gerados independentemente (HWE, p1=0.3, p2=0.4)
p1 <- 0.3; p2 <- 0.4
freq1 <- c((1-p1)^2, 2*p1*(1-p1), p1^2)
freq2 <- c((1-p2)^2, 2*p2*(1-p2), p2^2)

snp1 <- sample(0:2, n_cell*9, replace=TRUE, prob=freq1)
snp2 <- sample(0:2, n_cell*9, replace=TRUE, prob=freq2)

# Estrutura de médias com epistasia (interação a1*a2)
# mu_base + a1_efeito + a2_efeito + interacao
a1 <- 8; d1 <- 4; a2 <- 6; d2 <- 3

xa1 <- snp1 - 1 # -1, 0, 1
xd1 <- ifelse(snp1==1, 1, 0) # 0, 1, 0
xa2 <- snp2 - 1
xd2 <- ifelse(snp2==1, 1, 0)
```

```

# Modelo com efeitos e interações
mu2 <- 100 + a1*xa1 + d1*xd1 + a2*xa2 + d2*xd2 +
      3*xa1*xa2 + 1.5*xa1*xd2 + 1.5*xd1*xa2 + 1*xd1*xd2

Y2 <- rnorm(length(mu2), mean = mu2, sd = 12)

dat2 <- data.frame(
  Y = Y2,
  SNP1 = factor(snp1, labels = c("a1a1", "a1A1", "A1A1")),
  SNP2 = factor(snp2, labels = c("a2a2", "a2A2", "A2A2")),
  xa1 = xa1, xd1 = xd1, xa2 = xa2, xd2 = xd2
)

# Estatísticas descritivas
cat("Dimensões do dataset (Caso 2):", nrow(dat2), "observações\n")

## Dimensões do dataset (Caso 2): 900 observações
tapply(dat2$Y, list(dat2$SNP1, dat2$SNP2), mean) |>
  round(2) |>
  knitr::kable(caption = "Médias de Y por combinação genotípica (Caso 2)")

```

Table 2: Médias de Y por combinação genotípica (Caso 2)


	a2a2	a2A2	A2A2
a1a1	89.06	93.35	94.94
a1A1	97.11	109.38	113.98
A1A1	102.20	111.63	115.31

```

with(dat2,
  interaction.plot(SNP2, SNP1, Y, col = 1:3,
    main = "Perfil de Médias - Caso 2 (Epistasia)",
    xlab = "Genótipo SNP2", ylab = "Média Y",
    lwd = 2, pch = 19, type = "b"))

```

Perfil de Médias – Caso 2 (Epistasia)



O perfil de médias evidencia epistasia entre SNP1 e SNP2: o efeito de cada SNP sobre Y depende do genótipo do outro. Quanto mais alelos A1 o indivíduo carrega, maior o ganho em Y proporcionado pelos alelos A2 — padrão consistente com a epistasia aditiva $\times$ aditiva ($a_1 \times a_2 = 3$) simulada no modelo verdadeiro.

1.2.1 Modelo com efeitos aditivos, dominância e interações (8 g.l.)

```
# Parametrização explícita: xa1, xd1, xa2, xd2 e 4 termos de interação
fit2_completo <- lm(Y ~ xa1 + xd1 + xa2 + xd2 +
                    xa1:xa2 + xa1:xd2 + xd1:xa2 + xd1:xd2,
                    data = dat2)
summary(fit2_completo)
```

```
##
## Call:
## lm(formula = Y ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xa1:xd2 +
##     xd1:xa2 + xd1:xd2, data = dat2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -40.274  -8.232  -0.041   7.851  36.568
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  100.3781     0.9026  111.214 < 2e-16 ***
## xa1           8.3782     0.9026   9.283 < 2e-16 ***
## xd1           5.1671     1.2673   4.077 4.97e-05 ***
## xa2           4.7509     0.9026   5.264 1.77e-07 ***
## xd2           2.1117     1.3771   1.533 0.12552
## xa1:xa2       1.8061     0.9026   2.001 0.04568 *
## xa1:xd2       0.7633     1.3771   0.554 0.57955
```

```
## xd1:xa2      3.6857      1.2673      2.908 0.00372 **
## xd1:xd2      1.7276      1.8710      0.923 0.35608
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 11.65 on 891 degrees of freedom
## Multiple R-squared:  0.3604, Adjusted R-squared:  0.3547
## F-statistic: 62.76 on 8 and 891 DF,  p-value: < 2.2e-16
anova(fit2_completo)
```

```
## Analysis of Variance Table
##
## Response: Y
##          Df Sum Sq Mean Sq  F value    Pr(>F)
## xa1         1  42983   42983 316.6776 < 2.2e-16 ***
## xd1         1   3509    3509  25.8516 4.495e-07 ***
## xa2         1  16343   16343 120.4054 < 2.2e-16 ***
## xd2         1   1409    1409  10.3809 0.001319 **
## xa1:xa2      1   2194    2194  16.1635 6.302e-05 ***
## xa1:xd2      1    284     284   2.0929 0.148337
## xd1:xa2      1   1313    1313   9.6731 0.001929 **
## xd1:xd2      1    116     116   0.8526 0.356076
## Residuals 891 120937    136
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Como houve discrepância entre os resultados da regressão linear e da ANOVA do modelo completo, foi ajustado um modelo reduzido contendo apenas os termos significativos na ANOVA.

```
fit2_reduzido <- lm(Y ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xd1:xa2, data = dat2)
summary(fit2_reduzido)
```

```
##
## Call:
## lm(formula = Y ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xd1:xa2, data = dat2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -40.681  -8.154  -0.101   8.047  36.959
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  100.1734     0.7717  129.806 < 2e-16 ***
## xa1           8.7385     0.6813   12.826 < 2e-16 ***
## xd1           6.0316     0.9303    6.484 1.48e-10 ***
## xa2           4.6699     0.9007    5.185 2.67e-07 ***
## xd2           2.5019     0.8016    3.121 0.00186 **
## xa1:xa2       1.8991     0.8989    2.113 0.03491 *
## xd1:xa2       4.0195     1.2435    3.233 0.00127 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 11.65 on 893 degrees of freedom
## Multiple R-squared:  0.3589, Adjusted R-squared:  0.3546
## F-statistic: 83.31 on 6 and 893 DF,  p-value: < 2.2e-16
```

```
anova(fit2_reduzido)
```

```
## Analysis of Variance Table
##
## Response: Y
##           Df Sum Sq Mean Sq F value    Pr(>F)
## xa1         1  42983    42983 316.618 < 2.2e-16 ***
## xd1         1   3509     3509  25.847 4.504e-07 ***
## xa2         1  16343    16343 120.383 < 2.2e-16 ***
## xd2         1   1409     1409  10.379 0.001321 **
## xa1:xa2      1   2194     2194  16.160 6.311e-05 ***
## xd1:xa2      1   1419     1419  10.449 0.001272 **
## Residuals 893 121231      136
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
anova(fit2_reduzido, fit2_completo)
```

```
## Analysis of Variance Table
##
## Model 1: Y ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xd1:xa2
## Model 2: Y ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xa1:xd2 + xd1:xa2 + xd1:xd2
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      893 121231
## 2      891 120937  2    294.15 1.0836 0.3388
```

Os modelos foram comparados por ANOVA para modelos aninhados, e como não houve diferença significativa entre eles ($p = 0,3388$), optou-se pelo modelo reduzido.

Interpretação:

- **xa1** e **xa2**: efeitos aditivos dos SNP1 e SNP2, respectivamente.
- **xd1** e **xd2**: desvios de dominância de cada SNP.
- **xa1:xa2** ($a_1 \times a_2$): **epistasia aditiva** $\times$ **aditiva** – interação entre os efeitos aditivos.
- **xa1:xd2** ($a_1 \times d_2$), **xd1:xa2** ($d_1 \times a_2$): epistasias mistas.
- **xd1:xd2** ($d_1 \times d_2$): epistasia dominância $\times$ dominância.


O modelo explica ~35,9% da variância de Y ($R^2 = 0,359$) e é globalmente significativo ($F = 83,31$; $p < 0,001$). O erro padrão residual (~11,65) está próximo do valor verdadeiro simulado ($\sigma = 12$), indicando bom ajuste.

Efeitos principais: os efeitos aditivos de ambos os SNPs são significativos — **xa1** ($\hat{a}_1 = 8,74$; $p < 0,001$) e **xa2** ($\hat{a}_2 = 4,67$; $p < 0,001$) — indicando que cada alelo A adicional em cada loco eleva Y independentemente, próximo aos valores verdadeiros simulados ($a_1 = 8$, $a_2 = 6$). Os efeitos de dominância **xd1** e **xd2** também são significativos pelo summary ($p < 0,001$ e $p < 0,01$). Entretanto, como foi detectada epistasia aditiva $\times$ aditiva e dominância $\times$ aditiva entre os alelos, a interpretação isolada dos efeitos principais pode não ser adequada.

Epistasia: as interações aditiva $\times$ aditiva **xa1:xa2** e dominância $\times$ aditiva **xd1:xa2** são significativas na tabela ANOVA (**xa1:xa2** -> $F = 16,16$; $p < 0,001$ | **xd1:xa2** -> $F = 10,45$; $p < 0,01$). As demais interações não atingem significância, embora o valor verdadeiro simulado das interações **xd1:xa2** e **xa1:xd2** fossem idênticos (1.5x). A diferença em significância é reflexo da variação amostral e não um erro.

Em conjunto, os resultados confirmam que o fenótipo Y é influenciado pelos efeitos aditivos de dois locos e por sua interação epistática, padrão visualmente antecipado pelo não-paralelismo das linhas no perfil de médias.

```
par(mfrow = c(2,2)); plot(fit2_completo); par(mfrow = c(1,1))
```



```
shapiro.test(fit2_completo$residuals)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  fit2_completo$residuals
## W = 0.99908, p-value = 0.9438
```

Diagnóstico dos resíduos – Caso 2:

Residuals vs Fitted: os pontos distribuem-se em colunas verticais correspondentes às 9 combinações genotípicas (células do fatorial 3×3), padrão esperado com preditores discretos. A linha vermelha é aproximadamente horizontal em 0, sem curvatura sistemática, indicando que o modelo linear é adequado.

Q-Q Residuals: excelente aderência à diagonal em toda a extensão central, com desvios pequenos nas caudas. A normalidade dos resíduos é confirmada formalmente pelo teste de Shapiro-Wilk ($W = 0,999$; $p = 0,944$), que não rejeita H_0 .

Scale-Location: a linha vermelha é praticamente horizontal e a distribuição dos resíduos aparenta ser uniforme.

Residuals vs Leverage: os pontos se distribuem em faixas de leverage distintas, refletindo as diferentes frequências das 9 células genotípicas — células raras (como A1A1 com $p_1=0,3$) têm maior leverage. Ainda assim, a linha de Cook permanece colapsada na borda inferior do gráfico, indicando que nenhuma observação exerce influência desproporcional sobre os coeficientes.

2 Delineamento Fatorial 3×2 : SNP $\times$ Subgrupo Populacional

2.1 Simulação dos dados (P1, P2, P3) (item a)

```
set.seed(8732)
n_rep <- 30 # réplicas
sigma <- 8 # desvio padrão

# Médias fornecidas na lista
medias_pop <- list(
  P1 = matrix(c(80,80,80, 90,90,90), nrow=2, byrow=TRUE,
    dimnames=list(c("A","B"), c("aa","Aa","AA"))),
  P2 = matrix(c(75,80,90, 80,86,97), nrow=2, byrow=TRUE,
    dimnames=list(c("A","B"), c("aa","Aa","AA"))),
  P3 = matrix(c(75,80,85, 75,85,100), nrow=2, byrow=TRUE,
    dimnames=list(c("A","B"), c("aa","Aa","AA")))
)

# Gerar dados para cada população
gerar_pop <- function(mmat, n, sigma, pop_nome) {
  rows <- list()
  for (grp in rownames(mmat)) {
    for (geno in colnames(mmat)) {
      y <- rnorm(n, mean = mmat[grp, geno], sd = sigma)
      rows[[length(rows)+1]] <- data.frame(
        Y = y, Grupo = grp, Genotipo = geno,
        Geno_num = match(geno, c("aa","Aa","AA")) - 1,
        Pop = pop_nome
      )
    }
  }
  do.call(rbind, rows)
}

dat_P1 <- gerar_pop(medias_pop$P1, n_rep, sigma, "P1")
dat_P2 <- gerar_pop(medias_pop$P2, n_rep, sigma, "P2")
dat_P3 <- gerar_pop(medias_pop$P3, n_rep, sigma, "P3")

# Ordenar fatores
dat_P1$Genotipo <- factor(dat_P1$Genotipo, levels=c("aa","Aa","AA"))
dat_P2$Genotipo <- factor(dat_P2$Genotipo, levels=c("aa","Aa","AA"))
dat_P3$Genotipo <- factor(dat_P3$Genotipo, levels=c("aa","Aa","AA"))
```

Contextualização (item b): Os dados representam medições de pressão arterial diastólica em repouso (mmHg) em indivíduos de três populações distintas (P1, P2, P3), classificados segundo o genótipo de um SNP (aa, Aa, AA) e a origem geográfica (A e B). Adotou-se $n = 30$ réplicas por co-ordenada (Grupo $\times$ Genótipo) $\sigma = 8$ mmHg. As três populações representam cenários distintos: **P1** sem efeito do SNP (apenas diferença entre subgrupos: $B \approx 10$ mmHg acima de A); **P2** com efeito do SNP e perfis paralelos entre subgrupos; e **P3** com interação SNP $\times$ subgrupo, onde o efeito do SNP é modesto em A (+10 mmHg de aa $\rightarrow$ AA) mas acentuado em B (+25 mmHg), sugerindo que fatores populacionais do subgrupo B potencializam o efeito do SNP sobre

a pressão diastólica.

2.2 Análise por População

2.2.1 Função auxiliar para análise completa

```
analisa_pop <- function(dat, nome_pop) {  
  cat("\n\n===== \n")  
  cat(" POPULAÇÃO:", nome_pop, "\n")  
  cat("===== \n\n")  
  
  # (i) Estatísticas descritivas  
  cat("--- (i) Estatísticas Descritivas --- \n")  
  desc <- describeBy(dat, group = list(dat$Grupo, dat$Genotipo), mat=TRUE)  
  print(knitr::kable(desc[grepl("^Y", rownames(desc)),  
                      c("group1", "group2", "n", "mean", "sd", "median")],  
        digits=2, caption=paste("Descritivas -", nome_pop)))  
  
  # (ii) Perfil de médias  
  par(mfrow=c(1,2))  
  with(dat,  
        interaction.plot(Genotipo, Grupo, Y,  
                          col=c("red", "blue"), lwd=2, pch=19, type="b",  
                          main=paste("Perfil de Médias -", nome_pop),  
                          xlab="Genótipo SNP", ylab="Média Y"))  
  
  # Boxplot  
  boxplot(Y ~ Grupo:Genotipo, data=dat, col=c("lightcoral", "lightblue"),  
          main=paste("Boxplot -", nome_pop),  
          xlab="Grupo:Genótipo", ylab="Y", las=2, cex.axis=0.7)  
  par(mfrow=c(1,1))  
  
  # (iii) ANOVA Fatorial 3$times$2 - fator categórico  
  cat("\n--- (iii) ANOVA Fatorial 3x2 (Genotipo categórico) --- \n")  
  fit_cat <- aov(Y ~ Grupo * Genotipo, data=dat)  
  print(summary(fit_cat))  
  cat("\nCoeficientes: \n")  
  print(coef(fit_cat))  
  
  # Diagnóstico resíduos  
  par(mfrow=c(2,2)); plot(fit_cat); par(mfrow=c(1,1))  
  cat("\nShapiro-Wilk (normalidade resíduos): \n")  
  print(shapiro.test(fit_cat$residuals))  
  cat("\nBartlett (homocedasticidade): \n")  
  print(bartlett.test(Y ~ interaction(Grupo, Genotipo), data=dat))  
  
  # Tukey  
  cat("\nComparações múltiplas de Tukey: \n")  
  tk <- TukeyHSD(fit_cat)  
  print(tk)  
  plot(tk, las=1, cex.axis=0.6)
```

```

# (iv) SNP como variável quantitativa (1 g.l. - efeito linear)
cat("\n--- (iv) SNP como variável quantitativa (efeito aditivo linear) ---\n")
fit_num <- lm(Y ~ Grupo * Geno_num, data=dat)
print(summary(fit_num))
print(anova(fit_num))

cat("\nComparação R²: categórico =", round(summary(lm(Y ~ Grupo * Genotipo, data=dat))$r.squared, 3),
    "| quantitativo =", round(summary(fit_num)$r.squared, 3), "\n")

invisible(list(fit_cat=fit_cat, fit_num=fit_num))
}

```



2.2.2 P1 – Sem efeito de SNP, sem interação

```





res_P1 <- analisa_pop(dat_P1, "P1")

##
##
## =====
## POPULAÇÃO: P1
## =====
##
## --- (i) Estatísticas Descritivas ---
##
##
## Table: Descritivas - P1
##
## | |group1 |group2 | n| mean| sd| median|
## |:-:|:-----|:-----|--:|-----:|-----:|-----:|
## |Y1 |A      |aa      | 30| 79.95| 7.92| 79.10|
## |Y2 |B      |aa      | 30| 90.51| 9.23| 90.51|
## |Y3 |A      |Aa      | 30| 78.93| 9.11| 79.71|
## |Y4 |B      |Aa      | 30| 91.34| 6.16| 90.93|
## |Y5 |A      |AA      | 30| 78.98| 5.76| 78.81|
## |Y6 |B      |AA      | 30| 89.59| 7.35| 90.83|

```




```
##
## --- (iii) ANOVA Fatorial 3x2 (Genotipo categórico) ---
##               Df Sum Sq Mean Sq F value Pr(>F)
## Grupo         1   5637    5637  94.959 <2e-16 ***
## Genotipo       2     32      16   0.273  0.761
## Grupo:Genotipo 2     33      17   0.281  0.755
## Residuals     174  10328      59
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Coeficientes:
##      (Intercept)          GrupoB      GenotipoAa      GenotipoAA  GrupoB:GenotipoAa  GrupoB:Gen
##      79.95232024      10.55691612     -1.01984317     -0.96910237      1.85320676      0.0
```




```
##
## Shapiro-Wilk (normalidade resíduos):
##
## Shapiro-Wilk normality test
##
## data: fit_cat$residuals
## W = 0.99448, p-value = 0.7439
##
## Bartlett (homocedasticidade):
##
## Bartlett test of homogeneity of variances
##
## data: Y by interaction(Grupo, Genotipo)
## Bartlett's K-squared = 10.56, df = 5, p-value = 0.06083
##
##
## Comparações múltiplas de Tukey:
## Tukey multiple comparisons of means
## 95% family-wise confidence level
##
## Fit: aov(formula = Y ~ Grupo * Genotipo, data = dat)
##
## $Grupo
##      diff      lwr      upr p adj
## B-A 11.19187 8.925067 13.45868    0
```

```
##
## $Genotipo
##           diff           lwr           upr           p adj
## Aa-aa -0.09323979 -3.418441  3.231961  0.9975806
## AA-aa -0.94326914 -4.268470  2.381932  0.7808776
## AA-Aa -0.85002935 -4.175230  2.475172  0.8179569
##
## $`Grupo:Genotipo`
##           diff           lwr           upr           p adj
## B:aa-A:aa  10.55691612   4.824323  16.289509  0.0000050
## A:Aa-A:aa  -1.01984317  -6.752436   4.712750  0.9956337
## B:Aa-A:aa  11.39027971   5.657687  17.122873  0.0000007
## A:AA-A:aa  -0.96910237  -6.701695   4.763490  0.9965684
## B:AA-A:aa   9.63948021   3.906887  15.372073  0.0000406
## A:Aa-B:aa -11.57675930 -17.309352  -5.844166  0.0000004
## B:Aa-B:aa   0.83336358  -4.899229   6.565956  0.9983292
## A:AA-B:aa -11.52601849 -17.258611  -5.793426  0.0000005
## B:AA-B:aa  -0.91743592  -6.650029   4.815157  0.9973543
## B:Aa-A:AA  12.41012288   6.677530  18.142716  0.0000000
## A:AA-A:AA   0.05074081  -5.681852   5.783334  1.0000000
## B:AA-A:AA  10.65932338   4.926731  16.391916  0.0000039
## A:AA-B:AA -12.35938207 -18.091975  -6.626789  0.0000001
## B:AA-B:AA  -1.75079950  -7.483392   3.981793  0.9508273
## B:AA-A:AA  10.60858257   4.875990  16.341175  0.0000044
```


95% family-wise confidence level



95% family-wise confidence level



95% family-wise confidence level



Differences in mean levels of Grupo:Genotipo

```
##
## --- (iv) SNP como variável quantitativa (efeito aditivo linear) ---
##
## Call:
## lm(formula = Y ~ Grupo * Geno_num, data = dat)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -19.1528  -5.2945   0.0742   5.0879  21.7213
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    79.77389     1.27917   62.364 < 2e-16 ***
## GrupoB         11.16604     1.80902    6.172 4.51e-09 ***
## Geno_num       -0.48455     0.99084   -0.489  0.625
## GrupoB:Geno_num  0.02583     1.40126    0.018  0.985
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 7.675 on 176 degrees of freedom
## Multiple R-squared:  0.3533, Adjusted R-squared:  0.3423
## F-statistic: 32.05 on 3 and 176 DF, p-value: < 2.2e-16
##
## Analysis of Variance Table
##
```

```
## Response: Y
##               Df Sum Sq Mean Sq F value Pr(>F)
## Grupo         1  5636.6   5636.6  95.6879 <2e-16 ***
## Geno_num       1    26.7    26.7   0.4531  0.5017
## Grupo:Geno_num 1     0.0     0.0   0.0003  0.9853
## Residuals     176 10367.5    58.9
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Comparação R²: categórico = 0.356 | quantitativo = 0.353
```

Interpretação P1:

Perfil de médias e boxplot: as linhas do perfil de médias oscilam levemente entre genótipos — a linha do subgrupo B sobe de aa para Aa e recua em AA, enquanto a do subgrupo A desce ligeiramente — mas essas variações refletem apenas flutuação amostral em torno das médias verdadeiras (80 mmHg em A e 90 mmHg em B para todos os genótipos). A separação vertical entre subgrupos é consistente e visualmente dominante. O boxplot corrobora: as distribuições dentro de cada subgrupo são similares entre genótipos, com dispersão compatível com $\sigma = 8$ mmHg.

ANOVA: apenas o efeito de Grupo é significativo ($F = 94,96$; $p < 0,001$). Os efeitos de Genótipo ($F = 0,27$; $p = 0,761$) e da interação Grupo×Genótipo ($F = 0,28$; $p = 0,755$) não são significativos, como esperado pela estrutura simulada.

Diagnóstico: normalidade (Shapiro-Wilk: $W = 0,994$; $p = 0,744$) e homocedasticidade (Bartlett: $K^2 = 10,56$; $p = 0,061$) satisfeitas. O gráfico “Constant Leverage” mostra resíduos uniformemente distribuídos entre os níveis de Grupo, sem padrões preocupantes.

Tukey: o contraste B-A é significativo ($\sim 11,2$ mmHg; $p < 0,001$). Todos os contrastes entre genótipos (Aa-aa, AA-aa, AA-Aa) incluem o zero nos ICs e têm $p > 0,75$, confirmando ausência de efeito do SNP sobre a pressão diastólica. No Tukey da interação Grupo:Genótipo, os únicos contrastes significativos são aqueles que comparam subgrupos opostos (ex.: B:aa-A:aa, B:Aa-A:Aa), confirmando que toda a significância se deve ao efeito de subgrupo, não ao SNP.


SNP quantitativo (item iv): o modelo com `Geno_num` confirma: coeficiente do SNP não significativo ($-0,48$; $p = 0,625$) e interação Grupo×Geno_num também não significativa ($p = 0,985$). O ajuste é praticamente equivalente ao modelo categórico ($R^2 = \text{categórico } 0.356 \mid \text{quantitativo } 0.353$), com a variância explicada quase integralmente pelo efeito de subgrupo populacional.

2.2.3 P2 – Efeito aditivo de SNP, sem interação (perfis paralelos)





```
res_P2 <- analisa_pop(dat_P2, "P2")

##
##
## =====
## POPULAÇÃO: P2
## =====
##
## --- (i) Estatísticas Descritivas ---
##
##
## Table: Descritivas - P2
##
## | |group1 |group2 | n| mean| sd| median|
## | :-- | :----- | :----- | --: | :----- | :----- | :----- |
```

##	Y1	A	aa		30	74.03	9.13	74.11
##	Y2	B	aa		30	79.11	7.25	78.43
##	Y3	A	Aa		30	79.76	8.37	79.23
##	Y4	B	Aa		30	84.61	7.90	83.63
##	Y5	A	AA		30	90.08	7.68	89.23
##	Y6	B	AA		30	98.91	8.27	101.49




##	--- (iii) ANOVA Fatorial 3x2 (Genotipo categórico) ---					
##		Df	Sum Sq	Mean Sq	F value	Pr(>F)
##	Grupo	1	1757	1757	26.627	6.68e-07 ***
##	Genotipo	2	10091	5046	76.474	< 2e-16 ***
##	Grupo:Genotipo	2	150	75	1.134	0.324
##	Residuals	174	11480	66		
##	---					
##	Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1					
##						
##	Coeficientes:					
##	(Intercept)		GrupoB	GenotipoAa	GenotipoAA	GrupoB:GenotipoAa
##			74.028813	5.0763575	5.7354973	16.0553098
##						-0.2321264
##						3.7




```
##
## Shapiro-Wilk (normalidade resíduos):
##
## Shapiro-Wilk normality test
##
## data: fit_cat$residuals
## W = 0.9929, p-value = 0.5306
##
## Bartlett (homocedasticidade):
##
## Bartlett test of homogeneity of variances
##
## data: Y by interaction(Grupo, Genotipo)
## Bartlett's K-squared = 1.8307, df = 5, p-value = 0.872
##
##
## Comparações múltiplas de Tukey:
## Tukey multiple comparisons of means
## 95% family-wise confidence level
##
## Fit: aov(formula = Y ~ Grupo * Genotipo, data = dat)
##
## $Grupo
##      diff      lwr      upr p adj
## B-A 6.248239 3.85837 8.638107 7e-07
```

```
##
## $Genotipo
##      diff      lwr      upr      p adj
## Aa-aa  5.619434  2.113712  9.125156  0.0006069
## AA-aa 17.929195 14.423473 21.434916  0.0000000
## AA-Aa 12.309761  8.804039 15.815482  0.0000000
##
## $`Grupo:Genotipo`
##      diff      lwr      upr      p adj
## B:aa-A:aa  5.0763575 -0.9674497 11.120165  0.1549331
## A:Aa-A:aa  5.7354973 -0.3083098 11.779304  0.0736213
## B:Aa-A:aa 10.5797283  4.5359212 16.623535  0.0000167
## A:AA-A:aa 16.0553098 10.0115027 22.099117  0.0000000
## B:AA-A:aa 24.8794373 18.8356302 30.923244  0.0000000
## A:Aa-B:aa  0.6591398 -5.3846673  6.702947  0.9995854
## B:Aa-B:aa  5.5033709 -0.5404363 11.547178  0.0969478
## A:AA-B:aa 10.9789523  4.9351452 17.022759  0.0000070
## B:AA-B:aa 19.8030798 13.7592727 25.846887  0.0000000
## B:Aa-A:AA  4.8442311 -1.1995761 10.888038  0.1957295
## A:AA-A:AA 10.3198125  4.2760054 16.363620  0.0000291
## B:AA-A:AA 19.1439400 13.1001329 25.187747  0.0000000
## A:AA-B:AA  5.4755815 -0.5682257 11.519389  0.1001007
## B:AA-B:AA 14.2997090  8.2559018 20.343516  0.0000000
## B:AA-A:AA  8.8241275  2.7803204 14.867935  0.0005826
```


95% family-wise confidence level



95% family-wise confidence level



95% family-wise confidence level



Differences in mean levels of Grupo:Genotipo

```
##
## --- (iv) SNP como variável quantitativa (efeito aditivo linear) ---
##
## Call:
## lm(formula = Y ~ Grupo * Geno_num, data = dat)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -21.0974  -5.5636   0.1684   4.8664  25.1543
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    73.265     1.375  53.299 < 2e-16 ***
## GrupoB         4.374     1.944   2.250  0.0257 *
## Geno_num       8.028     1.065   7.539 2.41e-12 ***
## GrupoB:Geno_num 1.874     1.506   1.244  0.2150
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 8.248 on 176 degrees of freedom
## Multiple R-squared:  0.4901, Adjusted R-squared:  0.4814
## F-statistic: 56.38 on 3 and 176 DF, p-value: < 2.2e-16
##
## Analysis of Variance Table
##
```

```
## Response: Y
##               Df Sum Sq Mean Sq F value    Pr(>F)
## Grupo         1  1756.8   1756.8   25.8265 9.479e-07 ***
## Geno_num      1  9643.7   9643.7  141.7691 < 2.2e-16 ***
## Grupo:Geno_num 1   105.3    105.3    1.5486   0.215
## Residuals    176 11972.2     68.0
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Comparação R²: categórico = 0.511 | quantitativo = 0.49
```

Interpretação P2:

Perfil de médias e boxplot: as linhas do perfil de médias variam de forma ascendente entre os genótipos. As linhas dos subgrupos são aproximadamente paralelas, indicando independência do efeito do SNP em relação ao subgrupo. O boxplot corrobora: as distribuições dentro de cada subgrupo mostram aumento progressivo da mediana e da média de Y de aa para AA, com dispersão compatível com $\sigma = 8$ mmHg.

ANOVA: são significativos tanto o efeito de Grupo ($F = 26,63$; $p < 0,001$) quanto do Genótipo ($F = 76,47$; $p < 0,001$). Já interação Grupo $\times$ Genótipo é não significativa ($F = 1,134$; $p = 0,324$), como esperado pela estrutura simulada.

Diagnóstico: normalidade (Shapiro-Wilk: $W = 0,993$; $p = 0,531$) e homocedasticidade (Bartlett: $K^2 = 1,831$; $p = 0,872$) satisfeitas. O gráfico “Constant Leverage” mostra resíduos bem distribuídos distribuídos.

Tukey: o contraste B-A é significativo ($\sim 6,2$ mmHg; $p < 0,001$), indicando diferença entre subgrupos. Todos os contrastes entre genótipos são significativos (Aa-aa: $+5,6$ mmHg, $p < 0,001$; AA-aa: $+17,9$ mmHg, $p < 0,001$; AA-Aa: $+12,3$ mmHg, $p < 0,001$), confirmando o efeito do SNP sobre a pressão diastólica. No Tukey da interação Grupo:Genótipo, os contrastes dentro do mesmo subgrupo entre genótipos distintos são em sua maioria significativos (ex.: A:AA-A:aa, B:AA-B:aa), enquanto contrastes entre subgrupos dentro do mesmo genótipo tendem a não atingir significância isoladamente (ex.: B:aa-A:aa: $p = 0,155$; B:Aa-A:Aa: $p = 0,196$), sugerindo que o efeito de subgrupo é menos pronunciado do que o efeito do SNP nesta população. A ausência de interação significativa na ANOVA é corroborada: o padrão de diferenças entre genótipos é consistente entre os subgrupos A e B.

SNP quantitativo (item iv): o modelo com `Geno_num` detecta efeito do SNP altamente significativo ($p < 0,001$). O efeito de Grupo permanece significativo ($p = 0,026$) e a interação Grupo $\times$ Geno_num não é significativa ($p = 0,215$), reforçando a ausência de interação já observada no modelo categórico. O R^2 é ligeiramente inferior ao do modelo categórico (0,490 vs. 0,511), diferença pequena que reflete a perda de um G.L. causada ao assumir linearidade do efeito de SNP, que assumindo os valores [0, 1, 2] seria necessariamente aditivo, ignorando possíveis efeitos adicionais, como dominância ou recessividade. Em casos como este, que o heterozigoto não está exatamente no ponto médio entre aa e AA, há perda de informação. O uso do SNP quantitativo é, então, ideal somente para casos em que o efeito aditivo é muito mais significativo que quaisquer outros.


2.2.4 P3 – Efeito de SNP com interação (epistasia SNP $\times$ Subgrupo)

```
res_P3 <- analisa_pop(dat_P3, "P3")


##
##
## =====
## POPULAÇÃO: P3
```

```
## =====
##
## --- (i) Estatísticas Descritivas ---
##
##
## Table: Descritivas - P3
##
## | |group1 |group2 | n| mean| sd| median|
## |---|:-----|:-----|---|-----:|-----:|-----:|
## |Y1 |A      |aa      | 30| 76.23| 7.10| 75.47|
## |Y2 |B      |aa      | 30| 75.40| 8.69| 74.82|
## |Y3 |A      |Aa      | 30| 78.91| 7.77| 78.46|
## |Y4 |B      |Aa      | 30| 84.26| 7.96| 84.10|
## |Y5 |A      |AA      | 30| 85.42| 9.07| 84.44|
## |Y6 |B      |AA      | 30| 100.44| 9.68| 101.09|
```

Perfil de Médias – P3







Boxplot – P3



```
##
## --- (iii) ANOVA Fatorial 3x2 (Genotipo categórico) ---
##
##          Df Sum Sq Mean Sq F value    Pr(>F)
## Grupo      1   1906    1906    26.87 5.99e-07 ***
## Genotipo    2   9096    4548    64.10 < 2e-16 ***
## Grupo:Genotipo 2   1916     958    13.50 3.54e-06 ***
## Residuals 174 12345       71
##
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
```

```
## Coeficientes:
##      (Intercept)      GrupoB      GenotipoAa      GenotipoAA GrupoB:GenotipoAa GrupoB:Gen
##      76.2341934      -0.8376434      2.6775862      9.1847370      6.1835631      15.8
```




```
##
## Shapiro-Wilk (normalidade resíduos):
##
## Shapiro-Wilk normality test
##
## data: fit_cat$residuals
## W = 0.99501, p-value = 0.8113
##
## Bartlett (homocedasticidade):
##
## Bartlett test of homogeneity of variances
##
## data: Y by interaction(Grupo, Genotipo)
## Bartlett's K-squared = 3.6449, df = 5, p-value = 0.6016
##
##
## Comparações múltiplas de Tukey:
## Tukey multiple comparisons of means
## 95% family-wise confidence level
##
## Fit: aov(formula = Y ~ Grupo * Genotipo, data = dat)
##
```

```


## $Grupo
##      diff      lwr      upr p adj
## B-A 6.508804 4.030576 8.987031 6e-07
##
## $Genotipo
##      diff      lwr      upr      p adj
## Aa-aa 5.769368 2.134031 9.404705 0.0006967
## AA-aa 17.112626 13.477289 20.747963 0.0000000
## AA-Aa 11.343258 7.707921 14.978595 0.0000000
##
## $`Grupo:Genotipo`
##      diff      lwr      upr      p adj
## B:aa-A:aa -0.8376434 -7.1049053 5.429619 0.9988855
## A:Aa-A:aa 2.6775862 -3.5896757 8.944848 0.8210097
## B:Aa-A:aa 8.0235058 1.7562439 14.290768 0.0040153
## A:AA-A:aa 9.1847370 2.9174751 15.451999 0.0005474
## B:AA-A:aa 24.2028712 17.9356094 30.470133 0.0000000
## A:Aa-B:aa 3.5152295 -2.7520324 9.782491 0.5889066
## B:Aa-B:aa 8.8611492 2.5938873 15.128411 0.0009766
## A:AA-B:aa 10.0223804 3.7551185 16.289642 0.0001131
## B:AA-B:aa 25.0405146 18.7732527 31.307777 0.0000000
## B:Aa-A:AA 5.3459197 -0.9213422 11.613182 0.1426013
## A:AA-A:AA 6.5071509 0.2398890 12.774413 0.0368267
## B:AA-A:AA 21.5252851 15.2580232 27.792547 0.0000000
## A:AA-B:AA 1.1612312 -5.1060307 7.428493 0.9947156
## B:AA-B:AA 16.1793654 9.9121035 22.446627 0.0000000
## B:AA-A:AA 15.0181342 8.7508723 21.285396 0.0000000

```


95% family-wise confidence level



95% family-wise confidence level



95% family-wise confidence level



Differences in mean levels of Grupo:Genotipo

```
##
## --- (iv) SNP como variável quantitativa (efeito aditivo linear) ---
##
## Call:
## lm(formula = Y ~ Grupo * Geno_num, data = dat)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -22.6306  -5.0435  -0.5809   6.1423  22.7371
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    75.596     1.415  53.425 < 2e-16 ***
## GrupoB         -1.419     2.001  -0.709   0.479
## Geno_num        4.592     1.096   4.190 4.41e-05 ***
## GrupoB:Geno_num  7.928     1.550   5.115 8.16e-07 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 8.49 on 176 degrees of freedom
## Multiple R-squared:  0.4978, Adjusted R-squared:  0.4893
## F-statistic: 58.16 on 3 and 176 DF, p-value: < 2.2e-16
##
## Analysis of Variance Table
##
```

```
## Response: Y
##               Df    Sum Sq Mean Sq F value    Pr(>F)
## Grupo          1   1906.4   1906.4   26.449 7.161e-07 ***
## Geno_num        1   8785.3   8785.3  121.883 < 2.2e-16 ***
## Grupo:Geno_num  1   1885.5   1885.5   26.159 8.158e-07 ***
## Residuals      176 12686.0     72.1
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Comparação R²: categórico = 0.511 | quantitativo = 0.498
```

Interpretação P3:

Perfil de médias e boxplot: as linhas do perfil de médias crescem afastando-se, indicando que dessa vez, não podemos assumir independência do efeito do SNP em relação ao subgrupo. O boxplot mostra “shifts” maiores entre genótipos no subgrupo B, evidenciando a interação: o efeito do SNP é mais acentuado em B do que em A.

ANOVA: são significativos ambos o efeito de Grupo ($F = 26,87$; $p < 0,001$) e de Genótipo ($F = 64,10$; $p < 0,001$). E também é significativa a interação Grupo×Genótipo ($F = 13,50$; $p < 0,001$), como esperado pela estrutura simulada.

Diagnóstico: normalidade (Shapiro-Wilk: $W = 0,995$; $p = 0,811$) e homocedasticidade (Bartlett: $K^2 = 3,645$; $p = 0,602$) satisfeitas. O gráfico “Constant Leverage” mostra resíduos bem distribuídos. Já o “Scale-Location” apresenta uma leve inclinação ascendente, sugerindo que a variabilidade dos resíduos tende a aumentar com os valores ajustados. Ainda assim, o teste de Bartlett não rejeita a homocedasticidade, então o padrão observado no gráfico não é estatisticamente relevante com este tamanho amostral.

Tukey: o contraste B-A é significativo ($\sim 6,5$ mmHg; $p < 0,001$), indicando diferença entre subgrupos. Todos os contrastes entre genótipos são significativos (Aa-aa: $+5,8$ mmHg, $p < 0,001$; AA-aa: $+17,1$ mmHg, $p < 0,001$; AA-Aa: $+11,3$ mmHg, $p < 0,001$), confirmando o efeito do SNP sobre a pressão diastólica. No Tukey da interação Grupo:Genótipo, o padrão de contrastes revela claramente a interação SNP×subgrupo: dentro do subgrupo A, o efeito do SNP é moderado (A:AA-A:aa: $+9,2$ mmHg; $p < 0,001$), enquanto no subgrupo B é muito mais acentuado (B:AA-B:aa: $+25,0$ mmHg; $p < 0,001$). Contrastes entre subgrupos dentro do mesmo genótipo mostram que A e B são indistinguíveis em aa (B:aa-A:aa: $p = 0,999$) mas divergem fortemente em AA (B:AA-A:AA: $+15,0$ mmHg; $p < 0,001$), confirmando que a diferença entre subgrupos depende do genótipo — assinatura inequívoca de interação. Estes resultados corroboram a interação significativa observada na ANOVA e o não-paralelismo das linhas no perfil de médias.

SNP quantitativo (item iv): o modelo com `Geno_num` assume e detecta efeito aditivo linear significativo no subgrupo A ($\hat{\beta} = 4,59$ mmHg por alelo A; $p < 0,001$) e uma interação Grupo×Geno_num altamente significativa ($\hat{\beta} = 7,93$; $p < 0,001$), indicando que o efeito do SNP é maior por alelo A no subgrupo B do que em A — resultado coerente com a interação detectada no modelo categórico. O efeito principal de Grupo não é significativo ($p = 0,479$). Isso pode ser justificado pois quando há interação, o efeito de Grupo depende do genótipo, não podendo ser interpretado isoladamente. O R^2 é ligeiramente inferior ao do modelo categórico (0,498 vs. 0,511), diferença pequena que reflete a restrição de G.L. causada pela adoção da linearidade. A conclusão é a mesma: há interação SNP×grupo significativa, com o efeito do SNP sendo muito mais pronunciado no grupo B.

2.3 Item (d) – Combinando as três populações

A análise conjunta permite avaliar se os efeitos do SNP e do subgrupo são consistentes entre populações ou se há heterogeneidade, questão central em estudos de genética de populações.

2.3.1 (d.i) – Fatorial 3 x 2 x 3 : SNP × Grupo × População (todos fixos)

```
dat_all <- rbind(dat_P1, dat_P2, dat_P3)
dat_all$Pop <- factor(dat_all$Pop) # Transformo população em var. categórica

# Estatísticas descritivas do dataset combinado
desc_all <- describeBy(dat_all$Y,
                        group = list(dat_all$Pop, dat_all$Grupo, dat_all$Genotipo),
                        mat = TRUE)

tabela_all <- desc_all[, c("group1", "group2", "group3", "n", "mean", "sd", "median", "min", "max")]
rownames(tabela_all) <- NULL


knitr::kable(tabela_all, digits = 2,
             col.names = c("População", "Grupo", "Genótipo", "n", "Média", "DP", "Mediana", "Mín", "Máx"),
             caption = "Estatísticas descritivas de Y por População, Grupo e Genótipo")
```

Table 3: Estatísticas descritivas de Y por População, Grupo e Genótipo

População	Grupo	Genótipo	n	Média	DP	Mediana	Mín	Máx
P1	A	aa	30	79.95	7.92	79.10	66.62	94.18
P2	A	aa	30	74.03	9.13	74.11	54.91	92.07
P3	A	aa	30	76.23	7.10	75.47	60.13	93.82
P1	B	aa	30	90.51	9.23	90.51	75.07	107.78
P2	B	aa	30	79.11	7.25	78.43	63.70	91.86
P3	B	aa	30	75.40	8.69	74.82	55.89	95.17
P1	A	Aa	30	78.93	9.11	79.71	60.14	94.87
P2	A	Aa	30	79.76	8.37	79.23	65.14	98.32
P3	A	Aa	30	78.91	7.77	78.46	60.86	94.20
P1	B	Aa	30	91.34	6.16	90.93	78.77	112.20
P2	B	Aa	30	84.61	7.90	83.63	73.61	103.71
P3	B	Aa	30	84.26	7.96	84.10	66.69	99.87
P1	A	AA	30	78.98	5.76	78.81	66.94	93.31
P2	A	AA	30	90.08	7.68	89.23	79.32	114.47
P3	A	AA	30	85.42	9.07	84.44	62.15	101.10
P1	B	AA	30	89.59	7.35	90.83	72.80	104.50
P2	B	AA	30	98.91	8.27	101.49	76.34	114.68
P3	B	AA	30	100.44	9.68	101.09	81.02	121.95

```
# Perfil de médias
with(dat_all,
     interaction.plot(Genotipo, interaction(Gruo,Pop), Y,
                     main="Perfil Médias: SNP x Grupo x População",
                     xlab="Genótipo", ylab="Média Y",
                     lwd=2, type="b"))
```

Perfil Médias: SNP x Grupo x População



Modelo completo 3x2x3

```
fit_fixo <- aov(Y ~ Grupo * Genótipo * Pop, data = dat_all)
```

```
summary(fit_fixo)
```

```
##              Df Sum Sq Mean Sq F value    Pr(>F)
## Grupo          1   8603    8603 131.492 < 2e-16 ***
## Genótipo        2  12069    6034  92.227 < 2e-16 ***
## Pop             2    195     97   1.490 0.226376
## Grupo:Genótipo  2    979     490   7.485 0.000624 ***
## Grupo:Pop       2    697     348   5.323 0.005145 **
## Genótipo:Pop    4   7151    1788  27.324 < 2e-16 ***
## Grupo:Genótipo:Pop 4   1120     280   4.278 0.002049 **
## Residuals      522  34153     65
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Coeficientes do modelo

```
fit_fixo$coef
```

```
##              (Intercept)              GrupoB              GenótipoAa              GenótipoAA
##              79.95232024              10.55691612              -1.01984317              -0.96910237
##      GrupoB:GenótipoAa      GrupoB:GenótipoAA      GrupoB:PopP2      GrupoB:PopP3
##              1.85320676              0.05166645              -5.48055866              -11.39455950
##      GenótipoAa:PopP3      GenótipoAA:PopP3      GrupoB:GenótipoAa:PopP2      GrupoB:GenótipoAA:PopP2      GrupoB:GenótipoAA:PopP3
##              3.69742933              10.15383941              -2.08533317              3.69610359
```

Modelo (d.i) — População como fator fixo: $Y \sim \text{Grupo} * \text{Genótipo} * \text{Pop}$ inclui todos os efeitos principais e interações de 2ª e 3ª ordem (17 g.l. de tratamento). Grupo ($F = 131,5$; $p < 0,001$) e Genótipo ($F = 92,2$; $p < 0,001$) são significativos, mas Pop isoladamente não ($F = 1,49$; $p = 0,226$). A interação tripla Grupo×Genótipo×Pop é significativa ($F = 4,28$; $p = 0,002$), confirmando que o padrão de interação SNP×subgrupo é heterogêneo entre populações — como visível no gráfico, onde as inclinações diferem marcadamente entre P1, P2 e P3.

2.3.2 (d.ii) – Fatorial 3 x 2 com População como fator aleatório (ANOVA Mista)

```
library(lme4)

# Modelo misto: Population como efeito aleatório (intercepto aleatório por Pop)
fit_misto <- lmer(Y ~ Grupo * Genotipo + (1 | Pop), data = dat_all, REML = TRUE)
summary(fit_misto)

## Linear mixed model fit by REML. t-tests use Satterthwaite's method ['lmerModLmerTest']
## Formula: Y ~ Grupo * Genotipo + (1 | Pop)
## Data: dat_all
##
## REML criterion at convergence: 3889.8
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -2.8484 -0.6599 -0.0410  0.6774  3.2897
##
## Random effects:
## Groups Name Variance Std.Dev.
## Pop (Intercept) 0.09122 0.302
## Residual 81.05413 9.003
## Number of obs: 540, groups: Pop, 3
##
## Fixed effects:
## Estimate Std. Error df t value Pr(>|t|)
## (Intercept) 76.7385 0.9649 49.9573 79.531 < 2e-16 ***
## GrupoB 4.9319 1.3421 532.0000 3.675 0.000262 ***
## GenotipoAa 2.4644 1.3421 532.0000 1.836 0.066878 .
## GenotipoAA 8.0903 1.3421 532.0000 6.028 3.1e-09 ***
## GrupoB:GenotipoAa 2.6015 1.8980 532.0000 1.371 0.171053
## GrupoB:GenotipoAA 6.5517 1.8980 532.0000 3.452 0.000601 ***
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
## (Intr) GrupoB GntpA GntpAA GrB:GA
## GrupoB -0.695
## GenotipoAa -0.695 0.500
## GenotipoAA -0.695 0.500 0.500
## GrpB:GntpA 0.492 -0.707 -0.707 -0.354
## GrpB:GntpAA 0.492 -0.707 -0.354 -0.707 0.500

# Coeficientes do modelo
print(coef(fit_misto))

## $Pop
## (Intercept) GrupoB GenotipoAa GenotipoAA GrupoB:GenotipoAa GrupoB:GenotipoAA
## P1 76.84579 4.931877 2.464413 8.090315 2.601548 6.551738
## P2 76.76683 4.931877 2.464413 8.090315 2.601548 6.551738
## P3 76.60277 4.931877 2.464413 8.090315 2.601548 6.551738
##
## attr(,"class")
## [1] "coef.mer"
```

```
# Teste dos efeitos fixos
library(lmerTest)
fit_misto2 <- lmer(Y ~ Grupo * Genotipo + (1 | Pop), data = dat_all, REML = FALSE)
anova(fit_misto2)
```

```
## Type III Analysis of Variance Table with Satterthwaite's method
##               Sum Sq Mean Sq NumDF DenDF  F value    Pr(>F)
## Grupo         8603.3  8603.3     1    540 107.2534 < 2.2e-16 ***
## Genotipo       12068.5  6034.3     2    540  75.2267 < 2.2e-16 ***
## Grupo:Genotipo   979.5   489.7     2    540   6.1053 0.002388 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Modelo (d.ii) — População como fator aleatório: $Y \sim \text{Grupo} * \text{Genotipo} + (1|\text{Pop})$ é adequado quando as populações são entendidas como amostra de um universo mais amplo, generalizando as inferências além das 3 observadas. A variância entre populações é ínfima ($\hat{\sigma}_{Pop}^2 = 0,091$) frente à residual ($\hat{\sigma}^2 = 81,05$), e os efeitos fixos de Grupo, Genótipo e sua interação permanecem significativos. Uma importante limitação deste modelo é que ele assume homogeneidade dos efeitos fixos entre populações, algo que já sabemos que não ocorre pelo modelo fixo do item anterior. Uma possível melhoria seria trabalhar com $(\text{Genotipo} | \text{Pop})$, permitindo que a inclinação do efeito do SNP também varie aleatoriamente entre populações. Porém, estimar essa matriz de variância-covariância na prática com apenas 3 populações é inviável, pois o modelo dificilmente iria convergir de forma estável, então esta argumentação serve mais como motivação para designs futuros com maior número de populações.

3 Regressão Logística: Y dicotomizada

3.1 Dicotomização de Y

```
# Ponto de corte: mediana global de cada dataset
corte1 <- median(dat1$Y)
corte2 <- median(dat2$Y)
corte_all <- median(dat_all$Y)

dat1$Ybin <- as.factor(ifelse(dat1$Y > corte1, 1, 0))
dat2$Ybin <- as.factor(ifelse(dat2$Y > corte2, 1, 0))
dat_all$Ybin <- as.factor(ifelse(dat_all$Y > corte_all, 1, 0))

cat("Ponto de corte Q1:", corte1, " | Distribuição:\n"); print(table(dat1$Ybin))

## Ponto de corte Q1: 108.5428 | Distribuição:
##
##  0  1
## 150 150

tab1 <- table(factor(dat1$Ybin, labels = c("baixo", "alto")), dat1$SNP)
tab1 <- rbind(tab1, "total" = colSums(tab1))
tab1

##      aa  Aa AA
## baixo 137  13  0
## alto   11 110 29
## total 148 123 29
```

```
#cat("Ponto de corte Q2:", corte2, " | Distribuição:\n"); print(table(dat2$Ybin))

#tab2 <- table(factor(dat2$Ybin, labels = c("ph1", "ph2")), dat2$SNP)
#tab2 <- rbind(tab2, "total" = colSums(tab2))
#tab2
```

Dicotomização de Y: A mediana é adotada como ponto de corte, resultando em distribuição perfeitamente balanceada: 150 observações em cada classe para Q1 (corte = 107,93) e 225 para Q2 (corte = 99,44). Essa escolha maximiza o poder do teste logístico, mas é arbitrária — um corte clinicamente motivado (ex.: PAD > 90 mmHg para hipertensão) seria igualmente válido e potencialmente mais interpretável.

3.2 Questão 1 (Caso 1) – Regressão Logística

```
# Modelo logístico
fitrl1_ad <- glm(as.factor(Ybin) ~ xa + xd, family=binomial(link="logit"), data=dat1)
summary(fitrl1_ad)
```

```
##
## Call:
## glm(formula = as.factor(Ybin) ~ xa + xd, family = binomial(link = "logit"),
##      data = dat1)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    8.022     605.612   0.013   0.989
## xa             10.544     605.612   0.017   0.986
## xd             -5.886     605.612  -0.010   0.992
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 415.89  on 299  degrees of freedom
## Residual deviance: 161.35  on 297  degrees of freedom
## AIC: 167.35
##
## Number of Fisher Scoring iterations: 17
```

```
cat("\nOR estimado (exp(coef)):\n")
```

```
##
## OR estimado (exp(coef)):
```

```
print(exp(coef(fitrl1_ad)))
```

```
## (Intercept)          xa          xd
## 3.047240e+03 3.795198e+04 2.776788e-03
```

```
cat("\nIC para OR:\n")
```

```
##
## IC para OR:
```

```
print(exp(confint(fitrl1_ad)))
```

```
##              2.5 %          97.5 %
```

```
## (Intercept) 1.339586e-17      NA
## xa          2.516933e-09 4.004769e+80
## xd          NA 1.777731e+12

# Probabilidades preditas e tabela de classificação
predlr <- predict(fitr11_ad, type="response")
classlr <- ifelse(predlr >= 0.5, 1, 0)
cat("Tabela de classificação:\n")

## Tabela de classificação:
print(table(Predito=classlr, Observado=dat1$Ybin))

##      Observado
## Predito    0    1
##      0 137   11
##      1   13 139

cat("Acurácia:", round(mean(classlr == dat1$Ybin), 3), "\n")

## Acurácia: 0.92

#plot(0:2, tapply(as.numeric(dat1$Ybin)-1, dat1$snp_num, mean),
#      type="b", pch=19, col="blue", xaxt="n",
#      xlab="Genótipo", ylab="P(Y=1 | Genótipo)",
#      main="Prob. estimadas vs. observadas - Regressão Logística (Q1-C1)")
#axis(1, at=0:2, labels=c("aa", "Aa", "AA"))
#lines(0:2, tapply(predlr, dat1$snp_num, mean), col="red", lty=2, pch=15, type="b")
#legend("topleft", c("Observado", "Predito"), col=c("blue", "red"), lty=c(1,2), bty="n")
```

Regressão Logística – Q1 Caso 1: O estabelecimento do valor corte para dicotomização de Y na mediana dos dados causou um fenômeno de separação completa dos grupos devido à ausência de observações “baixas” para o genótipo AA. Isso fez o modelo de regressão logística não recuperar adequadamente os coeficientes para os efeitos aditivo e de dominância, que tiveram a significância ignorada. Decidimos então voltar atrás e definir arbitrariamente um valor de corte que não deixasse valores nulos na tabela de contingência “altos *versus* baixos.”

```
corte1 <- 111
dat1$Ybin <- as.factor(ifelse(dat1$Y > corte1, 1, 0))

cat("Ponto de corte Q1:", corte1, " | Distribuição:\n"); print(table(dat1$Ybin))

## Ponto de corte Q1: 111 | Distribuição:

##
##      0    1
## 173 127

tab1 <- table(factor(dat1$Ybin, labels = c("baixo", "alto")), dat1$SNP)
tab1 <- rbind(tab1, "total" = colSums(tab1))
tab1

##      aa  Aa  AA
## baixo 144  27   2
## alto   4  96  27
## total 148 123  29

fitr11_ad <- glm(as.factor(Ybin) ~ xa + xd, family=binomial(link="logit"), data=dat1)
summary(fitr11_ad)
```

```
##
## Call:
## glm(formula = as.factor(Ybin) ~ xa + xd, family = binomial(link = "logit"),
##      data = dat1)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -0.4904      0.4455  -1.101  0.27101
## xa             3.0931      0.4455   6.943 3.85e-12 ***
## xd             1.7589      0.4959   3.547 0.00039 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 408.81  on 299  degrees of freedom
## Residual deviance: 180.80  on 297  degrees of freedom
## AIC: 186.8
##
## Number of Fisher Scoring iterations: 6
cat("\nOR estimado (exp(coef)):\n")

##
## OR estimado (exp(coef)):
print(exp(coef(fitr11_ad)))

## (Intercept)          xa          xd
##  0.6123724 22.0454077  5.8061979
cat("\nIC para OR:\n")

##
## IC para OR:
print(exp(confint(fitr11_ad)))

##              2.5 %    97.5 %
## (Intercept)  0.2636769  1.673448
## xa          10.2133711 61.911080
## xd           1.9757020 14.980133
pred1r <- predict(fitr11_ad, type="response")
class1r <- ifelse(pred1r >= 0.5, 1, 0)
cat("Tabela de classificação:\n")

## Tabela de classificação:
print(table(Predito=class1r, Observado=dat1$Ybin))

##      Observado
## Predito    0    1
##      0 144    4
##      1   29 123
cat("Acurácia:", round(mean(class1r == dat1$Ybin), 3), "\n")

## Acurácia: 0.89
```

Regressão Logística – Q1 Caso 1 (com corte arbitrário): Dessa vez, conseguimos evitar a separação total dos grupos, possibilitando que o modelo recuperasse adequadamente os coeficientes, resultando em $\log(\frac{\rho}{1-\rho}) = -0.4904 + 3.0931 \times x_a + 1.7589 \times x_d$, com significância para ambos ($p_{x_a} = 3.85 \times 10^{-12}$; $p_{x_d} = 0.00039$).

3.3 Questão 1 (Caso 2) – Regressão Logística com dois SNPs

```
fitrl2 <- glm(Ybin ~ xa1 + xd1 + xa2 + xd2 +
             xa1:xa2 + xa1:xd2 + xd1:xa2 + xd1:xd2,
             family=binomial(link="logit"), data=dat2)
summary(fitrl2)
```

```
##
## Call:
## glm(formula = Ybin ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xa1:xd2 +
##      xd1:xa2 + xd1:xd2, family = binomial(link = "logit"), data = dat2)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  0.42831    0.28327   1.512  0.13052
## xa1          1.35709    0.28327   4.791 1.66e-06 ***
## xd1          0.43266    0.35125   1.232  0.21804
## xa2          0.86441    0.28327   3.052  0.00228 **
## xd2          0.22832    0.39495   0.578  0.56319
## xa1:xa2      0.48568    0.28327   1.715  0.08643 .
## xa1:xd2      0.09649    0.39495   0.244  0.80700
## xd1:xa2      0.18416    0.35125   0.524  0.60007
## xd1:xd2      0.27470    0.48585   0.565  0.57181
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 1247.7  on 899  degrees of freedom
## Residual deviance: 1002.6  on 891  degrees of freedom
## AIC: 1020.6
##
## Number of Fisher Scoring iterations: 5
```

```
cat("\nOR estimados:\n")
```

```
##
## OR estimados:
print(round(exp(coef(fitrl2)), 3))
```

## (Intercept)	xa1	xd1	xa2	xd2	xa1:xa2	xa1:xd2	xd1:xa2	
## 1.535	3.885	1.541	2.374	1.256	1.625	1.101	1.202	

```
cat("\nIC para OR:\n")
```

```
##
## IC para OR:
```

```

print(round(exp(confint(fitr12)), 3))

##              2.5 % 97.5 %
## (Intercept) 0.961  3.247
## xa1         2.433  8.221
## xd1         0.675  2.949
## xa2         1.483  5.021
## xd2         0.524  2.740
## xa1:xa2     1.015  3.438
## xa1:xd2     0.459  2.402
## xd1:xa2     0.527  2.302
## xd1:xd2     0.506  3.623

pred2r <- predict(fitr12, type="response")
class2r <- ifelse(pred2r >= 0.5, 1, 0)
cat("Tabela de classificação:\n")

## Tabela de classificação:
print(table(Predito=class2r, Observado=dat2$Ybin))

##      Observado
## Predito    0    1
##      0 392 190
##      1  58 260

cat("Acurácia:", round(mean(class2r == dat2$Ybin), 3), "\n")

## Acurácia: 0.724

```

Regressão Logística – Q1 Caso 2: O modelo apresenta sérios problemas de convergência — os erros padrão são enormes (~162,7 para todos os coeficientes) e os p-valores são próximos de 1, indicando **separação completa ou quase-completa** dos dados: com 9 combinações genotípicas e Y dicotomizado pela mediana, o modelo logístico consegue separar perfeitamente (ou quase) as classes, tornando as estimativas instáveis. Os ORs estimados são numericamente absurdos (ex.: OR = 79 para xa1) e os ICs incluem 0 e infinito. A acurácia de 70,7% é razoável, mas as estimativas não são confiáveis. Neste caso, a regressão logística é inadequada com este tamanho amostral e parametrização — o modelo ANOVA sobre Y contínuo é claramente preferível.

3.4 Questão 2 – Regressão Logística por População

```

logistica_pop <- function(dat, nome) {
  cat("\n\n===== \n")
  cat(" POPULAÇÃO:", nome, "\n===== \n")

  # Codificação aditiva/dominância para SNP
  dat$xa_snp <- dat$Geno_num - 1
  dat$xd_snp <- ifelse(dat$Geno_num==1, 1, 0)
  dat$Grupo_bin <- ifelse(dat$Grupo=="A", 0, 1)

  # Dicotomizar Y
  corte_local <- median(dat$Y)
  dat$Ybin <- as.factor(ifelse(dat$Y > corte_local, 1, 0))
}

```

```

fit_logit <- glm(Ybin ~ Grupo_bin * (xa_snp + xd_snp),
                family=binomial(link="logit"), data=dat)
cat("\nModelo logístico - fator categórico:\n")
print(summary(fit_logit))
cat("\nOR estimados:\n")
print(round(exp(coef(fit_logit)), 3))

# Prob preditas
pred_r <- predict(fit_logit, type="response")
class_r <- ifelse(pred_r >= 0.5, 1, 0)
cat("\nAcurácia:", round(mean(class_r == dat$Ybin), 3), "\n")

# Comparação com ANOVA para o mesmo dado
cat("\n[ANOVA correspondente - para comparação]\n")
fit_anova <- lm(Y ~ Grupo * Genotipo, data=dat)
cat("ANOVA p-valor Genotipo:", anova(fit_anova)["Genotipo", "Pr(>F)"], "\n")
cat("Logístico p-valor xa: ", summary(fit_logit)$coef["xa_snp", "Pr(>|z|)"], "\n")

invisible(fit_logit)
}

logistica_pop(dat_P1, "P1")

##
##
## =====
## POPULAÇÃO: P1
## =====
##
## Modelo logístico - fator categórico:
##
## Call:
## glm(formula = Ybin ~ Grupo_bin * (xa_snp + xd_snp), family = binomial(link = "logit"),
##      data = dat)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -1.2825     0.3311  -3.874 0.000107 ***
## Grupo_bin         1.9910     0.4324   4.605 4.13e-06 ***
## xa_snp          -0.5893     0.3311  -1.780 0.075075 .
## xd_snp           0.5893     0.5095   1.157 0.247427
## Grupo_bin:xa_snp  0.8924     0.4324   2.064 0.039025 *
## Grupo_bin:xd_snp  0.5739     0.7908   0.726 0.467994
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 249.53  on 179  degrees of freedom
## Residual deviance: 198.68  on 174  degrees of freedom
## AIC: 210.68
##
## Number of Fisher Scoring iterations: 4
##

```

```

##
## OR estimados:
##      (Intercept)      Grupo_bin      xa_snp      xd_snp Grupo_bin:xa_snp Grupo_bin:xd_snp
##      0.277          7.323          0.555          1.803          2.441          1.77
##
## Acurácia: 0.733
##
## [ANOVA correspondente - para comparação]
## ANOVA p-valor Genotipo: 0.7613525
## Logístico p-valor xa: 0.07507511
logistica_pop(dat_P2, "P2")

##
##
## =====
##  POPULAÇÃO: P2
##  =====
##
## Modelo logístico - fator categórico:
##
## Call:
## glm(formula = Ybin ~ Grupo_bin * (xa_snp + xd_snp), family = binomial(link = "logit"),
##      data = dat)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -0.1312    0.3635  -0.361  0.7182
## Grupo_bin      1.3090    0.6583   1.989  0.0468 *
## xa_snp         1.7406    0.3635   4.789 1.68e-06 ***
## xd_snp        -0.7161    0.5393  -1.328  0.1842
## Grupo_bin:xa_snp  0.4488    0.6583   0.682  0.4954
## Grupo_bin:xd_snp -0.4617    0.8517  -0.542  0.5877
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 249.53  on 179  degrees of freedom
## Residual deviance: 172.40  on 174  degrees of freedom
## AIC: 184.4
##
## Number of Fisher Scoring iterations: 6
##
##
## OR estimados:
##      (Intercept)      Grupo_bin      xa_snp      xd_snp Grupo_bin:xa_snp Grupo_bin:xd_snp
##      0.877          3.703          5.701          0.489          1.566          0.63
##
## Acurácia: 0.767
##
## [ANOVA correspondente - para comparação]
## ANOVA p-valor Genotipo: 1.472674e-24
## Logístico p-valor xa: 1.677762e-06

```

```
logistica_pop(dat_P3, "P3")
```

```
##
##
## =====
##  POPULAÇÃO: P3
##  =====
##
## Modelo logístico - fator categórico:
##
## Call:
## glm(formula = Ybin ~ Grupo_bin * (xa_snp + xd_snp), family = binomial(link = "logit"),
##      data = dat)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -0.2099     0.3265  -0.643   0.520
## Grupo_bin       1.2988     0.6417   2.024   0.043 *
## xa_snp          1.3995     0.3265   4.287 1.81e-05 ***
## xd_snp         -0.6374     0.5151  -1.237   0.216
## Grupo_bin:xa_snp  0.8789     0.6417   1.370   0.171
## Grupo_bin:xd_snp -0.1832     0.8404  -0.218   0.827
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 249.53  on 179  degrees of freedom
## Residual deviance: 178.70  on 174  degrees of freedom
## AIC: 190.7
##
## Number of Fisher Scoring iterations: 6
##
##
## OR estimados:
##      (Intercept)      Grupo_bin      xa_snp      xd_snp Grupo_bin:xa_snp Grupo_bin:xd_snp
##           0.811           3.665           4.053           0.529           2.408           0.83
##
## Acurácia: 0.767
##
## [ANOVA correspondente - para comparação]
## ANOVA p-valor Genotipo: 1.384551e-21
## Logístico p-valor xa: 1.812864e-05
```

Regressão Logística por população: P1: o efeito de `xa_snp` não é significativo ($p = 0,075$), consistente com a ANOVA ($p = 0,761$). Apenas `Grupo_bin` é significativo ($OR = 7,32$; $p < 0,001$), refletindo a diferença entre subgrupos. Note-se, porém, que a interação `Grupo_bin:xa_snp` aparece significativa ($p = 0,039$) — resultado espúrio ausente na ANOVA, possivelmente devido à dicotomização combinada com o tamanho amostral moderado.

P2: `xa_snp` é significativo ($p < 0,001$), com $OR = 5,70$, confirmando o efeito aditivo do SNP. A interação `Grupo_bin:xa_snp` não é significativa ($p = 0,495$), coerente com a ausência de interação na ANOVA. Acurácia de 76,7%.

P3: `xa_snp` é significativo ($p < 0,001$; $OR = 4,05$), mas a interação `Grupo_bin:xa_snp` não

atinge significância ($p = 0,171$) — ao contrário da ANOVA, que detectou interação clara ($p < 0,001$). Este é um exemplo concreto de perda de poder pela dicotomização: a interação SNP×subgrupo, evidente nos dados contínuos, torna-se indetectável após o corte na mediana.

3.5 Regressão Logística Combinada (3 populações)

```
dat_all$xa_snp <- dat_all$Geno_num - 1
dat_all$xd_snp <- ifelse(dat_all$Geno_num==1, 1, 0)
dat_all$Grupo_bin <- ifelse(dat_all$Grupo=="A", 0, 1)

# Efeito fixo de Pop
fitrl_all_fixo <- glm(Ybin ~ Grupo_bin * (xa_snp + xd_snp) + Pop,
                     family=binomial(link="logit"), data=dat_all)
summary(fitrl_all_fixo)

##
## Call:
## glm(formula = Ybin ~ Grupo_bin * (xa_snp + xd_snp) + Pop, family = binomial(link = "logit"),
##      data = dat_all)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -0.2407     0.2132  -1.129  0.25889
## Grupo_bin      1.3688     0.2606   5.252 1.50e-07 ***
## xa_snp         0.7487     0.1666   4.495 6.96e-06 ***
## xd_snp        -0.3926     0.2872  -1.367  0.17171
## PopP2         -0.2237     0.2368  -0.945  0.34477
## PopP3         -0.6214     0.2399  -2.590  0.00959 **
## Grupo_bin:xa_snp  0.5102     0.2603   1.960  0.05002 .
## Grupo_bin:xd_snp  0.1500     0.4145   0.362  0.71743
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 748.60  on 539  degrees of freedom
## Residual deviance: 621.32  on 532  degrees of freedom
## AIC: 637.32
##
## Number of Fisher Scoring iterations: 4
cat("\nOR estimados:\n")

##
## OR estimados:
print(round(exp(coef(fitrl_all_fixo)), 3))

##              (Intercept)          Grupo_bin          xa_snp          xd_snp          PopP2          PopP3
##              0.786          3.931          2.114          0.675          0.800          0.53
```

```
# Modelo misto logístico (Pop aleatório)
library(lme4)
fitrl_all_misto <- glmer(Ybin ~ Grupo_bin * (xa_snp + xd_snp) + (1|Pop),
```

```

family=binomial(link="logit"), data=dat_all)
summary(fitrl_all_misto)

## Generalized linear mixed model fit by maximum likelihood (Laplace Approximation) ['glmerMod']
## Family: binomial ( logit )
## Formula: Ybin ~ Grupo_bin * (xa_snp + xd_snp) + (1 | Pop)
## Data: dat_all
##
##      AIC      BIC    logLik -2*log(L)  df.resid
##    640.9    670.9   -313.4    626.9     533
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -3.08692 -0.74029 -0.07955  0.81553  2.07019
##
## Random effects:
## Groups Name      Variance Std.Dev.
## Pop      (Intercept) 0.03731  0.1932
## Number of obs: 540, groups: Pop, 3
##
## Fixed effects:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -0.5190    0.2000  -2.595  0.00945 **
## Grupo_bin      1.3614    0.2599   5.237 1.63e-07 ***
## xa_snp         0.7441    0.1661   4.481 7.44e-06 ***
## xd_snp        -0.3897    0.2864  -1.361  0.17366
## Grupo_bin:xa_snp 0.5075    0.2597   1.954  0.05068 .
## Grupo_bin:xd_snp 0.1473    0.4133   0.356  0.72158
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
##              (Intr) Grp_bn xa_snp xd_snp Grp_bn:x_s
## Grupo_bin   -0.531
## xa_snp      -0.146  0.114
## xd_snp      -0.480  0.369  0.101
## Grp_bn:x_sn  0.092  0.175 -0.638 -0.065
## Grp_bn:xd_s  0.333 -0.627 -0.070 -0.693 -0.109

```

Regressão Logística combinada: No modelo com Pop fixo, Grupo_bin (OR = 3,93; $p < 0,001$) e xa_snp (OR = 2,11; $p < 0,001$) são significativos. PopP3 é significativo ($p = 0,010$), indicando que P3 tem menor chance basal de Y=1 em relação a P1. A interação Grupo_bin:xa_snp é marginalmente não significativa ($p = 0,050$). No modelo misto (glmer), a variância entre populações é ínfima ($\hat{\sigma}_{Pop}^2 = 0,037$) e os efeitos fixos são praticamente idênticos ao modelo fixo, confirmando a robustez das conclusões.

3.6 Comparação ANOVA vs. Regressão Logística

```

# ANOVA Q1C1
pval_anova_q1 <- anova(lm(Y ~ xa + xd, data=dat1))["xa", "Pr(>F)"]
pval_logit_q1 <- summary(fitrl1_ad)$coef["xa", "Pr(>|z|)"]
pval_anova_P2 <- anova(res_P2$fit_cat)["Genotipo", "Pr(>F)"]

```

```

pval_anova_P3 <- anova(res_P3$fit_cat)["Grupo:Genotipo","Pr(>F)"]

# Logístico P2
d2tmp <- dat_P2
d2tmp$xa <- d2tmp$Geno_num - 1
d2tmp$xd <- ifelse(d2tmp$Geno_num==1, 1, 0)
d2tmp$Gb <- ifelse(d2tmp$Grupo=="A", 0, 1)
d2tmp$Ybin2 <- as.factor(ifelse(d2tmp$Y > median(d2tmp$Y), 1, 0))
pval_logit_P2 <- tryCatch(
  summary(glm(Ybin2 ~ Gb*(xa+xd), family=binomial, data=d2tmp))$coef["xa","Pr(>|z|)"],
  error = function(e) NA)

# Logístico P3
d3tmp <- dat_P3
d3tmp$xa <- d3tmp$Geno_num - 1
d3tmp$xd <- ifelse(d3tmp$Geno_num==1, 1, 0)
d3tmp$Gb <- ifelse(d3tmp$Grupo=="A", 0, 1)
d3tmp$Ybin3 <- as.factor(ifelse(d3tmp$Y > median(d3tmp$Y), 1, 0))
fit_logit_p3 <- tryCatch(
  glm(Ybin3 ~ Gb*(xa+xd), family=binomial, data=d3tmp),
  error = function(e) NULL)
pval_logit_P3 <- if(!is.null(fit_logit_p3)) {
  cf <- summary(fit_logit_p3)$coef
  if ("Gb:xa" %in% rownames(cf)) cf["Gb:xa","Pr(>|z|)"] else NA
} else NA

comp <- data.frame(
  Modelo = c("ANOVA xa (Q1-C1)", "Logístico xa (Q1-C1)",
    "ANOVA SNP (P2)", "Logístico xa (P2)",
    "ANOVA SNP x Grupo (P3)", "Logístico xa x Grupo (P3)"),
  P_valor = round(c(pval_anova_q1, pval_logit_q1,
    pval_anova_P2, pval_logit_P2,
    pval_anova_P3, pval_logit_P3), 4)
)
knitr::kable(comp, caption="Comparação de p-valores: ANOVA vs. Regressão Logística")

```

Table 4: Comparação de p-valores: ANOVA vs. Regressão Logística

Modelo	P_valor
ANOVA xa (Q1-C1)	0.0000
Logístico xa (Q1-C1)	0.0000
ANOVA SNP (P2)	0.0000
Logístico xa (P2)	0.0000
ANOVA SNP x Grupo (P3)	0.0000
Logístico xa x Grupo (P3)	0.1708

Impacto da dicotomização: A tabela de p-valores ilustra de forma clara o impacto da dicotomização. Para efeitos fortes — como o efeito aditivo em Q1-C1 e em P2 — ambos os modelos detectam significância ($p < 0,001$), e a perda de poder é negligenciável. O caso mais revelador é P3: a interação SNP×subgrupo, altamente significativa na ANOVA ($p < 0,001$), torna-se completamente indetectável na regressão logística ($p = 0,171$) — perda de poder severa causada pela dicotomização de uma resposta contínua com interação moderada.

O Caso 2 ilustra um problema adicional: com muitos preditores e Y dicotomizado, a regressão logística pode sofrer separação completa, produzindo estimativas numericamente instáveis e ICs indefinidos — situação em que o modelo é formalmente inapropriado.

Em síntese, quando Y é genuinamente contínua, a ANOVA é preferível: preserva toda a informação, tem maior poder e evita os problemas de separação. A regressão logística é o modelo correto apenas quando o fenótipo é binário por natureza (ex.: hipertensão sim/não), situação em que os ORs oferecem interpretação clínica direta — por exemplo, $OR = 4,04$ para $\mathbf{x_a}$ em Q1-C1 significa que cada alelo A adicional quadruplica a chance de PAD acima da mediana.

Documento gerado com R Markdown – IBI5086/2026