

IBI5086 – Lista 2 (1º Sem/2026)

Grupo 4: Amanda Gonçalves, Carlos Lima, Daniel Nogueira, Guilherme Zonzin, Lucas Ito, Victoria Mel

2026-05-16

Contents

1	Mapeamento de Genes: ANOVA com SNPs	1
1.1	Caso 1 – ANOVA 1 fator em 3 níveis (efeitos aditivo e de dominância)	1
1.1.1	Codificação dos efeitos aditivo (xa) e de dominância (xd)	4
1.1.2	Modelo com 2 g.l. – fatores aditivo e de dominância	4
1.1.3	Diagnóstico dos resíduos (Caso 1)	5
1.1.4	Comparações múltiplas de Tukey	6
1.2	Caso 2 – ANOVA Fatorial 3×3 (dois SNPs, efeitos aditivo, dominância e epistasia)	7
1.2.1	Modelo com efeitos aditivos, dominância e interações (8 g.l.)	9
2	Delineamento Fatorial 3×2: SNP $\times$ Subgrupo Populacional	13
2.1	Simulação dos dados (P1, P2, P3) (item a)	13
2.2	Análise por População	14
2.2.1	Função auxiliar para análise completa	14
2.2.2	P1 – Sem efeito de SNP, sem interação	15
2.2.3	P2 – Efeito aditivo de SNP, sem interação (perfis paralelos)	21
2.2.4	P3 – Efeito de SNP com interação (epistasia SNP $\times$ Subgrupo)	27
2.3	Item (d) – Combinando as três populações	34
2.3.1	(d.i) – Fatorial $3 \times 2 \times 3$: SNP $\times$ Grupo $\times$ População (todos fixos)	34
2.3.2	(d.ii) – Fatorial 3×2 com População como fator aleatório (ANOVA Mista)	36
3	Regressão Logística: Y dicotomizada	37
3.1	Dicotomização de Y	37
3.2	Questão 1 (Caso 1) – Regressão Logística	38
3.3	Questão 1 (Caso 2) – Regressão Logística com dois SNPs	41
3.4	Questão 2 – Regressão Logística por População	47
3.5	Regressão Logística Combinada (3 populações)	50
3.6	Comparação ANOVA vs. Regressão Logística	52

1 Mapeamento de Genes: ANOVA com SNPs

Gerar X (binomial) e Y (normal); ajustar modelos de ANOVA.

1.1 Caso 1 – ANOVA 1 fator em 3 níveis (efeitos aditivo e de dominância)

```
set.seed(8732)
n_por_genot <- 100
```

```

# X: genótipos 0=aa, 1=Aa, 2=AA (distribuição ~binomial(2, p=0.3))
# probabilidades Hardy-Weinberg com p=0.3
p <- 0.3
freq <- c((1-p)^2, 2*p*(1-p), p^2) # aa, Aa, AA
snp <- sample(0:2, n_por_genot*3, replace=TRUE, prob=freq)

# Y: resposta com efeito aditivo (a=10) e dominância (d=5) sobre a média basal 100
# mu_aa=100, mu_Aa=115 (=100+d, com d=5 sobre midpoint), mu_AA=120 (=100+2a)
# Parametrização: a=(mu_AA-mu_aa)/2=10; d=mu_Aa-(mu_AA+mu_aa)/2=5
mu <- c(100, 115, 120)[snp + 1]
Y1 <- rnorm(length(snp), mean = mu, sd = 5)

dat1 <- data.frame(Y = Y1, SNP = factor(snp, labels = c("aa","Aa","AA")),
                  snp_num = snp)

# Estatísticas descritivas por genótipo
library(psych)
descr1 <- describeBy(dat1, group = "SNP", mat = TRUE)

tabela1 <- descr1[c("Y1", "Y2", "Y3"), c("group1","n","mean","sd","median","min","max")]
tabela1$group1 <- c("aa", "Aa", "AA")
rownames(tabela1) <- NULL

knitr::kable(tabela1, digits = 2,
             col.names = c("genotype","n","mean","sd","median","min","max"),
             caption = "Estatísticas descritivas de Y por genótipo (Caso 1)")

```

Table 1: Estatísticas descritivas de Y por genótipo (Caso 1)


genotype	n	mean	sd	median	min	max
aa	148	100.16	5.08	100.43	85.72	111.76
Aa	123	114.57	4.94	114.23	102.09	130.30
AA	29	120.15	4.63	120.39	109.25	128.01

```

boxplot(Y ~ SNP, data = dat1, col = c("lightblue","lightgreen","lightyellow"),
        main = "Distribuição de Y por Genótipo (Caso 1)", xlab = "Genótipo", ylab = "Y")


```

Distribuição de Y por Genótipo (Caso 1)



```
# Perfil de médias
medias1 <- tapply(dat1$Y, dat1$SNP, mean)
plot(0:2, medias1, type = "b", pch = 19, col = "red",
     xaxt = "n", xlab = "Genótipo", ylab = "Média de Y",
     main = "Perfil de Médias - Caso 1")
axis(1, at = 0:2, labels = c("aa", "Aa", "AA"))
```

Perfil de Médias – Caso 1



1.1.1 Codificação dos efeitos aditivo (xa) e de dominância (xd)

```
# xa: -1 (aa), 0 (Aa), 1 (AA) → captura efeito aditivo
# xd: 0 (aa), 1 (Aa), 0 (AA) → captura desvio de dominância
dat1$xa <- dat1$snp_num - 1
dat1$xd <- ifelse(dat1$snp_num == 1, 1, 0)
```

1.1.2 Modelo com 2 g.l. – fatores aditivo e de dominância

```
fit1_ad <- lm(Y ~ xa + xd, data = dat1)
summary(fit1_ad)
```

```
##
## Call:
## lm(formula = Y ~ xa + xd, data = dat1)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -14.4366  -3.3116  -0.0913   3.2016  15.7234
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  110.1521     0.5061  217.649 < 2e-16 ***
## xa           9.9967     0.5061  19.752 < 2e-16 ***
## xd           4.4209     0.6768   6.532 2.82e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.984 on 297 degrees of freedom
## Multiple R-squared:  0.7171, Adjusted R-squared:  0.7152
## F-statistic: 376.4 on 2 and 297 DF,  p-value: < 2.2e-16

anova(fit1_ad)
```

```
## Analysis of Variance Table
##
## Response: Y
##          Df Sum Sq Mean Sq F value    Pr(>F)
## xa         1 17642.1  17642.1  710.116 < 2.2e-16 ***
## xd         1  1059.9   1059.9   42.663 2.817e-10 ***
## Residuals 297  7378.6     24.8
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Discussão: Interpretação dos coeficientes

O intercepto estimado ($\hat{\mu} = 110,15$) representa o ponto médio entre as médias dos homozigotos, $(\mu_{AA} + \mu_{aa})/2$.


O efeito aditivo (xa, $\hat{a} = 9,99$) é altamente significativo ($p < 0,001$), indicando que cada alelo A adicional eleva Y em aproximadamente 10 unidades.

O efeito de dominância (xd, $\hat{d} = 4,42$) é significativo ($p < 0,001$) e positivo, indicando que o heterozigoto acrescenta em torno de 4,42 unidades à média de Y.

O modelo explica cerca de 72% da variância total de Y ($R^2 = 0,717$).

1.1.3 Diagnóstico dos resíduos (Caso 1)

```
par(mfrow = c(2,2))
plot(fit1_ad)
```



```
par(mfrow = c(1,1))
```

```
shapiro.test(fit1_ad$residuals)
```

```
##
## Shapiro-Wilk normality test
##
## data: fit1_ad$residuals
## W = 0.99764, p-value = 0.9466
```

```
bartlett.test(Y ~ SNP, data = dat1)
```

```
##
## Bartlett test of homogeneity of variances
##
## data: Y by SNP
## Bartlett's K-squared = 0.42151, df = 2, p-value = 0.81
```

Discussão dos gráficos de diagnóstico

Residuals vs Fitted: dispersão vertical nas três colunas parece similar, e a linha vermelha está praticamente horizontal. Aleatoriedade OK.

Q-Q Residuals: pontos muito bem aderidos à diagonal. Normalidade bem satisfeita.

Sale-Location: Dispersão bem uniforme, linha vermelha praticamente horizontal, homocedasticidade bem satisfeita. As três observações rotuladas são outliers, nada alarmante.

Residuals vs Leverage: As observações do genótipo AA concentram-se à direita ($\sim 0,033$), com maior leverage que os demais genótipos — esperado dado sua menor frequência amostral sob Hardy-Weinberg ($p=0,3$, $\sim 9\%$ de AA). Ainda assim, a linha de Cook aparece colapsada na borda esquerda do gráfico, indicando que nenhuma observação exerce influência desproporcional sobre os coeficientes. O modelo é estável.

Testes de diagnóstico: O teste de Shapiro-Wilk **não rejeita** a normalidade dos resíduos ($W = 0,998$; $p = 0,947$), e o teste de Bartlett **não rejeita** a homogeneidade de variâncias entre os três genótipos ($K^2 = 0,42$; $gl = 2$; $p = 0,810$). Ambos os resultados confirmam que as suposições do modelo linear são satisfeitas, em concordância com o diagnóstico visual dos gráficos.


1.1.4 Comparações múltiplas de Tukey

```
fit1_aov <- aov(Y ~ SNP, data = dat1)
TukeyHSD(fit1_aov)

##    Tukey multiple comparisons of means
##      95% family-wise confidence level
##
## Fit: aov(formula = Y ~ SNP, data = dat1)
##
## $SNP
##           diff           lwr          upr p adj
## Aa-aa 14.417637 12.985123 15.850151 0e+00
## AA-aa 19.993374 17.609109 22.377639 0e+00
## AA-Aa  5.575737  3.152098  7.999376 4e-07

par(mar=c(5,8,4,2))
plot(TukeyHSD(fit1_aov))
```

95% family-wise confidence level



Comparações múltiplas de Tukey: O teste de Tukey HSD compara os três genótipos par a par com controle da taxa de erro familiar a 5%. Aa-aa (diff = 14,42; $p < 0,001$), AA-aa (diff = 19,99; $p < 0,001$) e AA-Aa (diff = 5,58; $p < 0,001$) são todos significativos, confirmando que cada alelo A adicional eleva a média de Y (~ 10) e que o heterozigoto sofre influência positiva do fator de dominância (~ 5).

1.2 Caso 2 – ANOVA Fatorial 3×3 (dois SNPs, efeitos aditivo, dominância e epistasia)

```
set.seed(8732)
n_cell <- 100 # por célula (genótipo conjunto)

# SNP1 e SNP2 gerados independentemente (HWE, p1=0.3, p2=0.4)
p1 <- 0.3; p2 <- 0.4
freq1 <- c((1-p1)^2, 2*p1*(1-p1), p1^2)
freq2 <- c((1-p2)^2, 2*p2*(1-p2), p2^2)

snp1 <- sample(0:2, n_cell*9, replace=TRUE, prob=freq1)
snp2 <- sample(0:2, n_cell*9, replace=TRUE, prob=freq2)

# Estrutura de médias com epistasia (interação a1*a2)
# mu_base + a1_efeito + a2_efeito + interacao
a1 <- 8; d1 <- 4; a2 <- 6; d2 <- 3

xa1 <- snp1 - 1 # -1, 0, 1
xd1 <- ifelse(snp1==1, 1, 0) # 0, 1, 0
xa2 <- snp2 - 1
xd2 <- ifelse(snp2==1, 1, 0)
```

```

# Modelo com efeitos e interações
mu2 <- 100 + a1*xa1 + d1*xd1 + a2*xa2 + d2*xd2 +
      3*xa1*xa2 + 1.5*xa1*xd2 + 1.5*xd1*xa2 + 1*xd1*xd2

Y2 <- rnorm(length(mu2), mean = mu2, sd = 12)

dat2 <- data.frame(
  Y = Y2,
  SNP1 = factor(snp1, labels = c("a1a1", "a1A1", "A1A1")),
  SNP2 = factor(snp2, labels = c("a2a2", "a2A2", "A2A2")),
  xa1 = xa1, xd1 = xd1, xa2 = xa2, xd2 = xd2
)

# Estatísticas descritivas
cat("Dimensões do dataset (Caso 2):", nrow(dat2), "observações\n")

## Dimensões do dataset (Caso 2): 900 observações
tapply(dat2$Y, list(dat2$SNP1, dat2$SNP2), mean) |>
  round(2) |>
  knitr::kable(caption = "Médias de Y por combinação genotípica (Caso 2)")

```

Table 2: Médias de Y por combinação genotípica (Caso 2)


	a2a2	a2A2	A2A2
a1a1	89.06	93.35	94.94
a1A1	97.11	109.38	113.98
A1A1	102.20	111.63	115.31

```

with(dat2,
  interaction.plot(SNP2, SNP1, Y, col = 1:3,
    main = "Perfil de Médias - Caso 2 (Epistasia)",
    xlab = "Genótipo SNP2", ylab = "Média Y",
    lwd = 2, pch = 19, type = "b"))

```


Perfil de Médias – Caso 2 (Epistasia)



O perfil de médias evidencia epistasia entre SNP1 e SNP2: o efeito de cada SNP sobre Y depende do genótipo do outro. Quanto mais alelos A1 o indivíduo carrega, maior o ganho em Y proporcionado pelos alelos A2.

1.2.1 Modelo com efeitos aditivos, dominância e interações (8 g.l.)

```
# Parametrização explícita: xa1, xd1, xa2, xd2 e 4 termos de interação
fit2_completo <- lm(Y ~ xa1 + xd1 + xa2 + xd2 +
                    xa1:xa2 + xa1:xd2 + xd1:xa2 + xd1:xd2,
                    data = dat2)
summary(fit2_completo)
```

```
##
## Call:
## lm(formula = Y ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xa1:xd2 +
##     xd1:xa2 + xd1:xd2, data = dat2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -40.274  -8.232  -0.041   7.851  36.568
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  100.3781    0.9026  111.214 < 2e-16 ***
## xa1           8.3782    0.9026   9.283 < 2e-16 ***
## xd1           5.1671    1.2673   4.077 4.97e-05 ***
## xa2           4.7509    0.9026   5.264 1.77e-07 ***
## xd2           2.1117    1.3771   1.533 0.12552
## xa1:xa2       1.8061    0.9026   2.001 0.04568 *
## xa1:xd2       0.7633    1.3771   0.554 0.57955
## xd1:xa2       3.6857    1.2673   2.908 0.00372 **
```

```
## xd1:xd2      1.7276      1.8710      0.923      0.35608
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 11.65 on 891 degrees of freedom
## Multiple R-squared:  0.3604, Adjusted R-squared:  0.3547
## F-statistic: 62.76 on 8 and 891 DF,  p-value: < 2.2e-16
```

```
anova(fit2_completo)
```

```
## Analysis of Variance Table
##
## Response: Y
##          Df Sum Sq Mean Sq  F value    Pr(>F)
## xa1         1  42983   42983 316.6776 < 2.2e-16 ***
## xd1         1   3509    3509  25.8516 4.495e-07 ***
## xa2         1  16343   16343 120.4054 < 2.2e-16 ***
## xd2         1   1409    1409  10.3809 0.001319 **
## xa1:xa2      1   2194    2194  16.1635 6.302e-05 ***
## xa1:xd2      1    284     284   2.0929 0.148337
## xd1:xa2      1   1313    1313   9.6731 0.001929 **
## xd1:xd2      1    116     116   0.8526 0.356076
## Residuals 891 120937    136
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Como houve discrepância entre os resultados da regressão linear e da ANOVA do modelo completo, foi ajustado um modelo reduzido contendo apenas os termos significativos na ANOVA.

```
fit2_reduzido <- lm(Y ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xd1:xa2, data = dat2)
summary(fit2_reduzido)
```

```
##
## Call:
## lm(formula = Y ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xd1:xa2, data = dat2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -40.681  -8.154  -0.101   8.047  36.959
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 100.1734     0.7717 129.806 < 2e-16 ***
## xa1           8.7385     0.6813  12.826 < 2e-16 ***
## xd1           6.0316     0.9303   6.484 1.48e-10 ***
## xa2           4.6699     0.9007   5.185 2.67e-07 ***
## xd2           2.5019     0.8016   3.121 0.00186 **
## xa1:xa2       1.8991     0.8989   2.113 0.03491 *
## xd1:xa2       4.0195     1.2435   3.233 0.00127 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 11.65 on 893 degrees of freedom
## Multiple R-squared:  0.3589, Adjusted R-squared:  0.3546
## F-statistic: 83.31 on 6 and 893 DF,  p-value: < 2.2e-16
```

```
anova(fit2_reduzido)
```

```
## Analysis of Variance Table
##
## Response: Y
##          Df Sum Sq Mean Sq F value    Pr(>F)
## xa1       1  42983    42983 316.618 < 2.2e-16 ***
## xd1       1   3509     3509  25.847 4.504e-07 ***
## xa2       1  16343    16343 120.383 < 2.2e-16 ***
## xd2       1   1409     1409  10.379 0.001321 **
## xa1:xa2    1   2194     2194  16.160 6.311e-05 ***
## xd1:xa2    1   1419     1419  10.449 0.001272 **
## Residuals 893 121231      136
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
anova(fit2_reduzido, fit2_completo)
```

```
## Analysis of Variance Table
##
## Model 1: Y ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xd1:xa2
## Model 2: Y ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xa1:xd2 + xd1:xa2 + xd1:xd2
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      893 121231
## 2      891 120937  2    294.15 1.0836 0.3388
```

Os modelos foram comparados por ANOVA para modelos aninhados, e como não houve diferença significativa entre eles ($p = 0,3388$), optou-se pelo modelo reduzido.

Interpretação:

- **xa1** e **xa2**: efeitos aditivos dos SNP1 e SNP2, respectivamente.
- **xd1** e **xd2**: desvios de dominância de cada SNP.
- **xa1:xa2** ($a_1 \times a_2$): **epistasia aditiva** $\times$ **aditiva** – interação entre os efeitos aditivos.
- **xa1:xd2** ($a_1 \times d_2$), **xd1:xa2** ($d_1 \times a_2$): epistasias mistas.
- **xd1:xd2** ($d_1 \times d_2$): epistasia dominância $\times$ dominância.


O modelo explica ~35,9% da variância de Y ($R^2 = 0,359$) e é globalmente significativo ($F = 83,31$; $p < 0,001$). O erro padrão residual (~11,65) está próximo do valor verdadeiro simulado ($\sigma = 12$), indicando bom ajuste.

Efeitos principais: os efeitos aditivos de ambos os SNPs são significativos — **xa1** ($\hat{a}_1 = 8,74$; $p < 0,001$) e **xa2** ($\hat{a}_2 = 4,67$; $p < 0,001$) — indicando que cada alelo A adicional em cada loco eleva Y independentemente. Os efeitos de dominância **xd1** e **xd2** também são significativos pelo summary ($p < 0,001$ e $p < 0,01$). Entretanto, como foi detectada epistasia aditiva $\times$ aditiva e dominância $\times$ aditiva entre os alelos, a interpretação isolada dos efeitos principais pode não ser adequada. Nota: É interessante notar que os coeficientes recuperados para **xa1**, **xa2**, **xd1** e **xd2** foram próximos dos reais usados na geração: ($a_1 = 8$; $d_1 = 4$; $a_2 = 6$; $d_2 = 3$).

Epistasia: as interações aditiva $\times$ aditiva **xa1:xa2** e dominância $\times$ aditiva **xd1:xa2** são significativas na tabela ANOVA (**xa1:xa2** -> $F = 16,16$; $p < 0,001$ | **xd1:xa2** -> $F = 10,45$; $p < 0,01$). As demais interações não atingem significância, embora o valor verdadeiro simulado das interações **xd1:xa2** e **xa1:xd2** fossem idênticos (1.5x). A diferença em significância é reflexo da variação amostral e não um erro.

Em conjunto, os resultados confirmam que o fenótipo Y é influenciado pelos efeitos aditivos de dois locos e por sua interação epistática, padrão visualmente antecipado pelo não-paralelismo das linhas no perfil de médias.

```
par(mfrow = c(2,2)); plot(fit2_completo); par(mfrow = c(1,1))
```



```
shapiro.test(fit2_completo$residuals)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  fit2_completo$residuals
## W = 0.99908, p-value = 0.9438
```

Diagnóstico dos resíduos – Caso 2:

Residuals vs Fitted: os pontos distribuem-se em colunas verticais correspondentes às 9 combinações genotípicas (células do fatorial 3×3), padrão esperado com preditores discretos. A linha vermelha é aproximadamente horizontal em 0, sem curvatura sistemática, indicando que o modelo linear é adequado.

Q-Q Residuals: excelente aderência à diagonal em toda a extensão central, com desvios pequenos nas caudas. A normalidade dos resíduos é confirmada formalmente pelo teste de Shapiro-Wilk ($W = 0,999$; $p = 0,944$), que não rejeita H_0 .

Scale-Location: a linha vermelha é praticamente horizontal e a distribuição dos resíduos aparenta ser uniforme.

Residuals vs Leverage: os pontos se distribuem em faixas de leverage distintas, refletindo as diferentes frequências das 9 células genotípicas — células raras (como A1A1 com $p_1=0,3$) têm maior leverage. Ainda assim, a linha de Cook permanece colapsada na borda inferior do gráfico, indicando que nenhuma observação exerce influência desproporcional sobre os coeficientes.

2 Delineamento Fatorial 3×2 : SNP $\times$ Subgrupo Populacional

2.1 Simulação dos dados (P1, P2, P3) (item a)

```
set.seed(8732)
n_rep <- 30 # réplicas
sigma <- 8 # desvio padrão

# Médias fornecidas na lista
medias_pop <- list(
  P1 = matrix(c(80,80,80, 90,90,90), nrow=2, byrow=TRUE,
    dimnames=list(c("A","B"), c("aa","Aa","AA"))),
  P2 = matrix(c(75,80,90, 80,86,97), nrow=2, byrow=TRUE,
    dimnames=list(c("A","B"), c("aa","Aa","AA"))),
  P3 = matrix(c(75,80,85, 75,85,100), nrow=2, byrow=TRUE,
    dimnames=list(c("A","B"), c("aa","Aa","AA")))
)

# Gerar dados para cada população
gerar_pop <- function(mmat, n, sigma, pop_nome) {
  rows <- list()
  for (grp in rownames(mmat)) {
    for (geno in colnames(mmat)) {
      y <- rnorm(n, mean = mmat[grp, geno], sd = sigma)
      rows[[length(rows)+1]] <- data.frame(
        Y = y, Grupo = grp, Genotipo = geno,
        Geno_num = match(geno, c("aa","Aa","AA")) - 1,
        Pop = pop_nome
      )
    }
  }
  do.call(rbind, rows)
}

dat_P1 <- gerar_pop(medias_pop$P1, n_rep, sigma, "P1")
dat_P2 <- gerar_pop(medias_pop$P2, n_rep, sigma, "P2")
dat_P3 <- gerar_pop(medias_pop$P3, n_rep, sigma, "P3")

# Ordenar fatores
dat_P1$Genotipo <- factor(dat_P1$Genotipo, levels=c("aa","Aa","AA"))
dat_P2$Genotipo <- factor(dat_P2$Genotipo, levels=c("aa","Aa","AA"))
dat_P3$Genotipo <- factor(dat_P3$Genotipo, levels=c("aa","Aa","AA"))
```

Contextualização (item b): Os dados representam medições de pressão arterial diastólica em repouso (mmHg) em indivíduos de três populações distintas (P1, P2, P3), classificados segundo o genótipo de um SNP (aa, Aa, AA) e a origem geográfica (A e B). Adotou-se $n = 30$ réplicas por co-ordenada (Grupo $\times$ Genótipo) $\sigma = 8$ mmHg. As três populações representam cenários distintos: **P1** sem efeito do SNP (apenas diferença entre subgrupos: $B \approx 10$ mmHg acima de A); **P2** com efeito do SNP e perfis paralelos entre subgrupos; e **P3** com interação SNP $\times$ subgrupo, onde o efeito do SNP é modesto em A (+10 mmHg de aa $\rightarrow$ AA) mas acentuado em B (+25 mmHg), sugerindo que fatores populacionais do subgrupo B potencializam o efeito do SNP sobre

a pressão diastólica.

2.2 Análise por População

2.2.1 Função auxiliar para análise completa

```
analisa_pop <- function(dat, nome_pop) {  
  cat("\n\n===== \n")  
  cat(" POPULAÇÃO:", nome_pop, "\n")  
  cat("===== \n\n")  
  
  # (i) Estatísticas descritivas  
  cat("--- (i) Estatísticas Descritivas --- \n")  
  desc <- describeBy(dat, group = list(dat$Grupo, dat$Genotipo), mat=TRUE)  
  print(knitr::kable(desc[grepl("^Y", rownames(desc)),  
                      c("group1", "group2", "n", "mean", "sd", "median")],  
        digits=2, caption=paste("Descritivas -", nome_pop)))  
  
  # (ii) Perfil de médias  
  par(mfrow=c(1,2))  
  with(dat,  
        interaction.plot(Genotipo, Grupo, Y,  
                          col=c("red", "blue"), lwd=2, pch=19, type="b",  
                          main=paste("Perfil de Médias -", nome_pop),  
                          xlab="Genótipo SNP", ylab="Média Y"))  
  
  # Boxplot  
  boxplot(Y ~ Grupo:Genotipo, data=dat, col=c("lightcoral", "lightblue"),  
          main=paste("Boxplot -", nome_pop),  
          xlab="Grupo:Genótipo", ylab="Y", las=2, cex.axis=0.7)  
  par(mfrow=c(1,1))  
  
  # (iii) ANOVA Fatorial 3$times$2 - fator categórico  
  cat("\n--- (iii) ANOVA Fatorial 3x2 (Genotipo categórico) --- \n")  
  fit_cat <- aov(Y ~ Grupo * Genotipo, data=dat)  
  print(summary(fit_cat))  
  cat("\nCoeficientes: \n")  
  print(coef(fit_cat))  
  
  # Diagnóstico resíduos  
  par(mfrow=c(2,2)); plot(fit_cat); par(mfrow=c(1,1))  
  cat("\nShapiro-Wilk (normalidade resíduos): \n")  
  print(shapiro.test(fit_cat$residuals))  
  cat("\nBartlett (homocedasticidade): \n")  
  print(bartlett.test(Y ~ interaction(Grupo, Genotipo), data=dat))  
  
  # Tukey  
  cat("\nComparações múltiplas de Tukey: \n")  
  tk <- TukeyHSD(fit_cat)  
  print(tk)  
  plot(tk, las=1, cex.axis=0.6)
```

```

# (iv) SNP como variável quantitativa (1 g.l. - efeito linear)
cat("\n--- (iv) SNP como variável quantitativa (efeito aditivo linear) ---\n")
fit_num <- lm(Y ~ Grupo * Geno_num, data=dat)
print(summary(fit_num))
print(anova(fit_num))

cat("\nComparação R²: categórico =", round(summary(lm(Y ~ Grupo * Genotipo, data=dat))$r.squared, 3),
    "| quantitativo =", round(summary(fit_num)$r.squared, 3), "\n")

invisible(list(fit_cat=fit_cat, fit_num=fit_num))
}

```



2.2.2 P1 – Sem efeito de SNP, sem interação

```





res_P1 <- analisa_pop(dat_P1, "P1")

##
##
## =====
## POPULAÇÃO: P1
## =====
##
## --- (i) Estatísticas Descritivas ---
##
##
## Table: Descritivas - P1
##
## |   |group1 |group2 |  n|  mean|   sd| median|
## |:-:|:-----|:-----|--:|-----:|-----:|-----:|
## |Y1 |A      |aa      | 30| 79.95| 7.92| 79.10|
## |Y2 |B      |aa      | 30| 90.51| 9.23| 90.51|
## |Y3 |A      |Aa      | 30| 78.93| 9.11| 79.71|
## |Y4 |B      |Aa      | 30| 91.34| 6.16| 90.93|
## |Y5 |A      |AA      | 30| 78.98| 5.76| 78.81|
## |Y6 |B      |AA      | 30| 89.59| 7.35| 90.83|

```




```
##
## --- (iii) ANOVA Fatorial 3x2 (Genótipo categórico) ---
##               Df Sum Sq Mean Sq F value Pr(>F)
## Grupo         1   5637    5637  94.959 <2e-16 ***
## Genótipo       2     32      16   0.273  0.761
## Grupo:Genótipo 2     33      17   0.281  0.755
## Residuals     174  10328      59
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Coeficientes:
##      (Intercept)          GrupoB      GenótipoAa      GenótipoAA  GrupoB:GenótipoAa  GrupoB:Gen
##      79.95232024      10.55691612     -1.01984317     -0.96910237      1.85320676      0.0
```


```
##
## Shapiro-Wilk (normalidade resíduos):
##
## Shapiro-Wilk normality test
##
## data: fit_cat$residuals
## W = 0.99448, p-value = 0.7439
##
## Bartlett (homocedasticidade):
##
## Bartlett test of homogeneity of variances
##
## data: Y by interaction(Grupo, Genotipo)
## Bartlett's K-squared = 10.56, df = 5, p-value = 0.06083
##
##
## Comparações múltiplas de Tukey:
## Tukey multiple comparisons of means
## 95% family-wise confidence level
##
## Fit: aov(formula = Y ~ Grupo * Genotipo, data = dat)
##
## $Grupo
##      diff      lwr      upr p adj
## B-A 11.19187 8.925067 13.45868    0
```

```
##
## $Genotipo
##      diff      lwr      upr      p adj
## Aa-aa -0.09323979 -3.418441 3.231961 0.9975806
## AA-aa -0.94326914 -4.268470 2.381932 0.7808776
## AA-Aa -0.85002935 -4.175230 2.475172 0.8179569
##
## $`Grupo:Genotipo`
##      diff      lwr      upr      p adj
## B:aa-A:aa 10.55691612  4.824323 16.289509 0.0000050
## A:Aa-A:aa -1.01984317 -6.752436  4.712750 0.9956337
## B:Aa-A:aa 11.39027971  5.657687 17.122873 0.0000007
## A:AA-A:aa -0.96910237 -6.701695  4.763490 0.9965684
## B:AA-A:aa  9.63948021  3.906887 15.372073 0.0000406
## A:Aa-B:aa -11.57675930 -17.309352 -5.844166 0.0000004
## B:Aa-B:aa  0.83336358 -4.899229  6.565956 0.9983292
## A:AA-B:aa -11.52601849 -17.258611 -5.793426 0.0000005
## B:AA-B:aa -0.91743592 -6.650029  4.815157 0.9973543
## B:Aa-A:AA 12.41012288  6.677530 18.142716 0.0000000
## A:AA-A:AA  0.05074081 -5.681852  5.783334 1.0000000
## B:AA-A:AA 10.65932338  4.926731 16.391916 0.0000039
## A:AA-B:AA -12.35938207 -18.091975 -6.626789 0.0000001
## B:AA-B:AA -1.75079950 -7.483392  3.981793 0.9508273
## B:AA-A:AA 10.60858257  4.875990 16.341175 0.0000044
```


95% family-wise confidence level



95% family-wise confidence level



95% family-wise confidence level



Differences in mean levels of Grupo:Genotipo

```
##
## --- (iv) SNP como variável quantitativa (efeito aditivo linear) ---
##
## Call:
## lm(formula = Y ~ Grupo * Geno_num, data = dat)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -19.1528  -5.2945   0.0742   5.0879  21.7213
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    79.77389     1.27917   62.364 < 2e-16 ***
## GrupoB         11.16604     1.80902    6.172 4.51e-09 ***
## Geno_num       -0.48455     0.99084   -0.489  0.625
## GrupoB:Geno_num  0.02583     1.40126    0.018  0.985
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 7.675 on 176 degrees of freedom
## Multiple R-squared:  0.3533, Adjusted R-squared:  0.3423
## F-statistic: 32.05 on 3 and 176 DF, p-value: < 2.2e-16
##
## Analysis of Variance Table
##
```

```
## Response: Y
##               Df Sum Sq Mean Sq F value Pr(>F)
## Grupo         1  5636.6   5636.6  95.6879 <2e-16 ***
## Geno_num       1    26.7    26.7   0.4531  0.5017
## Grupo:Geno_num 1     0.0     0.0   0.0003  0.9853
## Residuals     176 10367.5    58.9
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Comparação R²: categórico = 0.356 | quantitativo = 0.353
```

Interpretação P1:

Perfil de médias e boxplot: as linhas do perfil de médias oscilam levemente entre genótipos — a linha do subgrupo B sobe de aa para Aa e recua em AA, enquanto a do subgrupo A desce ligeiramente — mas essas variações refletem apenas flutuação amostral, hipótese fortalecida pelos testes seguintes. A separação vertical entre subgrupos é consistente e visualmente dominante. O boxplot corrobora: as distribuições dentro de cada subgrupo são similares entre genótipos.

ANOVA: apenas o efeito de Grupo é significativo ($F = 94,96$; $p < 0,001$). Os efeitos de Genótipo ($F = 0,27$; $p = 0,761$) e da interação Grupo×Genótipo ($F = 0,28$; $p = 0,755$) não são significativos.

Diagnóstico: normalidade (Shapiro-Wilk: $W = 0,994$; $p = 0,744$) e homocedasticidade (Bartlett: $K^2 = 10,56$; $p = 0,061$) satisfeitas. O gráfico “Constant Leverage” mostra resíduos uniformemente distribuídos entre os níveis de Grupo, sem padrões preocupantes.

Tukey: o contraste B-A é significativo ($\sim 11,2$ mmHg; $p < 0,001$). Todos os contrastes entre genótipos (Aa-aa, AA-aa, AA-Aa) incluem o zero nos ICs e têm $p > 0,75$, confirmando ausência de efeito do SNP sobre a pressão diastólica. No Tukey da interação Grupo:Genótipo, os únicos contrastes significativos são aqueles que comparam subgrupos opostos (ex.: B:aa-A:aa, B:Aa-A:Aa), confirmando que toda a significância se deve ao efeito de subgrupo, não ao SNP.


SNP quantitativo (item iv): o modelo com `Geno_num` confirma: coeficiente do SNP não significativo ($-0,48$; $p = 0,625$) e interação Grupo×Geno_num também não significativa ($p = 0,985$). O ajuste é praticamente equivalente ao modelo categórico ($R^2 = \text{categórico } 0.356 \mid \text{quantitativo } 0.353$), com a variância explicada quase integralmente pelo efeito de subgrupo populacional.

2.2.3 P2 – Efeito aditivo de SNP, sem interação (perfis paralelos)





```
res_P2 <- analisa_pop(dat_P2, "P2")

##
##
## =====
## POPULAÇÃO: P2
## =====
##
## --- (i) Estatísticas Descritivas ---
##
##
## Table: Descritivas - P2
##
## |   |group1 |group2 |  n| mean|   sd| median|
## |---|:-----|:-----|--|:-----|:-----|:-----|
## |Y1 |A      |aa      | 30| 74.03| 9.13| 74.11|
## |Y2 |B      |aa      | 30| 79.11| 7.25| 78.43|
## |Y3 |A      |Aa      | 30| 79.76| 8.37| 79.23|
```

##	Y4	B	Aa		30	84.61	7.90	83.63
##	Y5	A	AA		30	90.08	7.68	89.23
##	Y6	B	AA		30	98.91	8.27	101.49




```
##
## --- (iii) ANOVA Fatorial 3x2 (Genotipo categórico) ---
##
##          Df Sum Sq Mean Sq F value    Pr(>F)
## Grupo      1   1757    1757  26.627 6.68e-07 ***
## Genotipo    2  10091    5046  76.474 < 2e-16 ***
## Grupo:Genotipo 2    150     75   1.134   0.324
## Residuals 174  11480     66
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Coeficientes:
##      (Intercept)          GrupoB      GenotipoAa      GenotipoAA  GrupoB:GenotipoAa  GrupoB:Gen
##      74.0288813         5.0763575         5.7354973        16.0553098        -0.2321264         3.7
```




```
##
## Shapiro-Wilk (normalidade resíduos):
##
## Shapiro-Wilk normality test
##
## data: fit_cat$residuals
## W = 0.9929, p-value = 0.5306
##
## Bartlett (homocedasticidade):
##
## Bartlett test of homogeneity of variances
##
## data: Y by interaction(Grupo, Genotipo)
## Bartlett's K-squared = 1.8307, df = 5, p-value = 0.872
##
##
## Comparações múltiplas de Tukey:
## Tukey multiple comparisons of means
## 95% family-wise confidence level
##
## Fit: aov(formula = Y ~ Grupo * Genotipo, data = dat)
##
## $Grupo
##      diff      lwr      upr p adj
## B-A 6.248239 3.85837 8.638107 7e-07
```

```
##
## $Genotipo
##      diff      lwr      upr      p adj
## Aa-aa  5.619434  2.113712  9.125156  0.0006069
## AA-aa 17.929195 14.423473 21.434916 0.0000000
## AA-Aa 12.309761  8.804039 15.815482 0.0000000
##
## $`Grupo:Genotipo`
##      diff      lwr      upr      p adj
## B:aa-A:aa  5.0763575 -0.9674497 11.120165 0.1549331
## A:Aa-A:aa  5.7354973 -0.3083098 11.779304 0.0736213
## B:Aa-A:aa 10.5797283  4.5359212 16.623535 0.0000167
## A:AA-A:aa 16.0553098 10.0115027 22.099117 0.0000000
## B:AA-A:aa 24.8794373 18.8356302 30.923244 0.0000000
## A:Aa-B:aa  0.6591398 -5.3846673  6.702947 0.9995854
## B:Aa-B:aa  5.5033709 -0.5404363 11.547178 0.0969478
## A:AA-B:aa 10.9789523  4.9351452 17.022759 0.0000070
## B:AA-B:aa 19.8030798 13.7592727 25.846887 0.0000000
## B:Aa-A:AA  4.8442311 -1.1995761 10.888038 0.1957295
## A:AA-A:AA 10.3198125  4.2760054 16.363620 0.0000291
## B:AA-A:AA 19.1439400 13.1001329 25.187747 0.0000000
## A:AA-B:AA  5.4755815 -0.5682257 11.519389 0.1001007
## B:AA-B:AA 14.2997090  8.2559018 20.343516 0.0000000
## B:AA-A:AA  8.8241275  2.7803204 14.867935 0.0005826
```


95% family-wise confidence level



95% family-wise confidence level



95% family-wise confidence level



Differences in mean levels of Grupo:Genotipo

```
##
## --- (iv) SNP como variável quantitativa (efeito aditivo linear) ---
##
## Call:
## lm(formula = Y ~ Grupo * Geno_num, data = dat)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -21.0974  -5.5636   0.1684   4.8664  25.1543
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    73.265     1.375  53.299 < 2e-16 ***
## GrupoB          4.374     1.944   2.250  0.0257 *
## Geno_num        8.028     1.065   7.539 2.41e-12 ***
## GrupoB:Geno_num  1.874     1.506   1.244  0.2150
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 8.248 on 176 degrees of freedom
## Multiple R-squared:  0.4901, Adjusted R-squared:  0.4814
## F-statistic: 56.38 on 3 and 176 DF, p-value: < 2.2e-16
##
## Analysis of Variance Table
##
```

```
## Response: Y
##               Df Sum Sq Mean Sq F value    Pr(>F)
## Grupo         1  1756.8   1756.8   25.8265 9.479e-07 ***
## Geno_num      1  9643.7   9643.7  141.7691 < 2.2e-16 ***
## Grupo:Geno_num 1   105.3    105.3    1.5486   0.215
## Residuals    176 11972.2    68.0
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Comparação R²: categórico = 0.511 | quantitativo = 0.49
```

Interpretação P2:

Perfil de médias e boxplot: as linhas do perfil de médias variam de forma ascendente entre os genótipos. As linhas dos subgrupos são aproximadamente paralelas, indicando independência do efeito do SNP em relação ao subgrupo. O boxplot corrobora: as distribuições dentro de cada subgrupo mostram aumento progressivo da mediana e da média de Y de aa para AA.

ANOVA: são significativos tanto o efeito de Grupo ($F = 26,63$; $p < 0,001$) quanto do Genótipo ($F = 76,47$; $p < 0,001$). Já interação Grupo $\times$ Genótipo é não significativa ($F = 1,134$; $p = 0,324$).

Diagnóstico: normalidade (Shapiro-Wilk: $W = 0,993$; $p = 0,531$) e homocedasticidade (Bartlett: $K^2 = 1,831$; $p = 0,872$) satisfeitas. O gráfico “Constant Leverage” mostra resíduos bem distribuídos.

Tukey: o contraste B-A é significativo ($\sim 6,2$ mmHg; $p < 0,001$), indicando diferença entre subgrupos. Todos os contrastes entre genótipos são significativos (Aa-aa: $+5,6$ mmHg, $p < 0,001$; AA-aa: $+17,9$ mmHg, $p < 0,001$; AA-Aa: $+12,3$ mmHg, $p < 0,001$), confirmando o efeito do SNP sobre a pressão diastólica. No Tukey da interação Grupo:Genótipo, os contrastes dentro do mesmo subgrupo entre genótipos distintos são em sua maioria significativos (ex.: A:AA-A:aa, B:AA-B:aa), enquanto contrastes entre subgrupos dentro do mesmo genótipo tendem a não atingir significância isoladamente (ex.: B:aa-A:aa: $p = 0,155$; B:Aa-A:Aa: $p = 0,196$), sugerindo que o efeito de subgrupo é menos pronunciado do que o efeito do SNP nesta população. A ausência de interação significativa na ANOVA é corroborada: o padrão de diferenças entre genótipos é consistente entre os subgrupos A e B.

SNP quantitativo (item iv): o modelo com `Geno_num` detecta efeito do SNP altamente significativo ($p < 0,001$). O efeito de Grupo permanece significativo ($p = 0,026$) e a interação Grupo $\times$ Geno_num não é significativa ($p = 0,215$), reforçando a ausência de interação já observada no modelo categórico. O R^2 é ligeiramente inferior ao do modelo categórico (0,490 vs. 0,511), diferença pequena que reflete a perda de um G.L. causada ao assumir linearidade do efeito de SNP, que assumindo os valores [0, 1, 2] seria necessariamente aditivo, ignorando possíveis efeitos adicionais, como dominância ou recessividade. Em casos como este, que o heterozigoto não está exatamente no ponto médio entre aa e AA, há perda de informação. O uso do SNP quantitativo é, então, ideal somente para casos em que o efeito aditivo é muito mais significativo que quaisquer outros.


2.2.4 P3 – Efeito de SNP com interação (epistasia SNP $\times$ Subgrupo)

```
res_P3 <- analisa_pop(dat_P3, "P3")
```


```
##
##
## =====
## POPULAÇÃO: P3
## =====
##
```

```
## --- (i) Estatísticas Descritivas ---
##
##
## Table: Descritivas - P3
##
## | |group1 |group2 | n| mean| sd| median|
## |---|:-----|:-----|---|-----:|-----:|-----:|
## |Y1 |A      |aa      | 30| 76.23| 7.10| 75.47|
## |Y2 |B      |aa      | 30| 75.40| 8.69| 74.82|
## |Y3 |A      |Aa      | 30| 78.91| 7.77| 78.46|
## |Y4 |B      |Aa      | 30| 84.26| 7.96| 84.10|
## |Y5 |A      |AA      | 30| 85.42| 9.07| 84.44|
## |Y6 |B      |AA      | 30| 100.44| 9.68| 101.09|
```

Perfil de Médias – P3







Boxplot – P3



```
##
## --- (iii) ANOVA Fatorial 3x2 (Genotipo categórico) ---
##
##          Df Sum Sq Mean Sq F value    Pr(>F)
## Grupo      1   1906    1906    26.87 5.99e-07 ***
## Genotipo    2   9096    4548    64.10 < 2e-16 ***
## Grupo:Genotipo 2   1916     958    13.50 3.54e-06 ***
## Residuals 174 12345       71
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Coeficientes:
##      (Intercept)      GrupoB      GenotipoAa      GenotipoAA  GrupoB:GenotipoAa  GrupoB:GenotipoAA
```


76.2341934 -0.8376434 2.6775862 9.1847370 6.1835631 15.8




```
##
## Shapiro-Wilk (normalidade resíduos):
##
## Shapiro-Wilk normality test
##
## data: fit_cat$residuals
## W = 0.99501, p-value = 0.8113
##
## Bartlett (homocedasticidade):
##
## Bartlett test of homogeneity of variances
##
## data: Y by interaction(Grupo, Genotipo)
## Bartlett's K-squared = 3.6449, df = 5, p-value = 0.6016
##
##
## Comparações múltiplas de Tukey:
## Tukey multiple comparisons of means
## 95% family-wise confidence level
##
## Fit: aov(formula = Y ~ Grupo * Genotipo, data = dat)
##
## $Grupo
##      diff      lwr      upr p adj
```

```
## B-A 6.508804 4.030576 8.987031 6e-07
##
## $Genotipo
##      diff      lwr      upr      p adj
## Aa-aa  5.769368  2.134031  9.404705 0.0006967
## AA-aa 17.112626 13.477289 20.747963 0.0000000
## AA-Aa 11.343258  7.707921 14.978595 0.0000000
##
## $`Grupo:Genotipo`
##      diff      lwr      upr      p adj
## B:aa-A:aa -0.8376434 -7.1049053  5.429619 0.9988855
## A:Aa-A:aa  2.6775862 -3.5896757  8.944848 0.8210097
## B:Aa-A:aa  8.0235058  1.7562439 14.290768 0.0040153
## A:AA-A:aa  9.1847370  2.9174751 15.451999 0.0005474
## B:AA-A:aa 24.2028712 17.9356094 30.470133 0.0000000
## A:Aa-B:aa  3.5152295 -2.7520324  9.782491 0.5889066
## B:Aa-B:aa  8.8611492  2.5938873 15.128411 0.0009766
## A:AA-B:aa 10.0223804  3.7551185 16.289642 0.0001131
## B:AA-B:aa 25.0405146 18.7732527 31.307777 0.0000000
## B:Aa-A:AA  5.3459197 -0.9213422 11.613182 0.1426013
## A:AA-A:AA  6.5071509  0.2398890 12.774413 0.0368267
## B:AA-A:AA 21.5252851 15.2580232 27.792547 0.0000000
## A:AA-B:AA  1.1612312 -5.1060307  7.428493 0.9947156
## B:AA-B:AA 16.1793654  9.9121035 22.446627 0.0000000
## B:AA-A:AA 15.0181342  8.7508723 21.285396 0.0000000
```


95% family-wise confidence level



95% family-wise confidence level



95% family-wise confidence level



Differences in mean levels of Grupo:Genotipo

```
##
## --- (iv) SNP como variável quantitativa (efeito aditivo linear) ---
##
## Call:
## lm(formula = Y ~ Grupo * Geno_num, data = dat)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -22.6306  -5.0435  -0.5809   6.1423  22.7371
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    75.596     1.415  53.425 < 2e-16 ***
## GrupoB         -1.419     2.001  -0.709   0.479
## Geno_num         4.592     1.096   4.190 4.41e-05 ***
## GrupoB:Geno_num  7.928     1.550   5.115 8.16e-07 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 8.49 on 176 degrees of freedom
## Multiple R-squared:  0.4978, Adjusted R-squared:  0.4893
## F-statistic: 58.16 on 3 and 176 DF, p-value: < 2.2e-16
##
## Analysis of Variance Table
##
```



```
## Response: Y
##               Df Sum Sq Mean Sq F value    Pr(>F)
## Grupo          1  1906.4   1906.4   26.449 7.161e-07 ***
## Geno_num        1   8785.3   8785.3  121.883 < 2.2e-16 ***
## Grupo:Geno_num  1   1885.5   1885.5   26.159 8.158e-07 ***
## Residuals      176 12686.0     72.1
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Comparação R²: categórico = 0.511 | quantitativo = 0.498
```

Interpretação P3:

Perfil de médias e boxplot: as linhas do perfil de médias crescem afastando-se, indicando que dessa vez, não podemos assumir independência do efeito do SNP em relação ao subgrupo. O boxplot mostra “shifts” maiores entre genótipos no subgrupo B, evidenciando a interação: o efeito do SNP é mais acentuado em B do que em A.

ANOVA: são significativos ambos o efeito de Grupo ($F = 26,87$; $p < 0,001$) e de Genótipo ($F = 64,10$; $p < 0,001$). E também é significativa a interação Grupo×Genótipo ($F = 13,50$; $p < 0,001$).

Diagnóstico: normalidade (Shapiro-Wilk: $W = 0,995$; $p = 0,811$) e homocedasticidade (Bartlett: $K^2 = 3,645$; $p = 0,602$) satisfeitas. O gráfico “Constant Leverage” mostra resíduos bem distribuídos. Já o “Scale-Location” apresenta uma leve inclinação ascendente, sugerindo que a variabilidade dos resíduos tende a aumentar com os valores ajustados. Ainda assim, o teste de Bartlett não rejeita a homocedasticidade, então o padrão observado no gráfico não é estatisticamente relevante com este tamanho amostral.

Tukey: o contraste B-A é significativo ($\sim 6,5$ mmHg; $p < 0,001$), indicando diferença entre subgrupos. Todos os contrastes entre genótipos são significativos (Aa-aa: $+5,8$ mmHg, $p < 0,001$; AA-aa: $+17,1$ mmHg, $p < 0,001$; AA-Aa: $+11,3$ mmHg, $p < 0,001$), confirmando o efeito do SNP sobre a pressão diastólica. No Tukey da interação Grupo:Genótipo, o padrão de contrastes revela claramente a interação SNP×subgrupo: dentro do subgrupo A, o efeito do SNP é moderado (A:AA-A:aa: $+9,2$ mmHg; $p < 0,001$), enquanto no subgrupo B é muito mais acentuado (B:AA-B:aa: $+25,0$ mmHg; $p < 0,001$). Contrastes entre subgrupos dentro do mesmo genótipo mostram que A e B são indistinguíveis em aa (B:aa-A:aa: $p = 0,999$) mas divergem fortemente em AA (B:AA-A:AA: $+15,0$ mmHg; $p < 0,001$), confirmando que a diferença entre subgrupos depende do genótipo — assinatura inequívoca de interação. Estes resultados corroboram a interação significativa observada na ANOVA e o não-paralelismo das linhas no perfil de médias.

SNP quantitativo (item iv): o modelo com `Geno_num` assume e detecta efeito aditivo linear significativo no subgrupo A ($\hat{\beta} = 4,59$ mmHg por alelo A; $p < 0,001$) e uma interação Grupo×Geno_num altamente significativa ($\hat{\beta} = 7,93$; $p < 0,001$), indicando que o efeito do SNP é maior por alelo A no subgrupo B do que em A — resultado coerente com a interação detectada no modelo categórico. O efeito principal de Grupo não é significativo ($p = 0,479$). Isso pode ser justificado pois quando há interação, o efeito de Grupo depende do genótipo, não podendo ser interpretado isoladamente. O R^2 é ligeiramente inferior ao do modelo categórico (0,498 vs. 0,511), diferença pequena que reflete a restrição de G.L. causada pela adoção da linearidade. A conclusão é a mesma: há interação SNP×grupo significativa, com o efeito do SNP sendo muito mais pronunciado no grupo B.

2.3 Item (d) – Combinando as três populações

A análise conjunta permite avaliar se os efeitos do SNP e do subgrupo são consistentes entre populações ou se há heterogeneidade, questão central em estudos de genética de populações.

2.3.1 (d.i) – Fatorial 3 x 2 x 3 : SNP × Grupo × População (todos fixos)

```
dat_all <- rbind(dat_P1, dat_P2, dat_P3)
dat_all$Pop <- factor(dat_all$Pop) # Transformo população em var. categórica

# Estatísticas descritivas do dataset combinado
desc_all <- describeBy(dat_all$Y,
                        group = list(dat_all$Pop, dat_all$Grupo, dat_all$Genotipo),
                        mat = TRUE)

tabela_all <- desc_all[, c("group1", "group2", "group3", "n", "mean", "sd", "median", "min", "max")]
rownames(tabela_all) <- NULL


knitr::kable(tabela_all, digits = 2,
             col.names = c("População", "Grupo", "Genótipo", "n", "Média", "DP", "Mediana", "Mín", "Máx"),
             caption = "Estatísticas descritivas de Y por População, Grupo e Genótipo")
```

Table 3: Estatísticas descritivas de Y por População, Grupo e Genótipo

População	Grupo	Genótipo	n	Média	DP	Mediana	Mín	Máx
P1	A	aa	30	79.95	7.92	79.10	66.62	94.18
P2	A	aa	30	74.03	9.13	74.11	54.91	92.07
P3	A	aa	30	76.23	7.10	75.47	60.13	93.82
P1	B	aa	30	90.51	9.23	90.51	75.07	107.78
P2	B	aa	30	79.11	7.25	78.43	63.70	91.86
P3	B	aa	30	75.40	8.69	74.82	55.89	95.17
P1	A	Aa	30	78.93	9.11	79.71	60.14	94.87
P2	A	Aa	30	79.76	8.37	79.23	65.14	98.32
P3	A	Aa	30	78.91	7.77	78.46	60.86	94.20
P1	B	Aa	30	91.34	6.16	90.93	78.77	112.20
P2	B	Aa	30	84.61	7.90	83.63	73.61	103.71
P3	B	Aa	30	84.26	7.96	84.10	66.69	99.87
P1	A	AA	30	78.98	5.76	78.81	66.94	93.31
P2	A	AA	30	90.08	7.68	89.23	79.32	114.47
P3	A	AA	30	85.42	9.07	84.44	62.15	101.10
P1	B	AA	30	89.59	7.35	90.83	72.80	104.50
P2	B	AA	30	98.91	8.27	101.49	76.34	114.68
P3	B	AA	30	100.44	9.68	101.09	81.02	121.95

```
# Perfil de médias
with(dat_all,
     interaction.plot(Genotipo, interaction(Gruo,Pop), Y,
                     main="Perfil Médias: SNP x Grupo x População",
                     xlab="Genótipo", ylab="Média Y",
                     lwd=2, type="b"))
```

Perfil Médias: SNP x Grupo x População



Modelo completo 3x2x3

```
fit_fixo <- aov(Y ~ Grupo * Genótipo * Pop, data = dat_all)
summary(fit_fixo)
```

```
##              Df Sum Sq Mean Sq F value    Pr(>F)
## Grupo          1   8603    8603 131.492 < 2e-16 ***
## Genótipo        2  12069    6034  92.227 < 2e-16 ***
## Pop             2    195      97   1.490 0.226376
## Grupo:Genótipo  2    979     490   7.485 0.000624 ***
## Grupo:Pop       2    697     348   5.323 0.005145 **
## Genótipo:Pop    4   7151    1788  27.324 < 2e-16 ***
## Grupo:Genótipo:Pop 4   1120     280   4.278 0.002049 **
## Residuals      522  34153      65
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Coeficientes do modelo

```
fit_fixo$coef
```

```
##              (Intercept)              GrupoB              GenótipoAa              GenótipoAA
##              79.95232024              10.55691612              -1.01984317              -0.96910237
##              GrupoB:GenótipoAA              GrupoB:PopP2              GrupoB:PopP3              GenótipoAa:PopP2
##              0.05166645              -5.48055866              -11.39455950              6.75534045
## GrupoB:GenótipoAa:PopP2 GrupoB:GenótipoAA:PopP2 GrupoB:GenótipoAa:PopP3 GrupoB:GenótipoAA:PopP3
##              -2.08533317              3.69610359              4.33035631              15.80411113
```

Modelo (d.i) — População como fator fixo: $Y \sim \text{Grupo} * \text{Genótipo} * \text{Pop}$ inclui todos os efeitos principais e interações de 2ª e 3ª ordem (17 g.l. de tratamento). Grupo ($F = 131,5$; $p < 0,001$) e Genótipo ($F = 92,2$; $p < 0,001$) são significativos, mas Pop isoladamente não ($F = 1,49$; $p = 0,226$). A interação tripla Grupo×Genótipo×Pop é significativa ($F = 4,28$; $p = 0,002$), confirmando que o padrão de interação SNP×subgrupo é heterogêneo entre populações — como visível no gráfico, onde as inclinações diferem marcadamente entre P1, P2 e P3.

2.3.2 (d.ii) – Fatorial 3 x 2 com População como fator aleatório (ANOVA Mista)

```
library(lme4)

# Modelo misto: Population como efeito aleatório (intercepto aleatório por Pop)
fit_misto <- lmer(Y ~ Grupo * Genotipo + (1 | Pop), data = dat_all, REML = TRUE)
summary(fit_misto)

## Linear mixed model fit by REML. t-tests use Satterthwaite's method ['lmerModLmerTest']
## Formula: Y ~ Grupo * Genotipo + (1 | Pop)
## Data: dat_all
##
## REML criterion at convergence: 3889.8
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -2.8484 -0.6599 -0.0410  0.6774  3.2897
##
## Random effects:
## Groups Name Variance Std.Dev.
## Pop (Intercept) 0.09122 0.302
## Residual 81.05413 9.003
## Number of obs: 540, groups: Pop, 3
##
## Fixed effects:
## Estimate Std. Error df t value Pr(>|t|)
## (Intercept) 76.7385 0.9649 49.9573 79.531 < 2e-16 ***
## GrupoB 4.9319 1.3421 532.0000 3.675 0.000262 ***
## GenotipoAa 2.4644 1.3421 532.0000 1.836 0.066878 .
## GenotipoAA 8.0903 1.3421 532.0000 6.028 3.1e-09 ***
## GrupoB:GenotipoAa 2.6015 1.8980 532.0000 1.371 0.171053
## GrupoB:GenotipoAA 6.5517 1.8980 532.0000 3.452 0.000601 ***
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
## (Intr) GrupoB GntpA GntpAA GrB:GA
## GrupoB -0.695
## GenotipoAa -0.695 0.500
## GenotipoAA -0.695 0.500 0.500
## GrpB:GntpA 0.492 -0.707 -0.707 -0.354
## GrpB:GntpAA 0.492 -0.707 -0.354 -0.707 0.500

# Coeficientes do modelo
print(coef(fit_misto))

## $Pop
## (Intercept) GrupoB GenotipoAa GenotipoAA GrupoB:GenotipoAa GrupoB:GenotipoAA
## P1 76.84579 4.931877 2.464413 8.090315 2.601548 6.551738
## P2 76.76683 4.931877 2.464413 8.090315 2.601548 6.551738
## P3 76.60277 4.931877 2.464413 8.090315 2.601548 6.551738
##
## attr(,"class")
## [1] "coef.mer"
```

```
# Teste dos efeitos fixos
library(lmerTest)
fit_misto2 <- lmer(Y ~ Grupo * Genotipo + (1 | Pop), data = dat_all, REML = FALSE)
anova(fit_misto2)
```

```
## Type III Analysis of Variance Table with Satterthwaite's method
##              Sum Sq Mean Sq NumDF DenDF  F value    Pr(>F)
## Grupo          8603.3   8603.3     1    540 107.2534 < 2.2e-16 ***
## Genotipo       12068.5   6034.3     2    540  75.2267 < 2.2e-16 ***
## Grupo:Genotipo   979.5    489.7     2    540   6.1053 0.002388 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Modelo (d.ii) — População como fator aleatório: $Y \sim \text{Grupo} * \text{Genotipo} + (1|\text{Pop})$ é adequado quando as populações são entendidas como amostra de um universo mais amplo, generalizando as inferências além das 3 observadas. A variância entre populações é ínfima ($\hat{\sigma}_{Pop}^2 = 0,091$) frente à residual ($\hat{\sigma}^2 = 81,05$), e os efeitos fixos de Grupo, Genótipo e sua interação permanecem significativos. Uma importante limitação deste modelo é que ele assume homogeneidade dos efeitos fixos entre populações, algo que já sabemos que não ocorre pelo modelo fixo do item anterior. Uma possível melhoria seria trabalhar com $(\text{Genotipo} | \text{Pop})$, permitindo que a inclinação do efeito do SNP também varie aleatoriamente entre populações. Porém, estimar essa matriz de variância-covariância na prática com apenas 3 populações é inviável, pois o modelo dificilmente iria convergir de forma estável, então esta argumentação serve mais como motivação para designs futuros com maior número de populações.

3 Regressão Logística: Y dicotomizada

3.1 Dicotomização de Y

```
# Ponto de corte: mediana global de cada dataset
corte1 <- median(dat1$Y)
corte2 <- median(dat2$Y)
corte_all <- median(dat_all$Y)

dat1$Ybin <- as.factor(ifelse(dat1$Y > corte1, 1, 0))
dat2$Ybin <- as.factor(ifelse(dat2$Y > corte2, 1, 0))
dat_all$Ybin <- as.factor(ifelse(dat_all$Y > corte_all, 1, 0))

cat("Ponto de corte Q1:", corte1, " | Distribuição:\n"); print(table(dat1$Ybin))

## Ponto de corte Q1: 108.5428 | Distribuição:
##
##  0  1
## 150 150

tab1 <- table(factor(dat1$Ybin, labels = c("baixo", "alto")), dat1$SNP)
tab1 <- rbind(tab1, "total" = colSums(tab1))
tab1

##      aa  Aa AA
## baixo 137  13  0
## alto   11 110 29
## total 148 123 29
```

```
cat("Ponto de corte Q2:", corte2, " | Distribuição:\n"); print(table(dat2$Ybin))
```

```
## Ponto de corte Q2: 99.32791 | Distribuição:
```


```
##
```

```
## 0 1
```

```
## 450 450
```

```
plot <- ggplot2::ggplot(dat2, ggplot2::aes(x = SNP1, fill = SNP2)) +
  ggplot2::geom_bar(position = ggplot2::position_dodge()) +
  ggplot2::facet_wrap(~ Ybin) +
  ggplot2::scale_fill_brewer(type = "qual", palette = "Set2", name = "SNP2") +
  ggplot2::labs(
    title = "Contingência - Q2 (SNP1 x SNP2 x Resposta)",
    x = "Genótipo SNP1",
    y = "Contagem"
  ) +
  ggplot2::theme_minimal()
```

```
print(plot)
```



Dicotomização de Y: A mediana é adotada como ponto de corte, resultando em distribuição perfeitamente balanceada: 150 observações em cada classe para Q1 (corte = 107,93) e 225 para Q2 (corte = 99,44). Essa escolha maximiza o poder do teste logístico, mas é arbitrária — um corte clinicamente motivado seria igualmente válido e potencialmente mais interpretável.

3.2 Questão 1 (Caso 1) – Regressão Logística

```
# Modelo logístico
fitr11_ad <- glm(as.factor(Ybin) ~ xa + xd, family=binomial(link="logit"), data=dat1)
```

```

summary(fitr11_ad)

##
## Call:
## glm(formula = as.factor(Ybin) ~ xa + xd, family = binomial(link = "logit"),
##      data = dat1)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    8.022    605.612   0.013   0.989
## xa             10.544    605.612   0.017   0.986
## xd             -5.886    605.612  -0.010   0.992
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 415.89  on 299  degrees of freedom
## Residual deviance: 161.35  on 297  degrees of freedom
## AIC: 167.35
##
## Number of Fisher Scoring iterations: 17
cat("\nOR estimado (exp(coef)):\n")

##
## OR estimado (exp(coef)):
print(exp(coef(fitr11_ad)))

## (Intercept)          xa          xd
## 3.047240e+03 3.795198e+04 2.776788e-03
cat("\nIC para OR:\n")

##
## IC para OR:
print(exp(confint(fitr11_ad)))

##              2.5 %          97.5 %
## (Intercept) 1.339586e-17          NA
## xa          2.516933e-09 4.004769e+80
## xd          NA 1.777731e+12
# Probabilidades preditas e tabela de classificação
pred1r <- predict(fitr11_ad, type="response")
class1r <- ifelse(pred1r >= 0.5, 1, 0)
cat("Tabela de classificação:\n")

## Tabela de classificação:
print(table(Predito=class1r, Observado=dat1$Ybin))

##      Observado
## Predito    0    1
##      0 137  11
##      1  13 139
cat("Acurácia:", round(mean(class1r == dat1$Ybin), 3), "\n")

```

```
## Acurácia: 0.92
```

```
#plot(0:2, tapply(as.numeric(dat1$Ybin)-1, dat1$snp_num, mean),
#      type="b", pch=19, col="blue", xaxt="n",
#      xlab="Genótipo", ylab="P(Y=1 | Genótipo)",
#      main="Prob. estimadas vs. observadas - Regressão Logística (Q1-C1)")
#axis(1, at=0:2, labels=c("aa", "Aa", "AA"))
#lines(0:2, tapply(pred1r, dat1$snp_num, mean), col="red", lty=2, pch=15, type="b")
#legend("topleft", c("Observado", "Predito"), col=c("blue", "red"), lty=c(1,2), bty="n")
```

Regressão Logística – Q1 Caso 1: O estabelecimento do valor corte para dicotomização de Y na mediana dos dados causou um fenômeno de separação completa dos grupos devido à ausência de observações “baixas” para o genótipo AA. Isso fez o modelo de regressão logística não recuperar adequadamente os coeficientes para os efeitos aditivo e de dominância, que tiveram a significância ignorada. Decidimos então voltar atrás e definir arbitrariamente um valor de corte que não deixasse valores nulos na tabela de contingência “altos *versus* baixos.”

```
corte1 <- 111
dat1$Ybin <- as.factor(ifelse(dat1$Y > corte1, 1, 0))

cat("Ponto de corte Q1:", corte1, " | Distribuição:\n"); print(table(dat1$Ybin))
```

```
## Ponto de corte Q1: 111 | Distribuição:
```

```
##
##  0  1
## 173 127
```

```
tab1 <- table(factor(dat1$Ybin, labels = c("baixo", "alto")), dat1$SNP)
tab1 <- rbind(tab1, "total" = colSums(tab1))
tab1
```

```
##      aa  Aa AA
## baixo 144  27  2
## alto   4  96 27
## total 148 123 29
```

```
fitr11_ad <- glm(as.factor(Ybin) ~ xa + xd, family=binomial(link="logit"), data=dat1)
summary(fitr11_ad)
```

```
##
## Call:
## glm(formula = as.factor(Ybin) ~ xa + xd, family = binomial(link = "logit"),
##      data = dat1)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -0.4904      0.4455  -1.101  0.27101
## xa              3.0931      0.4455   6.943 3.85e-12 ***
## xd              1.7589      0.4959   3.547 0.00039 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 408.81  on 299  degrees of freedom
## Residual deviance: 180.80  on 297  degrees of freedom
## AIC: 186.8
```



```
##
## Number of Fisher Scoring iterations: 6
cat("\nOR estimado (exp(coef)):\n")

##
## OR estimado (exp(coef)):
print(exp(coef(fitr11_ad)))

## (Intercept)          xa          xd
## 0.6123724 22.0454077 5.8061979
cat("\nIC para OR:\n")

##
## IC para OR:
print(exp(confint(fitr11_ad)))

##          2.5 %    97.5 %
## (Intercept) 0.2636769 1.673448
## xa         10.2133711 61.911080
## xd          1.9757020 14.980133
pred1r <- predict(fitr11_ad, type="response")
class1r <- ifelse(pred1r >= 0.5, 1, 0)
cat("Tabela de classificação:\n")

## Tabela de classificação:
print(table(Predito=class1r, Observado=dat1$Ybin))

##      Observado
## Predito    0    1
##      0 144    4
##      1  29 123
cat("Acurácia:", round(mean(class1r == dat1$Ybin), 3), "\n")

## Acurácia: 0.89
```

Regressão Logística – Q1 Caso 1 (com corte arbitrário): Dessa vez, conseguimos evitar a separação total dos grupos, possibilitando que o modelo recuperasse adequadamente os coeficientes, resultando em $\log\left(\frac{\rho}{1-\rho}\right) = -0.4904 + 3.0931 \times x_a + 1.7589 \times x_d$, com significância para ambos ($p_{x_a} = 3.85 \times 10^{-12}$; $p_{x_d} = 0.00039$).

3.3 Questão 1 (Caso 2) – Regressão Logística com dois SNPs

```
fitr12 <- glm(Ybin ~ xa1 + xd1 + xa2 + xd2 +
              xa1:xa2 + xa1:xd2 + xd1:xa2 + xd1:xd2,
              family=binomial(link="logit"), data=dat2)
summary(fitr12)

##
## Call:
## glm(formula = Ybin ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xa1:xd2 +
##      xd1:xa2 + xd1:xd2, family = binomial(link = "logit"), data = dat2)
```

```
##
## Coefficients:
##           Estimate Std. Error z value Pr(>|z|)
## (Intercept)  0.42831    0.28327   1.512  0.13052
## xa1          1.35709    0.28327   4.791 1.66e-06 ***
## xd1          0.43266    0.35125   1.232  0.21804
## xa2          0.86441    0.28327   3.052  0.00228 **
## xd2          0.22832    0.39495   0.578  0.56319
## xa1:xa2      0.48568    0.28327   1.715  0.08643 .
## xa1:xd2      0.09649    0.39495   0.244  0.80700
## xd1:xa2      0.18416    0.35125   0.524  0.60007
## xd1:xd2      0.27470    0.48585   0.565  0.57181
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
## Null deviance: 1247.7 on 899 degrees of freedom
## Residual deviance: 1002.6 on 891 degrees of freedom
## AIC: 1020.6
##
## Number of Fisher Scoring iterations: 5
```

```
cat("\nOR estimados:\n")
```

```
##
## OR estimados:
```

```
print(round(exp(coef(fitr12)), 3))
```

```
## (Intercept)      xa1      xd1      xa2      xd2      xa1:xa2      xa1:xd2      xd1:xa2
##      1.535      3.885      1.541      2.374      1.256      1.625      1.101      1.202
```

```
cat("\nIC para OR:\n")
```

```
##
## IC para OR:
```

```
print(round(exp(confint(fitr12)), 3))
```

```
##           2.5 % 97.5 %
## (Intercept) 0.961 3.247
## xa1         2.433 8.221
## xd1         0.675 2.949
## xa2         1.483 5.021
## xd2         0.524 2.740
## xa1:xa2     1.015 3.438
## xa1:xd2     0.459 2.402
## xd1:xa2     0.527 2.302
## xd1:xd2     0.506 3.623
```

```
pred2r <- predict(fitr12, type="response")
class2r <- ifelse(pred2r >= 0.5, 1, 0)
cat("Tabela de classificação:\n")
```

```
## Tabela de classificação:
```

```
print(table(Predito=class2r, Observado=dat2$Ybin))
```

```
##      Observado
## Predito    0    1
##      0 392 190
##      1   58 260
```

```
cat("Acurácia:", round(mean(class2r == dat2$Ybin), 3), "\n")
```

```
## Acurácia: 0.724
```

Regressão Logística – Q1 Caso 2: O estabelecimento do valor corte para dicotomização de Y na mediana dos dados causou uma separação muito desbalanceada entre os grupos **resposta** e **não resposta**, que acreditamos ter atrapalhado a eficácia do teste. Decidimos então, tentar novamente com um corte manual.

```
corte2 <- 105
```

```
dat2$Ybin <- as.factor(ifelse(dat2$Y > corte2, 1, 0))
```

```
cat("Ponto de corte Q2:", corte2, " | Distribuição:\n"); print(table(dat2$Ybin))
```


```
## Ponto de corte Q2: 105 | Distribuição:
```

```
##
##    0    1
## 574 326
```

```
plot <- ggplot2::ggplot(dat2, ggplot2::aes(x = SNP1, fill = SNP2)) +
  ggplot2::geom_bar(position = ggplot2::position_dodge()) +
  ggplot2::facet_wrap(~ Ybin) +
  ggplot2::scale_fill_brewer(type = "qual", palette = "Set2", name = "SNP2") +
  ggplot2::labs(
    title = "Contingência - Q2 (SNP1 x SNP2 x Resposta)",
    x = "Genótipo SNP1",
    y = "Contagem"
  ) +
  ggplot2::theme_minimal()

print(plot)
```

Contingência – Q2 (SNP1 x SNP2 x Resposta)



```
fitrl2 <- glm(Ybin ~ xa1 + xd1 + xa2 + xd2 +
              xa1:xa2 + xa1:xd2 + xd1:xa2 + xd1:xd2,
              family=binomial(link="logit"), data=dat2)
summary(fitrl2)
```

```
##
## Call:
## glm(formula = Ybin ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xa1:xd2 +
##       xd1:xa2 + xd1:xd2, family = binomial(link = "logit"), data = dat2)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -0.752799   0.180996  -4.159 3.19e-05 ***
## xa1          1.084446   0.180996   5.992 2.08e-09 ***
## xd1          0.853044   0.252301   3.381 0.000722 ***
## xa2          0.511880   0.180996   2.828 0.004682 **
## xd2          0.408230   0.267112   1.528 0.126437
## xa1:xa2      0.255085   0.180996   1.409 0.158735
## xa1:xd2     -0.005907   0.267112  -0.022 0.982355
## xd1:xa2      0.529973   0.252301   2.101 0.035680 *
## xd1:xd2      0.285214   0.360793   0.791 0.429223
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
## Null deviance: 1178.43  on 899  degrees of freedom
## Residual deviance: 936.85  on 891  degrees of freedom
## AIC: 954.85
##
## Number of Fisher Scoring iterations: 4
```

```

cat("\nOR estimados:\n")

##
## OR estimados:
print(round(exp(coef(fitrl2)), 3))

## (Intercept)      xa1      xd1      xa2      xd2    xa1:xa2    xa1:xd2    xd1:xa2
##      0.471      2.958      2.347      1.668      1.504      1.291      0.994      1.699

cat("\nIC para OR:\n")

##
## IC para OR:
print(round(exp(confint(fitrl2)), 3))

##           2.5 % 97.5 %
## (Intercept) 0.331  0.676
## xa1         2.088  4.264
## xd1         1.432  3.864
## xa2         1.178  2.405
## xd2         0.893  2.554
## xa1:xa2      0.912  1.862
## xa1:xd2      0.589  1.686
## xd1:xa2      1.036  2.794
## xd1:xd2      0.653  2.694

pred2r <- predict(fitrl2, type="response")
class2r <- ifelse(pred2r >= 0.5, 1, 0)
cat("Tabela de classificação:\n")

## Tabela de classificação:
print(table(Predito=class2r, Observado=dat2$Ybin))

##      Observado
## Predito    0    1
##      0 489 121
##      1   85 205

cat("Acurácia:", round(mean(class2r == dat2$Ybin), 3), "\n")

## Acurácia: 0.771

```

Regressão Logística – Q1 Caso 2 (corte manual): Foi desafiador definir um valor de corte que gerasse uma separação mais equilibrada entre os grupos, mas com o corte em 105, conseguimos ao menos evitar grupos zerados ou com representações excessivamente baixas. Apesar disso, notamos que o modelo logístico apresentou perda de significância em relação à ANOVA para o efeito de dominância do SNP2 e para a interação **xa1:xa2**. Esse cenário, inclusive, mostrou-se facilmente influenciado pelos vários valores de corte que experimentamos. Hora era detectada significância de alguns efeitos, hora de outros. Podemos ver que houve impacto significativo na adoção da categorização da resposta Y. Tornou-se mais desafiador por conta, acreditamos, das grandes separação e dispersão existentes nos dados. Entretanto, já que no ANOVA nós trabalhamos com um modelo reduzido, decidimos experimentar a mesma abordagem aqui, removendo efeitos que antes não haviam sido dados como significativos, a fim de focar nos efeitos de interesse.

```

fitrl2_reduzido <- glm(Ybin ~ xa1 + xd1 + xa2 + xd2 +
                      xa1:xa2 + xd1:xa2,

```

```

family=binomial(link="logit"), data=dat2)
summary(fitrl2_reduzido)

##
## Call:
## glm(formula = Ybin ~ xa1 + xd1 + xa2 + xd2 + xa1:xa2 + xd1:xa2,
##      family = binomial(link = "logit"), data = dat2)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -0.8195     0.1564  -5.239 1.62e-07 ***
## xa1           1.0909     0.1333   8.186 2.69e-16 ***
## xd1           0.9992     0.1800   5.552 2.82e-08 ***
## xa2           0.5015     0.1808   2.774 0.00553 **
## xd2           0.5443     0.1674   3.252 0.00115 **
## xa1:xa2       0.2544     0.1803   1.411 0.15830
## xd1:xa2       0.5753     0.2487   2.313 0.02071 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 1178.43  on 899  degrees of freedom
## Residual deviance:  937.56  on 893  degrees of freedom
## AIC: 951.56
##
## Number of Fisher Scoring iterations: 4
cat("\nOR estimados:\n")

##
## OR estimados:
print(round(exp(coef(fitrl2_reduzido)), 3))

## (Intercept)      xa1      xd1      xa2      xd2      xa1:xa2      xd1:xa2
##      0.441      2.977      2.716      1.651      1.723      1.290      1.778
cat("\nIC para OR:\n")

##
## IC para OR:
print(round(exp(confint(fitrl2_reduzido)), 3))

##              2.5 % 97.5 %
## (Intercept) 0.324 0.600
## xa1         2.302 3.888
## xd1         1.908 3.868
## xa2         1.165 2.374
## xd2         1.241 2.395
## xa1:xa2     0.911 1.853
## xd1:xa2     1.091 2.899
pred2r <- predict(fitrl2_reduzido, type="response")
class2r <- ifelse(pred2r >= 0.5, 1, 0)
cat("Tabela de classificação:\n")

```

```
## Tabela de classificação:
```

```
print(table(Predito=class2r, Observado=dat2$Ybin))
```

```
##      Observado
```

```
## Predito   0   1
```

```
##          0 489 121
```

```
##          1   85 205
```

```
cat("Acurácia:", round(mean(class2r == dat2$Ybin), 3), "\n")
```

```
## Acurácia: 0.771
```

Regressão Logística – Q1 Caso 2 (modelo reduzido): Agora, com um modelo reduzido, baseado naquele que utilizamos no ANOVA, conseguimos recuperar a significância para o efeito de dominância do SNP2, mas não o efeito da interação **xa1:xa2**. Acreditamos então, depois de tantas tentativas, que a regressão logística para esse caso é inadequada por gerar perda de informação.

3.4 Questão 2 – Regressão Logística por População

```
logistica_pop <- function(dat, nome) {  
  cat("\n\n===== \n")  
  cat(" POPULAÇÃO:", nome, "\n===== \n")  
  
  # Codificação aditiva/dominância para SNP  
  dat$xa_snp <- dat$Geno_num - 1  
  dat$xd_snp <- ifelse(dat$Geno_num==1, 1, 0)  
  dat$Grupo_bin <- ifelse(dat$Grupo=="A", 0, 1)  
  
  # Dicotomizar Y  
  corte_local <- median(dat$Y)  
  dat$Ybin <- as.factor(ifelse(dat$Y > corte_local, 1, 0))  
  
  fit_logit <- glm(Ybin ~ Grupo_bin * (xa_snp + xd_snp),  
                  family=binomial(link="logit"), data=dat)  
  cat("\nModelo logístico - fator categórico:\n")  
  print(summary(fit_logit))  
  cat("\nOR estimados:\n")  
  print(round(exp(coef(fit_logit)), 3))  
  
  # Prob preditas  
  pred_r <- predict(fit_logit, type="response")  
  class_r <- ifelse(pred_r >= 0.5, 1, 0)  
  cat("\nAcurácia:", round(mean(class_r == dat$Ybin), 3), "\n")  
  
  # Comparação com ANOVA para o mesmo dado  
  cat("\n[ANOVA correspondente - para comparação]\n")  
  fit_anova <- lm(Y ~ Grupo * Genotipo, data=dat)  
  cat("ANOVA p-valor Genotipo:", anova(fit_anova)["Genotipo", "Pr(>F)"], "\n")  
  cat("Logístico p-valor xa: ", summary(fit_logit)$coef["xa_snp", "Pr(>|z|)"], "\n")  
  
  invisible(fit_logit)  
}
```

```
logistica_pop(dat_P1, "P1")
```

```
##
##
## =====
## POPULAÇÃO: P1
## =====
##
## Modelo logístico - fator categórico:
##
## Call:
## glm(formula = Ybin ~ Grupo_bin * (xa_snp + xd_snp), family = binomial(link = "logit"),
##     data = dat)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -1.2825     0.3311  -3.874 0.000107 ***
## Grupo_bin       1.9910     0.4324   4.605 4.13e-06 ***
## xa_snp        -0.5893     0.3311  -1.780 0.075075 .
## xd_snp         0.5893     0.5095   1.157 0.247427
## Grupo_bin:xa_snp  0.8924     0.4324   2.064 0.039025 *
## Grupo_bin:xd_snp  0.5739     0.7908   0.726 0.467994
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##    Null deviance: 249.53  on 179  degrees of freedom
## Residual deviance: 198.68  on 174  degrees of freedom
## AIC: 210.68
##
## Number of Fisher Scoring iterations: 4
##
##
## OR estimados:
##      (Intercept)      Grupo_bin      xa_snp      xd_snp Grupo_bin:xa_snp Grupo_bin:xd_snp
##          0.277          7.323          0.555          1.803          2.441          1.779
##
## Acurácia: 0.733
##
## [ANOVA correspondente - para comparação]
## ANOVA p-valor Genotipo: 0.7613525
## Logístico p-valor xa: 0.07507511
```

```
logistica_pop(dat_P2, "P2")
```

```
##
##
## =====
## POPULAÇÃO: P2
## =====
##
## Modelo logístico - fator categórico:
##
```



```
## Call:
## glm(formula = Ybin ~ Grupo_bin * (xa_snp + xd_snp), family = binomial(link = "logit"),
##      data = dat)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -0.1312    0.3635  -0.361   0.7182
## Grupo_bin      1.3090    0.6583   1.989   0.0468 *
## xa_snp         1.7406    0.3635   4.789 1.68e-06 ***
## xd_snp        -0.7161    0.5393  -1.328   0.1842
## Grupo_bin:xa_snp  0.4488    0.6583   0.682   0.4954
## Grupo_bin:xd_snp -0.4617    0.8517  -0.542   0.5877
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 249.53  on 179  degrees of freedom
## Residual deviance: 172.40  on 174  degrees of freedom
## AIC: 184.4
##
## Number of Fisher Scoring iterations: 6
##
##
## OR estimados:
##      (Intercept)      Grupo_bin      xa_snp      xd_snp Grupo_bin:xa_snp Grupo_bin:xd_snp
##      0.877         3.703         5.701         0.489         1.566         0.630
##
## Acurácia: 0.767
##
## [ANOVA correspondente - para comparação]
## ANOVA p-valor Genotipo: 1.472674e-24
## Logístico p-valor xa: 1.677762e-06
```

```
logistica_pop(dat_P3, "P3")
```

```
##
##
## =====
## POPULAÇÃO: P3
## =====
##
## Modelo logístico - fator categórico:
##
## Call:
## glm(formula = Ybin ~ Grupo_bin * (xa_snp + xd_snp), family = binomial(link = "logit"),
##      data = dat)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -0.2099    0.3265  -0.643   0.520
## Grupo_bin      1.2988    0.6417   2.024   0.043 *
## xa_snp         1.3995    0.3265   4.287 1.81e-05 ***
## xd_snp        -0.6374    0.5151  -1.237   0.216
## Grupo_bin:xa_snp  0.8789    0.6417   1.370   0.171
```

```
## Grupo_bin:xd_snp -0.1832      0.8404 -0.218      0.827
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 249.53  on 179  degrees of freedom
## Residual deviance: 178.70  on 174  degrees of freedom
## AIC: 190.7
##
## Number of Fisher Scoring iterations: 6
##
##
## OR estimados:
##      (Intercept)      Grupo_bin      xa_snp      xd_snp Grupo_bin:xa_snp Grupo_bin:xd_snp
##           0.811           3.665           4.053           0.529           2.408           0.83
##
## Acurácia: 0.767
##
## [ANOVA correspondente - para comparação]
## ANOVA p-valor Genotipo: 1.384551e-21
## Logístico p-valor xa: 1.812864e-05
```

Regressão Logística por população: P1: o efeito de `xa_snp` não é significativo ($p = 0,075$), consistente com a ANOVA ($p = 0,761$). Apenas `Grupo_bin` é significativo ($OR = 7,32$; $p < 0,001$), refletindo a diferença entre subgrupos. Note-se, porém, que a interação `Grupo_bin:xa_snp` aparece significativa ($p = 0,039$) — resultado espúrio ausente na ANOVA, possivelmente devido à dicotomização combinada com o tamanho amostral moderado.

P2: `xa_snp` é significativo ($p < 0,001$), com $OR = 5,70$, confirmando o efeito aditivo do SNP. A interação `Grupo_bin:xa_snp` não é significativa ($p = 0,495$), coerente com a ausência de interação na ANOVA. Acurácia de 76,7%.

P3: `xa_snp` é significativo ($p < 0,001$; $OR = 4,05$), mas a interação `Grupo_bin:xa_snp` não atinge significância ($p = 0,171$) — ao contrário da ANOVA, que detectou interação clara ($p < 0,001$). Este é um exemplo concreto de perda de poder pela dicotomização: a interação $SNP \times$ subgrupo, evidente nos dados contínuos, torna-se indetectável após o corte na mediana.

3.5 Regressão Logística Combinada (3 populações)

```
dat_all$xa_snp <- dat_all$Geno_num - 1
dat_all$xd_snp <- ifelse(dat_all$Geno_num==1, 1, 0)
dat_all$Grupo_bin <- ifelse(dat_all$Grupo=="A", 0, 1)

# Efeito fixo de Pop
fitrl_all_fixo <- glm(Ybin ~ Grupo_bin * (xa_snp + xd_snp) + Pop,
                     family=binomial(link="logit"), data=dat_all)
summary(fitrl_all_fixo)

##
## Call:
## glm(formula = Ybin ~ Grupo_bin * (xa_snp + xd_snp) + Pop, family = binomial(link = "logit"),
##      data = dat_all)
##
```

```
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -0.2407    0.2132  -1.129  0.25889
## Grupo_bin      1.3688    0.2606   5.252 1.50e-07 ***
## xa_snp         0.7487    0.1666   4.495 6.96e-06 ***
## xd_snp        -0.3926    0.2872  -1.367  0.17171
## PopP2         -0.2237    0.2368  -0.945  0.34477
## PopP3         -0.6214    0.2399  -2.590  0.00959 **
## Grupo_bin:xa_snp 0.5102    0.2603   1.960  0.05002 .
## Grupo_bin:xd_snp 0.1500    0.4145   0.362  0.71743
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##    Null deviance: 748.60  on 539  degrees of freedom
## Residual deviance: 621.32  on 532  degrees of freedom
## AIC: 637.32
##
## Number of Fisher Scoring iterations: 4
cat("\nOR estimados:\n")

##
## OR estimados:
print(round(exp(coef(fitrl_all_fixo)), 3))

##              (Intercept)      Grupo_bin      xa_snp      xd_snp      PopP2      PopP3
##              0.786         3.931         2.114         0.675         0.800         0.533

# Modelo misto logístico (Pop aleatório)
library(lme4)
fitrl_all_misto <- glmer(Ybin ~ Grupo_bin * (xa_snp + xd_snp) + (1|Pop),
                        family=binomial(link="logit"), data=dat_all)
summary(fitrl_all_misto)

## Generalized linear mixed model fit by maximum likelihood (Laplace Approximation) ['glmerMod']
## Family: binomial ( logit )
## Formula: Ybin ~ Grupo_bin * (xa_snp + xd_snp) + (1 | Pop)
## Data: dat_all
##
##              AIC      BIC    logLik -2*log(L)  df.resid
##              640.9    670.9   -313.4    626.9     533
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -3.08692 -0.74029 -0.07955  0.81553  2.07019
##
## Random effects:
## Groups Name      Variance Std.Dev.
## Pop      (Intercept) 0.03731  0.1932
## Number of obs: 540, groups: Pop, 3
##
## Fixed effects:
##              Estimate Std. Error z value Pr(>|z|)
```

```
## (Intercept)      -0.5190      0.2000  -2.595  0.00945 **
## Grupo_bin        1.3614      0.2599   5.237  1.63e-07 ***
## xa_snp           0.7441      0.1661   4.481  7.44e-06 ***
## xd_snp          -0.3897      0.2864  -1.361  0.17366
## Grupo_bin:xa_snp  0.5075      0.2597   1.954  0.05068 .
## Grupo_bin:xd_snp  0.1473      0.4133   0.356  0.72158
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
##          (Intr) Grp_bn xa_snp xd_snp Grp_bn:x_s
## Grupo_bin  -0.531
## xa_snp      -0.146  0.114
## xd_snp      -0.480  0.369  0.101
## Grp_bn:x_s  0.092  0.175 -0.638 -0.065
## Grp_bn:xd_s 0.333 -0.627 -0.070 -0.693 -0.109
```

Regressão Logística combinada: No modelo com Pop fixo, Grupo_bin (OR = 3,93; $p < 0,001$) e xa_snp (OR = 2,11; $p < 0,001$) são significativos. PopP3 é significativo ($p = 0,010$), indicando que P3 tem menor chance basal de Y=1 em relação a P1. A interação Grupo_bin:xa_snp é marginalmente não significativa ($p = 0,050$). No modelo misto (glmer), a variância entre populações é ínfima ($\hat{\sigma}_{Pop}^2 = 0,037$) e os efeitos fixos são praticamente idênticos ao modelo fixo, confirmando a robustez das conclusões.

3.6 Comparação ANOVA vs. Regressão Logística

```
# ANOVA Q1C1
pval_anova_q1 <- anova(lm(Y ~ xa + xd, data=dat1))["xa", "Pr(>F)"]
pval_logit_q1 <- summary(fitrl1_ad)$coef["xa", "Pr(>|z|)"]
pval_anova_P2 <- anova(res_P2$fit_cat)["Genotipo", "Pr(>F)"]
pval_anova_P3 <- anova(res_P3$fit_cat)["Grupo:Genotipo", "Pr(>F)"]

# Logístico P2
d2tmp <- dat_P2
d2tmp$xa <- d2tmp$Geno_num - 1
d2tmp$xd <- ifelse(d2tmp$Geno_num==1, 1, 0)
d2tmp$Gb <- ifelse(d2tmp$Grupo=="A", 0, 1)
d2tmp$Ybin2 <- as.factor(ifelse(d2tmp$Y > median(d2tmp$Y), 1, 0))
pval_logit_P2 <- tryCatch(
  summary(glm(Ybin2 ~ Gb*(xa+xd), family=binomial, data=d2tmp))$coef["xa", "Pr(>|z|)"],
  error = function(e) NA)

# Logístico P3
d3tmp <- dat_P3
d3tmp$xa <- d3tmp$Geno_num - 1
d3tmp$xd <- ifelse(d3tmp$Geno_num==1, 1, 0)
d3tmp$Gb <- ifelse(d3tmp$Grupo=="A", 0, 1)
d3tmp$Ybin3 <- as.factor(ifelse(d3tmp$Y > median(d3tmp$Y), 1, 0))
fit_logit_p3 <- tryCatch(
  glm(Ybin3 ~ Gb*(xa+xd), family=binomial, data=d3tmp),
  error = function(e) NULL)
pval_logit_P3 <- if(!is.null(fit_logit_p3)) {
  cf <- summary(fit_logit_p3)$coef
```

```

  if ("Gb:xa" %in% rownames(cf)) cf["Gb:xa","Pr(>|z|)"] else NA
} else NA

comp <- data.frame(
  Modelo = c("ANOVA xa (Q1-C1)", "Logístico xa (Q1-C1)",
             "ANOVA SNP (P2)", "Logístico xa (P2)",
             "ANOVA SNP x Grupo (P3)", "Logístico xa x Grupo (P3)"),
  P_valor = round(c(pval_anova_q1, pval_logit_q1,
                   pval_anova_P2, pval_logit_P2,
                   pval_anova_P3, pval_logit_P3), 4)
)
knitr::kable(comp, caption="Comparação de p-valores: ANOVA vs. Regressão Logística")

```

Table 4: Comparação de p-valores: ANOVA vs. Regressão Logística

Modelo	P_valor
ANOVA xa (Q1-C1)	0.0000
Logístico xa (Q1-C1)	0.0000
ANOVA SNP (P2)	0.0000
Logístico xa (P2)	0.0000
ANOVA SNP x Grupo (P3)	0.0000
Logístico xa x Grupo (P3)	0.1708

Impacto da dicotomização: A tabela de p-valores ilustra de forma clara o impacto da dicotomização. Para efeitos fortes — como o efeito aditivo em Q1-C1 e em P2 — ambos os modelos detectam significância ($p < 0,001$), e a perda de poder é negligenciável. O caso mais revelador é P3: a interação SNP×subgrupo, altamente significativa na ANOVA ($p < 0,001$), torna-se completamente indetectável na regressão logística ($p = 0,171$) — perda de poder severa causada pela dicotomização de uma resposta contínua com interação moderada.

O Caso 2 ilustra um problema adicional: com muitos preditores e Y dicotomizado, a regressão logística pode sofrer separação completa, produzindo estimativas numericamente instáveis e ICs indefinidos — situação em que o modelo é formalmente inapropriado.

Em síntese, quando Y é genuinamente contínua, a ANOVA é preferível: preserva toda a informação, tem maior poder e evita os problemas de separação. A regressão logística é o modelo correto apenas quando o fenótipo é binário por natureza (ex.: hipertensão sim/não), situação em que os ORs oferecem interpretação clínica direta — por exemplo, OR = 4,04 para xa em Q1-C1 significa que cada alelo A adicional quadruplica a chance de PAD acima da mediana.